

微服务面试题

面试官：Spring Cloud 5大组件有哪些？

候选人：

早期我们一般认为的Spring Cloud五大组件是

- Eureka ：注册中心
- Ribbon ：负载均衡
- Feign ：远程调用
- Hystrix：服务熔断
- Zuul/Gateway ：网关

随着SpringCloudAlibba在国内兴起，我们项目中使用了一些阿里巴巴的组件

- 注册中心/配置中心 Nacos
- 负载均衡 Spring Cloud LoadBalancer
- 服务调用 Feign
- 服务保护 sentinel
- 服务网关 Gateway

面试官：服务注册和发现是什么意思？Spring Cloud 如何实现服务注册发现？

候选人：

我理解的是主要三块大功能，分别是服务注册、服务发现、服务状态监控

我们当时项目采用的eureka作为注册中心，这个也是spring cloud体系中的一个核心组件

服务注册：服务提供者需要把自己的信息注册到eureka，由eureka来保存这些信息，比如服务名称、ip、端口等等

服务发现：消费者向eureka拉取服务列表信息，如果服务提供者有集群，则消费者会利用负载均衡算法，选择一个发起调用

服务监控：服务提供者会每隔30秒向eureka发送心跳，报告健康状态，如果eureka服务90秒没接收到心跳，从eureka中剔除

我理解的服务注册与发现主要包括服务注册、服务发现和服务健康监测。我们项目使用 Nacos 作为注册中心，它是 Spring Cloud Alibaba 体系中的核心组件。

服务注册：服务提供者启动后，会把服务名称、IP、端口、分组、集群等实例信息注册到 Nacos，由 Nacos 统一维护服务实例列表。

服务发现：服务消费者调用其他服务时，会从 Nacos 获取指定服务的可用实例列表。若项目使用 OpenFeign 发起服务调用，OpenFeign 会结合 Spring Cloud LoadBalancer，在多个可用实例中按照负载均衡策略选择一个实例，再发起 HTTP 请求。

服务监测：服务实例会定时向 Nacos 发送心跳，报告自身健康状态。Nacos 根据心跳和健康检查结果维护实例状态；临时实例长时间未上报心跳时，会被标记为不健康，并最终从可用实例列表中剔除。消费者可以通过服务列表变化感知实例的上下线。

面试官：我看你之前也用过nacos、你能说下nacos与eureka的区别？

候选人：

我们当时xx项目就是采用的nacos作为注册中心，选择nacos还要一个重要原因就是它支持配置中心，不过nacos作为注册中心，也比eureka要方便好用一些，主要相同不同点在于几点：

- 共同点

Nacos与eureka都支持服务注册和服务拉取，都支持服务提供者心跳方式做健康检测

- Nacos与Eureka的区别
- Nacos支持服务端主动检测提供者状态：临时实例采用心跳模式，非临时实例采用主动检测模式
- 临时实例心跳不正常会被剔除，非临时实例则不会被剔除
- Nacos支持服务列表变更的消息推送模式，服务列表更新更及时
- Nacos集群默认采用AP方式，当集群中存在非临时实例时，采用CP模式；Eureka采用AP方式

面试官：你们项目负载均衡如何实现的？

候选人：

是这样~~

在服务调用过程中的负载均衡一般使用SpringCloud的Ribbon 组件实现，Feign的底层已经自动集成了Ribbon，使用起来非常简单

当发起远程调用时，ribbon先从注册中心拉取服务地址列表，然后按照一定的路由策略选择一个发起远程调用，一般的调用策略是轮询

我们项目的客户端负载均衡使用 Spring Cloud LoadBalancer 实现。

在远程服务调用时，Spring Cloud LoadBalancer 会通过服务发现组件从 Nacos 获取目标服务的可用实例列表，然后按照配置的负载均衡策略选择一个实例发起调用。默认策略通常是轮询，也可以根据业务需要配置随机、加权或自定义策略。

如果项目使用 OpenFeign，OpenFeign 负责声明和发起服务调用，底层由 Spring Cloud LoadBalancer 从多个可用服务实例中选择目标实例。因此，调用方不需要手动拼接服务地址，只需要按服务名调用即可。

面试官：Ribbon负载均衡策略有哪些？

候选人：

我想想啊，有很多种，我记得几个：

- RoundRobinRule：简单轮询服务列表来选择服务器
- WeightedResponseTimeRule：按照权重来选择服务器，响应时间越长，权重越小
- RandomRule：随机选择一个可用的服务器
- ZoneAvoidanceRule：区域敏感策略，以区域可用的服务器为基础进行服务器的选择。使用Zone对服务器进行分类，这个Zone可以理解为一个机房、一个机架等。而后再对Zone内的多个服务做轮询(默认)

面试官：如果想自定义负载均衡策略如何实现？

候选人：

提供了两种方式：

- 创建类实现IRule接口，可以指定负载均衡策略，这个是全局的，对所有的远程调用都起作用
- 在客户端的配置文件中，可以配置某一个服务调用的负载均衡策略，只是对配置的这个服务生效远程调用

面试官：什么是服务雪崩，怎么解决这个问题？

候选人：

服务雪崩是指一个服务失败，导致整条链路的服务都失败的情形，一般我们在项目解决的话就是两种方案，第一个是服务降级，第二个是服务熔断，如果流量太大的话，可以考虑限流

服务降级：服务自我保护的一种方式，或者保护下游服务的一种方式，用于确保服务不会受请求突增影响变得不可用，确保服务不会崩溃，一般在实际开发中与feign接口整合，编写降级逻辑

服务熔断：默认关闭，需要手动打开，如果检测到 10 秒内请求的失败率超过 50%，就触发熔断机制。之后每隔 5 秒重新尝试请求微服务，如果微服务不能响应，继续走熔断机制。如果微服务可达，则关闭熔断机制，恢复正常请求

面试官：你们的微服务是怎么监控的？

候选人：

我们项目中采用的skywalking进行监控的

- ，skywalking主要可以监控接口、服务、物理实例的一些状态。特别是在压测的时候可以看到众多服务中哪些服务和接口比较慢，我们可以针对性的分析和优化。
- ，我们还在skywalking设置了告警规则，特别是在项目上线以后，如果报错，我们分别设置了可以给相关负责人发短信和发邮件，第一时间知道项目的bug情况，第一时间修复

面试官：你们项目中有没有做过限流？怎么做的？

候选人：

我当时做的xx项目，采用就是微服务的架构，因为xx因为，应该会有突发流量，最大QPS可以达到2000，但是服务支撑不住，我们项目都通过压测最多可以支撑1200QPS。因为我们平时的QPS也就不到100，为了解决这些突发流量，所以采用了限流。

我当时做的广告平台线索回传和自动建单接口，因为广告投放可能导致短时间内线索集中到达，可能会有突发流量，最大QPS可以达到2000，但是服务支撑不住，我们项目都通过压测最多可以支撑1200QPS。因为我们平时的QPS也就不到50，为了解决这些突发流量，所以采用了限流。

【版本1】

我们当时采用的nginx限流操作，nginx使用的漏桶算法来实现过滤，让请求以固定的速率处理请求，可以应对突发流量，我们控制的速率是按照ip进行限流，限制的流量是每秒20

【版本2】

我们当时采用的是spring cloud gateway中支持局部过滤器RequestRateLimiter来做限流，使用的是令牌桶算法，可以根据ip或路径进行限流，可以设置每秒填充平均速率，和令牌桶总容量

- 段配置位于某个具体 Route 的 `filters` 下。这样配置的就是局部过滤器，只对该 Route 生效。
- `RequestRateLimiter` 是 Gateway 过滤器，用来调用限流器；
- 默认使用的 `RedisRateLimiter` 才是基于令牌桶算法实现的；

面试官：限流常见的算法有哪些呢？

候选人：

比较常见的限流算法有漏桶算法和令牌桶算法

漏桶算法是把请求存入到桶中，以固定速率从桶中流出，可以让我们的服务做到绝对的平均，起到很好的限流效果

令牌桶算法在桶中存储的是令牌，按照一定的速率生成令牌，每个请求都要先申请令牌，申请到令牌以后才能正常请求，也可以起到很好的限流作用

它们的区别是，漏桶和令牌桶都可以处理突发流量，其中漏桶可以做到绝对的平滑，令牌桶有可能会产生突发大量请求的情况，一般nginx限流采用的漏桶，spring cloud gateway中可以支持令牌桶算法

面试官：什么是CAP理论？

候选人：

CAP主要是在分布式项目下的一个理论。包含了三项，一致性、可用性、分区容错性

- 一致性(Consistency)是指更新操作成功并返回客户端完成后，所有节点在同一时间的数据完全一致(强一致性)，不能存在中间状态。
- 可用性(Availability) 是指系统提供的服务必须一直处于可用的状态，对于用户的每一个操作请求总是能够在有限的时间内返回结果。
- 分区容错性(Partition tolerance) 是指分布式系统在遇到任何网络分区故障时，仍然需要能够保证对外提供满足一致性和可用性的服务，除非是整个网络环境都发生了故障。

面试官：为什么分布式系统中无法同时保证一致性和可用性？

候选人：

嗯，是这样的~~

首先一个前提，对于分布式系统而言，分区容错性是一个最基本的要求，因此基本上我们在设计分布式系统的时候只能从一致性（C）和可用性（A）之间进行取舍。

如果保证了一致性（C）：对于节点N1和N2，当往N1里写数据时，N2上的操作必须被暂停，只有当N1同步数据到N2时才能对N2进行读写请求，在N2被暂停操作期间客户端提交的请求会收到失败或超时。显然，这与可用性是相悖的。

如果保证了可用性（A）：那就不能暂停N2的读写操作，但同时N1在写数据的话，这就违背了一致性的要求。

面试官：什么是BASE理论？

候选人：

嗯，这个也是CAP分布式系统设计理论

BASE是CAP理论中AP方案的延伸，核心思想是即使无法做到强一致性（StrongConsistency，CAP的一致性就是强一致性），但应用可以采用适合的方式达到最终一致性（Eventual Consistency）。它的思想包含三方面：

- Basically Available（基本可用）：基本可用是指分布式系统在出现不可预知的故障的时候，允许损失部分可用性，但不等于系统不可用。
- Soft state（软状态）：即是指允许系统中的数据存在中间状态，并认为该中间状态的存在不会影响系统的整体可用性，即允许系统在不同节点的数据副本之间进行数据同步的过程存在延时。
- Eventually consistent（最终一致性）：强调系统中所有的数据副本，在经过一段时间的同步后，最终能够达到一个一致的状态。其本质是需要系统保证最终数据能够达到一致，而不需要实时保证系统数据的强一致性。

面试官：你们采用哪种分布式事务解决方案？

候选人：

我们当时是xx项目，主要使用到的seata的at模式解决的分布式事务

seata的AT模型分为两个阶段：

- 阶段一RM的工作：① 注册分支事务 ② 记录undo-log（数据快照）③ 执行业务sql并提交 ④报告事务状态
- 阶段二提交时RM的工作：删除undo-log即可
- 阶段二回滚时RM的工作：根据undo-log恢复数据到更新前

at模式牺牲了一致性，保证了可用性，不过，它保证的是最终一致性

面试官：分布式服务的接口幂等性如何设计？

候选人：

嗯，我们当时有一个xx项目的下单操作，采用的token+redis实现的，流程是这样的

第一次请求，也就是用户打开了商品详情页面，我们会发起一个请求，在后台生成一个唯一token存入redis，key就是用户的id，value就是这个token，同时把这个token返回前端

第二次请求，当用户点击了下单操作会后，会携带之前的token，后台先到redis进行验证，如果存在token，可以执行业务，同时删除token；如果不存在，则直接返回，不处理业务，就保证了同一个token只处理一次业务，就保证了幂等性

面试官：xxl-job路由策略有哪些？

候选人：

xxl-job提供了很多的路由策略，我们平时用的较多就是：轮询、故障转移、分片广播...

面试官：xxl-job任务执行失败怎么解决？

候选人：

有这么几个操作

第一：路由策略选择故障转移，优先使用健康的实例来执行任务

第二，如果还有失败的，我们在创建任务时，可以设置重试次数

第三，如果还有失败的，就可以查看日志或者配置邮件告警来通知相关负责人解决

面试官：如果有大数据量的任务同时都需要执行，怎么解决？

候选人：

我们会让部署多个实例，共同去执行这些批量的任务，其中任务的路由策略是分片广播

在任务执行的代码中可以获取分片总数和当前分片，按照取模的方式分摊到各个实例执行就可以了

SpringCloudAlibaba里负载均衡不是通过什么loader-balancer吗，为什么说用的Ribbon？

“负载均衡（load balance）”是能力/概念，Ribbon是实现这项能力的客户端组件。

在较早的 Spring Cloud Alibaba / Spring Cloud 版本中：

- Nacos 负责服务注册与发现，返回实例列表。
- Ribbon 根据负载均衡策略（轮询、随机、权重等）从实例列表中选一个。
- `@LoadBalanced RestTemplate` 通常由 Ribbon 接管实现客户端负载均衡。

所以常说“Spring Cloud Alibaba 用 Ribbon”，指的是它曾复用 Spring Cloud Netflix Ribbon 作为负载均衡实现，不是说 Ribbon 等同于“负载均衡”这个概念。

新版情况有变化：Ribbon 已停止维护，较新的 Spring Cloud 默认使用 Spring Cloud LoadBalancer 替代它。Nacos 本身依旧主要负责服务发现；具体由 Ribbon 还是 Spring Cloud LoadBalancer 选实例，取决于你的 Spring Cloud 版本和依赖。

重点问题：JAVA微服务里的服务降级和服务熔断是什么？区别又是什么？

在 Java 微服务中：

- 服务降级：服务出问题或压力过大时，主动降低功能质量，保证核心功能可用。
- 服务熔断：下游服务故障达到阈值后，暂时停止继续调用，避免故障扩散。

举个例子：订单服务调用优惠券服务。

当优惠券服务响应很慢或不可用时：

订单服务
↓
优惠券服务异常

订单服务可以直接返回“暂不计算优惠券，但允许下单”，这叫服务降级。

如果优惠券服务连续超时、报错，订单服务判断它已经不健康，于是暂时不再调用优惠券服务，直接执行兜底逻辑。这个“暂时不调用”的开关就是服务熔断。

对比	服务降级	服务熔断
关注点	出问题后怎么处理	是否继续调用故障服务
主要目的	保住核心功能	防止故障扩散、保护系统
典型行为	返回默认值、缓存数据、空结果、关闭非核心功能	快速失败，直接返回，不访问下游
是否一定停止调用	不一定	会暂时停止调用
范围	一种整体容灾策略	降级策略中的一种技术手段

熔断通常有三个状态：

- Closed：正常调用并统计失败率。
- Open：失败超过阈值，暂时禁止调用，直接失败或降级。
- Half-Open：等待一段时间后放少量请求试探；恢复则关闭熔断，否则继续打开。

一句话记忆：

降级是“功能打折但系统继续运行”，熔断是“发现下游不行，先别调用它”。

两者经常配合使用：熔断负责快速阻断，降级负责返回兜底结果。

重点问题：所以“暂不计算优惠券，但允许下单”本身就是熔断了然后降级，是吗？

对，但要区分“结果”和“过程”：

优惠券服务连续超时
↓
触发熔断：暂时不再调用优惠券服务
↓
执行降级：按“无优惠”处理
↓
允许下单

因此，“暂不计算优惠券，但允许下单”是降级结果；如果前面还有“停止调用优惠券服务”的熔断动作，那么整体就是“熔断 + 降级”。

如果只是偶尔调用失败，然后直接返回“无优惠”，但没有达到熔断阈值、也没有停止后续调用，那就只是降级，不算熔断。

重点问题：降级和熔断是不是在sentinal里配置？

大白话说：是，但只配置了一半。

- 熔断：在 Sentinel 里配置规则，比如失败率超过多少就熔断。
- 降级触发条件：也可以在 Sentinel 里配置，比如异常比例、慢调用比例超过阈值。
- 降级后返回什么：要在你自己的代码里写，比如返回缓存、默认值或提示信息。

例如：

```
graph TD
    A[Sentinel发现库存服务连续失败] --> B[Sentinel触发熔断]
    B --> C[执行你写的fallback代码]
    C --> D[返回“库存暂时不可用”或缓存库存]
```

所以准确说法是：

Sentinel负责配置和判断“什么时候限流、什么时候熔断”；开发者负责编写“触发后返回什么结果”的降级代码。

Sentinel不是一个单独的服务降级返回值生成器，具体兜底内容仍然要自己实现。

重点问题：重点问题：“Sentinel发现库存服务连续失败 ↓ Sentinel触发熔断 ↓ 执行你写的fallback代码 ↓ 返回“库存暂时不可用”或缓存库存”
这里好像只是熔断和熔断后的回调，好像没有结合降级是吗？

你理解得对。之前那段流程主要展示的是：

熔断触发 → 执行 fallback

但这两步合起来，才完整体现了“熔断 + 降级”。

简单区分：

熔断：不再调用库存服务

降级：不调用之后，返回什么替代结果

完整流程应该是：

```
graph TD
    A[调用库存服务失败] --> B[还没达到熔断阈值]
    B --> C[本次请求异常，执行fallback]
    C --> D[返回缓存或默认值]
```

这只是“服务降级”，还没有熔断。

如果持续失败：

```
graph TD
    A[持续失败达到Sentinel配置的阈值] --> B[Sentinel打开熔断器]
    B --> C[后续请求不再调用库存服务]
    C --> D[直接执行fallback降级]
```


↓
返回缓存或默认值

这时才是“熔断 + 降级”。

所以：

- 失败后返回默认值：降级
- 直接不再请求下游：熔断
- 不再请求下游，并返回默认值：熔断后降级

Sentinel里通常把这部分叫“熔断降级”，因为它负责判断什么时候熔断，而 **fallback** 代码负责实现降级后的具体业务结果。

重点问题：所以说熔断后的fallback里其实就是降级对吗？

对，熔断后的 fallback 本质上就是降级处理。

但要注意两者不是完全等价：

熔断：停止调用异常的下游服务
降级：调用失败后执行备用方案
fallback：降级方案的代码实现

所以完整过程是：

下游服务连续失败
↓
触发熔断，不再调用下游
↓
执行 fallback
↓
返回缓存、默认值或友好提示

也就是说：

熔断是手段，降级是结果，fallback 是降级逻辑的具体代码。

另外，即使没有触发熔断，只要调用超时或异常后执行了 fallback，也属于服务降级。

重点问题：如何做限流？通常在 Gateway 做第一层入口限流，在各个微服务内部再使用 Sentinel 做第二层精细限流。Gateway负责控制整体流量，Sentinel负责保护具体服务和资源，两者一般配合使用。