

邓懿轩 · 面试押题

A. 八股 / 基础原理题 共 77 题

方向一：AI Agent / 大模型 / RAG / 应用框架 (A1, 共 34 题)

【A1-01】【L1】Token、Embedding 与上下文窗口

题目：什么是 Token？Embedding 在 RAG 里起什么作用？上下文窗口超长时你会怎么处理？

思考方向：从“文本如何变成模型可计算的数字”切入，再落到工程上的截断/压缩。

考察点：LLM 基础认知、向量语义表示、长上下文工程。

参考答案

- Token 是模型的最小处理单元，中文 1 字 $\approx$ 1~2 token；计费、限流、上下文长度都以 token 计。
- Embedding 把文本映射成高维稠密向量，语义相近的文本向量距离近，是向量检索/语义召回的基础。
- 超长上下文：滑动窗口截断（保留 system + 最近 N 轮 + 相关检索片段）、对话摘要压缩、把历史放到向量记忆里按需召回，而非全塞进 prompt。

评分要点

- **优秀：**能说出截断会丢信息、需要“分层记忆 + 摘要”策略，并关联 RAG 的检索片段注入。
- **及格：**讲清 Token/Embedding 概念与基本截断方式。
- **不足：**把 Token 等同于“字”，或不知道 Embedding 是向量。

常见追问：1) 为什么 1 个汉字常算 1~2 个 token？2) 向量维度越高越好吗？

★意思是这里说的是解决超长上下文的三种办法，并不是说这三种方法要同时运用，对吗？

对，这里列的是三种处理超长上下文的办法，并不要求同时使用。

可以只用一种，也可以根据需要组合使用：

- **滑动窗口截断：**保留最近的聊天，移除较早内容。
- **摘要压缩：**把较早内容缩成简短总结。
- **按需召回：**把历史存起来，需要时再找回相关内容。

其中，括号里的“相关检索片段”已经体现了按需召回，所以这三种办法也有交叉，并非完全独立。

【A1-02】【L2】Transformer 自注意力机制

题目：简述 Transformer 的自注意力（Self-Attention）与多头注意力，为什么需要位置编码？

思考方向： $Q/K/V \rightarrow$ 相似度加权求和 $\rightarrow$ 多头并行捕捉不同子空间关系。

考察点：大模型底层架构理解。

参考答案

- Self-Attention：输入经线性变换得 Q、K、V，用 $Q \cdot K^T$ 算词与词的相似度，softmax 归一化后加权求和 V，得到融合上下文的表示；除以 $\sqrt{d}$ 防止梯度消失。
- 多头：把 Q/K/V 拆成多组并行计算，不同头关注不同语义子空间（语法、指代、位置等），最后拼接。

- 注意力本身无视顺序，需位置编码（正弦/可学习/RoPE 旋转位置编码）注入位置信息；RoPE 是现代主流。

评分要点

- **优秀**：写出 Q/K/V 计算流程、 $\sqrt{d}$ 缩放原因、多头意义、RoPE 优于绝对位置编码（外推性）。
- **及格**：讲清 Q/K/V 与加权求和、多头和多位置编码作用。
- **不足**：只会背“注意力就是加权求和”，讲不出 Q/K/V 与缩放。

常见追问：1) 为什么自注意力复杂度是 $O(n^2)$ ，工程上如何优化？2) RoPE 相对正弦编码的优势？

面试官您好，这三个部分是 Transformer 读懂语言的核心，我可以分为三个层面来回答：

第一，关于自注意力机制（Self-Attention）：

它的核心目的，是让句子里的每个词**结合上下文，搞清楚自己的真正含义**。

它的计算流程可以分为四步：

1. **生成 Q、K、V**：输入经过线性变换，每个词都会生成 Q （查询/搜索请求）、 K （标签/索引）和 V （实际内容信息）。
2. **打分与缩放**：用 Q 和 K 做点积（ $Q \cdot K^T$ ）计算词与词的相关性得分。特别关键的一步是**必须除以 $\sqrt{d}$** ，因为向量维度相乘累加后数值会膨胀，除以 $\sqrt{d}$ 是为了给分数降温，避免送入下一步时数值过大导致 Softmax 饱和与**梯度消失**。
3. **归一化**：通过 Softmax 将打分转化为加起来为 100% 的注意力权重概率。
4. **加权求和**：用这个权重对 V 进行加权求和，原本孤立的词就吸收了整句话的上下文信息。

第二，关于多头注意力（Multi-Head Attention）：

如果只算一次注意力（单头），模型看句子的视角会很单一，容易‘以偏概全’。

所以模型把 Q 、 K 、 V 拆分成多组（比如 8 个或 32 个头）并行计算：

- 不同的‘头’各司其职，在不同的子空间里捕捉不同维度的特征——有的头关注**代词指代**，有的头关注**语法主谓宾**，有的头关注**长短距离依赖**。
- 最后把各个头得出的特征**拼接（Concat）起来**，这样模型对整句话的理解就更加立体、全面。

第三，为什么需要位置编码（Positional Encoding）：

这是因为 Transformer 是一口气把所有词同时送入显卡并行计算的，**自注意力机制本身是完全无视前后语序的**。如果不做处理，模型根本分不清‘我打你’和‘你打我’的区别。因此必须强行注入位置信息。

- 早期的 Transformer 采用的是正弦绝对位置编码，死记硬背每个词的绝对坐标。
- 而在现在的 LLaMA、DeepSeek 等现代主流大模型中，普遍采用了 **RoPE（旋转位置编码）**。RoPE 通过在复数空间旋转向量，优雅地保留了词与词之间的**相对距离**，而且具备非常强的**长文本外推能力**，这也是大模型能支持超长上下文的关键基础。

【A1-03】【L2】微调 vs RAG vs Prompt 怎么选

题目：业务上要提升模型效果，Prompt 工程、RAG、微调三者你怎么选？

思考方向：先按“知识是外部事实还是模型行为/风格”分类，再看成本与时效。

考察点：技术选型决策、成本意识。

参考答案

- 知识类需求（私域事实、实时数据、可溯源）→ RAG：不改模型、可热更新、可溯源、成本低。

- 行为/风格/格式类需求（固定话术、JSON 结构化输出、领域语气）→ Prompt（Few-shot/CoT）优先，成本最低。
- 微调（SFT/LoRA）：当需要固化复杂领域能力、压缩推理成本（用小模型替代大模型）、或 RAG+Prompt 都达不到效果时使用；缺点是数据/算力成本高、知识更新要重训。
- 实践常“组合拳”：微调让模型“会说”，RAG 让模型“知道”。

评分要点

- **优秀**：给出决策树并按知识/行为分类，指出可组合、以及微调小模型降本的价值。
- **及格**：讲清三者定位与 RAG 优先的原因。
- **不足**：上来就说“微调效果最好”，无成本/时效考量。

常见追问：1) 公司有大量客服话术，你会微调还是做 RAG？2) LoRA 和全参微调的区别与取舍？

【A1-04】【L3】幻觉成因与抑制

题目：大模型为什么会幻觉？在你做的问答 Agent 里，你是怎么抑制幻觉的？

思考方向：从“概率生成 + 知识缺失 + prompt 诱导”三层归因，再对应到你的工程手段。

考察点：幻觉机理、RAG 兜底与拒答策略。

参考答案

- 成因：① 本质是“预测下一个 token 的概率模型”，无事实校验；② 训练知识截止/缺失私域知识；③ prompt 未约束、上下文噪声干扰；④ 采样温度过高。
- 抑制：检索侧提升召回质量（混合召回+RRF+Rerank）、给出相关度阈值；生成侧强约束 prompt（“仅依据给定资料作答，不得编造，无依据则回答不知道”）、降低 temperature、要求引用来源；兜底低置信/无命中时拒答或转人工接管。
- 度量：用 RAGAS 的 Faithfulness（答案是否被上下文支撑）持续监控幻觉率。

评分要点

- **优秀**：三层归因 + 检索/生成/兜底三处手段 + 用 Faithfulness 量化，并说明拒答阈值怎么定。
- **及格**：能说出“无依据就拒答、prompt 约束、提升检索质量”。
- **不足**：只说“调 prompt 让它别乱说”。

常见追问：1) 拒答会不会误杀正常问题，怎么平衡召回率与拒答率？2) Faithfulness 怎么算的？

★我的回答

因为大模型的本质是“预测下一个 token 的概率模型”，没有事实校验，所以当出现训练知识截止/缺失私域知识；prompt 未约束、上下文噪声干扰；采样温度过高时都可能出现幻觉。

然后我是通过检索侧提升召回质量（混合召回+RRF+Rerank）、给出相关度阈值；生成侧强约束 prompt（“仅依据给定资料作答，不得编造，无依据则回答不知道”）、降低 temperature、要求引用来源；这些方式来降低幻觉率的。

最后是采用 RAGAS 的 Faithfulness（答案是否被上下文支撑）持续监控幻觉率。

可以，整体思路很完整：为什么会幻觉、怎么抑制、怎么评估，都说到了。建议改三个小地方：

1. 把拒答说明确。

“给出相关度阈值”后面补一句：“检索结果相关性太低，或者资料不足以回答问题时，就补查或直接说不知道。”这样兜底策略就清楚了。

2. 降低 temperature 后补一句限制。

“让回答更稳定，但不能保证答案一定正确。”避免让面试官觉得你把调参数当成解决幻觉的核心方法。

3. 最后一句换个说法。

Faithfulness 衡量的是答案有没有被资料支持，不能直接等同于系统的幻觉率。[Ragas 官方定义](#)

可以改成：“最后用 RAGAS 的 Faithfulness 检查答案有没有资料依据，再结合人工抽查，看有没有乱编，以及有没有把能回答的问题也拒绝了。”

另外，你这版还是稍微偏书面。口头回答时，把：

- “缺失私域知识”换成“没学过公司的内部资料”。
- “检索侧提升召回质量”换成“先把资料找准”。
- “生成侧强约束 prompt”换成“在提示词里把回答规则说清楚”。

技术词保留，连接这些技术词的话说自然一点，就更像在讲自己的项目了。

大模型本质上是一个极其庞大、超级进化的“智能联想输入法”或“成语接龙引擎”。它从来没有“先在大脑里构思一个完整答案再写出来”，而是一边看着前面的字，一边猜下一个字最可能是什么。

【A1-05】【L3】推理性能优化：KV Cache 与量化

题目：什么是 KV Cache？模型量化（INT8/INT4、GPTQ/AWQ）能带来什么收益与代价？

思考方向：从“自回归推理重复计算”解释 KV Cache，从“显存换精度”解释量化。

考察点：推理优化、成本与部署认知。

参考答案

- KV Cache：自回归生成时，已生成 token 的 K/V 结果不变，缓存后可避免每步重算整个序列，把生成阶段从 $O(n^2)$ 降到 $O(n)$ ，代价是显存占用随序列长度线性增长；配套 PagedAttention (vLLM) 按页管理显存、Continuous Batching 提升吞吐。
- 量化：把权重/激活从 FP16 压到 INT8/INT4，显著降显存、提吞吐、可单卡部署更大模型；代价是精度损失，需评估效果回退。GPTQ 是训练后逐层量化，AWQ 保护重要通道精度更好。

评分要点

- **优秀：**讲清 KV Cache 为什么省算力、为什么费显存，能提到 PagedAttention/Continuous Batching、量化精度与显存的权衡。
- **及格：**能说 KV Cache 的作用与量化“省显存牺牲精度”。
- **不足：**没听过或答非所问。

常见追问：1) 首 token 延迟和吞吐如何权衡？2) 长上下文时 KV Cache 显存爆炸怎么办？

【A1-06】【L1】对话式 Agent 与 Function Calling 基础

题目：你怎么理解 Agent？Function Calling（工具调用）的工作原理是什么？

思考方向：Agent = LLM + 规划 + 工具 + 记忆；工具调用是“模型输出结构化调用意图 → 系统执行 → 结果回灌”。

考察点：Agent 基本概念、工具调用机制。

参考答案

- Agent：以大模型为决策核心，具备意图理解/规划、工具调用、记忆、多轮交互能力，能自主完成多步任务的系统。
- Function Calling：把工具的 name/description/参数 schema 以结构化形式告诉模型；模型判断需要调用时输出结构化的工具名+参数（而非自然语言）；系统执行后把结果作为新一轮上下文回灌模型，直到模型给出最终答案。

- 关键点：参数校验与异常兜底、工具描述质量决定模型能否选对工具、限制最大调用轮数防死循环。

评分要点

- **优秀**：讲清 schema 声明→模型决策→执行→回灌的完整闭环，并提到参数校验/防死循环。
- **及格**：讲清 Agent 由模型+工具+记忆构成、工具调用的基本流程。
- **不足**：把 Agent 等同于"套壳聊天"。

常见追问：1) 工具很多 (几十个) 时怎么让模型选准？2) 工具执行失败怎么让模型重试？

【A1-07】 【L2】 ReAct 推理框架原理

题目：ReAct 框架的核心思想是什么？它解决什么问题？

思考方向：Reason + Act 交替，让模型"边想边做"，用外部观察修正推理。

考察点：Agent 推理范式、工具编排。

参考答案

- ReAct = Reasoning + Acting：让模型循环执行 Thought（思考）→ Action（选择工具）→ Observation（观察结果），直到得出 Final Answer。
- 解决的问题：纯推理（CoT）容易幻觉、无法获取外部信息；纯执行无法规划。ReAct 通过"思考过程显式化 + 工具反馈闭环"提升复杂任务的准确性与可解释性。
- 工程要点：Thought 可观测便于调试、限制最大步数、工具返回结果要做截断与结构化。

评分要点

- **优秀**：画出 Thought/Action/Observation 循环，说明与 CoT 的区别、以及调试与步数控制。
- **及格**：讲清"边想边做、用工具结果修正"。
- **不足**：只答"就是调用工具"。

常见追问：1) ReAct 容易陷入循环，你怎么防？2) ReAct 和 Function Calling 的关系？

★我的回答

ReAct 是 Reasoning 和 Acting 的结合，也就是把推理和行动结合起来。

模型先分析下一步需要做什么，比如需要查资料，就调用搜索工具；拿到工具返回的结果后，再判断信息够不够、接下来该做什么。这样不断循环，直到能给出答案。

它主要解决两个问题：一是模型只靠自己想，缺少外部信息时容易编答案；二是复杂任务执行过程中，可能需要根据实际结果调整计划。ReAct 通过工具获取信息，再用反馈修正后续步骤，让回答更有依据、执行更灵活。

你只要记住这个流程：

想下一步（Thought）→ 调工具（Action）→ 看结果（Observation）→ 再想下一步。

★如果面试官继续追问，可以补一句："实际落地时要限制最大循环次数，避免一直调用工具。另外，ReAct 能缓解幻觉，但不能保证答案一定正确。"

【A1-08】 【L2】 Plan-and-Execute 与 ReAct 对比

题目：Plan-and-Execute 与 ReAct 有什么区别？你项目里什么时候用哪个？

思考方向：先全局规划再逐步执行 vs 每步即时决策。

考察点：Agent 范式选型。

参考答案

- ReAct: 每步即时"想一步做一步", 灵活、适合步骤少、环境反馈即时的任务; 缺点是缺少全局规划, 长任务易跑偏、token 消耗多。
- Plan-and-Execute: 先由 Planner 产出多步计划(任务列表), 再由 Executor 逐步执行, 可按需重规划(Re-plan); 适合步骤多、可分解的流程型任务; 缺点是计划一旦偏差需重规划、交互延迟更高。
- 选型: 知识问答/探索式取数用 ReAct; 多步业务流程自动化(如先查订单→再查库存→再生成报告)用 Plan-and-Execute。实践中常"规划+执行+反思"混合。

评分要点

- **优秀**: 讲清两者优缺点与重规划(Re-plan)机制, 并给出结合业务的选型判据。
- **及格**: 讲清"先规划后执行 vs 边想边做"的区别。
- **不足**: 把两者混为一谈。

常见追问: 1) 计划执行到一半发现前置条件不满足怎么办? 2) 怎么评估规划质量?

【A1-09】【L3】多 Agent 编排模式 (AgentScope)

题目: 多 Agent 有哪些常见协作模式? 你在 AgentScope 里怎么做多 Agent 编排? 什么时候不该用多 Agent?

思考方向: Supervisor (主管调度) / Swarm (平级移交) / 流水线 (Pipeline) 三种范式。

考察点: 多 Agent 架构、复杂度治理。

参考答案

- 常见模式: ① Supervisor/主管——中心 Agent 拆解任务并分发给子 Agent, 汇总结果(可控、易调试); ② Swarm/平级移交——Agent 之间按需转交控制权; ③ 流水线——按固定顺序串联(如检索 Agent→分析 Agent→写作 Agent)。
- AgentScope 实践: 用统一的 message 传递机制 + MsgHub 广播共享上下文, 各 Agent 挂不同模型/职责/工具, 主控 Agent 做路由与结果聚合。
- 不该用的场景: 任务简单、单 Agent + 工具即可时, 多 Agent 只会增加延迟、成本与不可控性; "为用而用"是常见反模式。

评分要点

- **优秀**: 讲清三种模式差异与适用场景, 说明共享上下文/消息传递机制, 并给出"不该用"的判断。
- **及格**: 能说出主管/流水线模式与多 Agent 解决的问题。
- **不足**: 只知道"多个 Agent 一起干活", 无协作机制。

常见追问: 1) 多 Agent 之间上下文怎么共享与隔离? 2) 出错时如何定位是哪个 Agent 的问题?

★我的回答

常见模式包括主管调度、平级移交和流水线。主管模式适合动态分工并统一汇总, 平级移交适合专家之间灵活接手, 流水线适合步骤稳定的任务。在 AgentScope 中, 可以用消息传递连接各 Agent, 用 Pipeline 控制顺序、用 MsgHub 广播信息, 并通过路由或工具调用实现任务分派。同时要设计上下文边界、停止条件和日志追踪。如果单 Agent 配合工具已经能稳定完成任务, 我会优先使用更简单的方案。

★追问回答

上下文怎么共享与隔离? 各 Agent 保留自己的任务历史, 按需传递任务描述、必要资料和结构化结果; 需要讨论时, 再向指定参与者广播。

出错怎么定位？ 给一次任务设置统一标识，记录各 Agent 的输入、输出、工具调用、耗时和交接关系。沿调用链找到最早出现错误的步骤，而不是只看最后答案。

【A1-10】【L2】Agent 持久化记忆机制

题目：Agent 的记忆怎么设计？短期记忆与长期记忆分别怎么存？

思考方向：短期=会话上下文，长期=向量记忆/结构化画像。

考察点：记忆分层设计、与 RAG 的结合。

参考答案

- 短期记忆：当前会话多轮上下文，存 Redis（带 TTL、按 sessionId），超长时做摘要压缩或滑动窗口。
- 长期记忆：把重要事实/用户偏好写入向量库（语义可召回）或关系库（结构化画像），下次会话按 query 召回注入，实现"跨会话记住用户"。
- 要点：写入时机（哪些该记）、去重与更新（同一事实变更要覆盖）、隐私与权限（用户数据隔离）、记忆检索相关性阈值。

评分要点

- **优秀：**讲清短期/长期的分层与存储选型，提到写入策略、去重更新、隐私隔离。
- **及格：**讲清短期用会话上下文、长期用向量库。
- **不足：**只会说"把历史都塞进 prompt"。

常见追问：1) 记忆越来越多检索不准怎么办？2) 多用户共享一个 Agent 时怎么隔离记忆？

★我的回答

可以。**短期记忆指服务当前会话的上下文，存到 PostgreSQL 里依然属于短期记忆。**

LangGraph 官方也提供了 PostgreSQL 保存会话状态的方案。[官方文档](#)

面试时可以这样回答：

我会把 Agent 的记忆分成短期记忆和长期记忆，两者都可以基于 PostgreSQL 实现。

短期记忆用于保持当前会话连续性。我会按用户 ID 和会话 ID 保存消息历史、对话摘要和任务状态，消息按序号排列，并建立相应索引。每次调用模型时，在 token 预算内读取“历史摘要 + 最近几轮消息”。对话过长时更新摘要，并记录摘要覆盖的位置，避免遗漏或重复。

会话的保留周期单独管理：设置 `expires_at`，读取时过滤过期会话，再通过定时任务清理。PostgreSQL 普通表的过期删除需要我们实现。

长期记忆用于跨会话保存用户偏好、稳定事实和重要经历。结构化画像放在 PostgreSQL 表中，按用户 ID 查询；需要语义检索的历史内容，可以通过 pgvector 保存文本对应的向量。

每次请求先确定用户权限，读取短期上下文和用户画像，再检索与当前问题相关的长期记忆，筛选后提供给模型，这就是与 RAG 的结合。写入长期记忆时，只保留有复用价值的信息，并处理去重、事实更新和过期失效。所有读写都带用户或租户范围，保证不同用户的记忆隔离。

选择 PostgreSQL，主要是考虑会话持久化、事务一致性，以及与已有业务数据库统一管理。后续如果会话读写成为性能瓶颈，再根据压测结果增加缓存。

【A1-11】【L3】低置信兜底与人工接管设计

题目：你项目里"低置信/敏感问题转人工接管"是怎么实现的？置信度如何量化？

思考方向：从"何时该转人工"的信号定义，到状态机与工单流转。

考察点：Agent 兜底策略、人机协同。

参考答案

- 触发信号（多信号融合）：① 检索最高相关度低于阈值（召回不足）；② Rerank 分数低；③ 模型自评置信度低或明确表达不确定；④ 命中敏感词/合规词表；⑤ 用户显式要求转人工或连续多轮未解决。
- 实现：会话状态机（bot → pending_human → human → bot），转人工时冻结上下文并生成工单/事件通知坐席（WebSocket/消息队列），人工回复可回写并沉淀为知识，形成闭环。
- 要点：阈值需用线上 Badcase 校准（平衡误转与漏转），并统计转人工率、人工解决率作为迭代指标。

评分要点

- **优秀：**多信号触发 + 状态机 + 闭环沉淀，并强调阈值校准与指标监控。
- **及格：**能说出“检索分低/敏感词触发转人工 + 状态流转”。
- **不足：**只说“加个转人工按钮”。

常见追问：1) 转人工率过高会怎样，怎么优化？2) 人工接管期间用户又发消息怎么办？

【A1-12】【L2】Agent 效果评估指标

题目：Agent（区别于纯 RAG）的效果怎么评估？任务成功率和工具调用准确率怎么定义？

思考方向：拆成“最终结果、过程正确性、效率与体验”三层。

考察点：Agent 评估体系。

参考答案

- 结果层：任务成功率（端到端达成用户目标的比例）、答案正确率（与标准答案比对或人工标注）。
- 过程层：工具调用准确率（选对工具的比例）、参数正确率、平均步数/调用轮数（越低越好）、无效循环率。
- 体验/成本层：首 token 延迟、端到端时延、转人工率、单次对话成本（token 消耗）。
- 方法：构建评测集（含 golden 工具调用序列）+ 离线回放 + 线上 A/B 与用户反馈（点赞/点踩）。

评分要点

- **优秀：**区分结果/过程/成本三层，提到 golden 轨迹比对与 A/B。
- **及格：**能说清任务成功率与工具调用准确率两个核心指标。
- **不足：**只会说“看效果好不好”。

常见追问：1) 没有标注数据怎么快速评估？2) 用大模型当裁判（LLM-as-Judge）可靠吗？

★我的答案

我会从结果、过程、效率与体验三个层面评估 Agent。

结果层重点看任务成功率，也就是满足预先定义的业务验收条件的任务数，占全部评估任务的比例。对于有实际操作的任务，我会检查数据库或业务系统的最终状态，不能只凭 Agent 的最终回答判断成功。

过程层看工具选择准确率和参数正确率，同时检查漏调用、多余调用、关键步骤顺序以及无效循环。这能帮助我们区分失败究竟来自工具选择、参数生成，还是执行过程。

效率与体验层看端到端延迟、调用次数、token 和工具成本，以及转人工率。在成功率和业务约束达标的前提下优化这些指标。

具体实施时，我会建立包含正常、异常和边界场景的评测集，标注成功条件、必要工具和关键步骤。先做离线评估和回归测试，再通过线上 A/B 和用户反馈验证效果。

【A1-13】【L1】RAG 全链路

题目：完整讲一下 RAG 的流程，每一步的作用是什么？

思考方向：离线入库链路 + 在线检索生成链路两条线。

考察点：RAG 全局认知（必答题）。

参考答案

- 离线：文档预处理（解析/清洗）→ 分块（chunk）→ 元数据标注 → Embedding 向量化 → 写入向量库（Milvus）。
- 在线：用户 query → （改写/扩写）→ 混合召回（向量 + BM25）→ 融合（RRF）→ Rerank 精排 → TopK 上下文拼装 prompt → 大模型生成 → 输出/引用/拒答。
- 质量闭环：RAGAS 评测（召回率、忠实度）+ Badcase 归因，反哺分块与召回参数迭代。

评分要点

- **优秀：**两条链路完整无遗漏，能指出每一步的常见坑（分块过碎、召回不准、上下文噪声）。
- **及格：**能串起“分块→向量化→检索→重排→生成”。
- **不足：**漏掉分块或重排，只说“向量库检索后喂给模型”。

常见追问：1) 哪一步对最终效果影响最大？2) 文档更新后怎么增量同步？

★我的答案

首先是离线入库链路，核心是保证数据质量，遵循 Garbage in, Garbage out：

1. 第一步是**文档解析与清洗**，尤其是 PDF、表格和多模态排版，我们会将其提取清洗为干净的 Markdown 结构；
2. 第二步是**分块（Chunking）**，为了避免暴力定长切分打断语义，通常采用递归字符切分配合 10%~15% 的 Overlap，或者采用父子块（Small-to-Big）设计；
3. 第三步是**打元数据（Metadata）**，比如章节层级、时间、权限标签，便于在线前置过滤；
4. 第四步是**向量化（Embedding）并存库**，我们会将稠密向量写入 Milvus 构建 HNSW 索引，同时把原始文本同步到 ES 建立 BM25 倒排索引，构建混合检索底座。

接着是在线检索与生成链路，核心是降低检索噪声与幻觉：

1. 用户 Query 输入后，先经过**意图理解与改写**，做多轮代词消解或 Query 扩写；
2. 随后发起**混合召回（Hybrid Search）**，同时用向量搜语义泛化、用 BM25 搜型号/专有名词，并通过 **RRF（倒数排名融合）** 算法合并出初步的 Top 50 候选集；
3. 接下来是关键**的 Rerank 精排**，利用 Cross-Encoder 重排模型进行深度二次打分，截取 Top 3~5。这一步能为整体准确率带来 15%~30% 的提升；
4. 之后进入 **Prompt 组装**，考虑大模型的‘Lost in the Middle’特性，把最相关的 Chunk 贴在首尾，并加上‘未知则拒答’的约束；
5. 最后交由大模型生成带来源引用的回答。

最后是质量闭环：我们线上会基于类似 RAGAS 的框架，对‘检索召回率’与‘生成忠实度’建立自动化评估体系，针对 Badcase 定位是切分、召回还是 Prompt 的问题，持续反哺参数迭代。”

追问 1：哪一步对最终效果影响最大？

- **回答逻辑：**不要单选某一步，要分**数据端**和**算法检索端**两层回答：
 - **数据层面（上限）：**分块与预处理（Chunking & Preprocessing）。

- *理由*：数据的干净程度与语义切分粒度决定了系统的上限。如果表格被切烂了、核心主语被截断了，后续无论是 Embedding 还是 LLM 都不可能‘无中生有’。

- **算法检索层面（转化率）：Rerank 精排。**

- *理由*：双塔稠密向量召回在多候选集下不可避免存在大量弱相关噪声。生产环境中引入 Cross-Encoder Rerank 是直接提升 Top-K 命中率、降低模型幻觉最立竿见影的手段。

追问 2：文档更新后怎么做增量同步？

- **回答逻辑**：分为 **识别变更、精准失效/重建、无感切换** 三步：

1. 变更捕获与比对：

- 文档接入 CDC（如 Canal 监听数据库变更）或定时扫库；
- 对原始文档计算全局 Hash，文档若变动，进一步对各 Chunk 计算 MD5/SHA256，实现**Chunk 级别的增量更新**，避免全量重新 Embedding 浪费算力。

2. 删改查操作：

- 基于入库时记录的 `doc_id` 或 `chunk_id`，利用向量库和 ES 的元数据软删除/批量删除（Delete by Metadata Filter）；
- 重新对变动/新增的 Chunk 进行 Embedding 写入。

3. 缓存与平滑切换：

- 同步失效上层缓存（如语义缓存 Semantic Cache、Query 结果缓存）；
- 若文档有大版本批量发布（如全套知识库升级），通常采用**蓝绿双索引（Blue-Green Index Switch）**，在新索引构建完成后一键切换路由，保证业务零中断。

【A1-14】【L2】分块策略：语义分块与父子文档

题目：你项目用了“语义分块 + 父子文档”，它们分别解决什么问题？分块粒度怎么定？

思考方向：分块粒度是“检索精度 vs 上下文完整性”的权衡。

考察点：RAG 分块策略。

参考答案

- 固定长度分块简单但会在句子/语义中间切断；语义分块按语义边界（段落、标题、句子相似度突变处）切，保证块内语义完整。
- 父子文档：用小的子块做向量检索（更精准），命中后返回其所属的父块/整段作为上下文（更完整），兼顾“检索准”与“信息全”。
- 粒度：chunk 太小语义不全、太大引入噪声且稀释向量；常见 300~800 token、overlap 10%~20%；最终靠 A/B 实验用指标（Recall@K、Faithfulness）定参数。

评分要点

- **优秀：**讲清父子文档“小子块检索、父块喂模型”的机制，并给出参数实验思路。
- **及格：**讲清语义分块的价值与 chunk size/overlap 的权衡。
- **不足：**只知道“按固定字数切”。

常见追问：1) overlap 太大会什么问题？2) 表格/扫描件 PDF 怎么处理？

★我的回答

我们采用“语义分块 + 父子文档”，主要是平衡检索的准确性和生成时的上下文完整性。

语义分块解决切分边界的问题。固定长度切分容易把一个知识点的条件、结论或解释拆开。我们尽量沿标题、段落和完整句子切分；如果采用基于 embedding 的语义切分，就根据相邻句子组的相似度，在主题变化明显的位置切开，同时限制块的大小。[语义切分机制](#)

父子文档解决检索粒度和上下文粒度不同的问题。子块内容更聚焦，用来做向量检索；命中后通过 `parent_id` 找到所属父块，去重后提供给模型。比如用户问“报销额度”，子块可以定位额度条款，父块再补充适用条件和例外情况。父块可以是一个完整小节，不一定是整篇文档。[父子文档机制](#)

粒度需要通过业务数据验证。子块太小，容易丢失实体、条件和指代；太大，可能混入多个主题，影响检索。图里的 300 ~ 800 token、10% ~ 20% overlap 可以作为实验起点，父块则尽量保留完整小节，并受上下文预算约束。这些参数没有通用最优值，需要结合文档类型和问题类型调整。[分块与重叠的考虑因素](#)

面试官如果追问“**具体怎么验证？**”，可以接着说：

我会准备一批真实业务问题，标注标准答案和对应证据，对比“固定长度分块”“语义分块”“语义分块 + 父子文档”。固定模型和上下文预算，检索阶段看 Recall@K、证据覆盖情况，生成阶段看答案正确率和 Faithfulness，同时记录延迟和 token 成本。Faithfulness 衡量的是答案中的陈述是否有检索上下文支持。[指标定义](#)

图里的两个追问，可以这样接：

- **overlap 太大会怎样？**重复内容会增加索引和 embedding 成本，相似块还可能挤占 Top-K，减少不同证据的覆盖。可以减少重叠、按完整句子重叠，并对子块和回溯得到的父块去重。
- **表格、扫描 PDF 怎么处理？**先做文档解析，扫描件需要 OCR 和版面分析。表格保留表头、行列关系、单位和标题；大表按行组切分，每块带上表头，并保留页码和来源，方便引用与核查。[文档版面解析](#)

回答时按你的实际实现调整：只按标题、段落切分，就说“基于文档结构切分”；没有做过调参实验，就说“会这样验证”，不要把示例参数和验证思路说成已经取得的项目成果。

【A1-15】【L2】Query Rewrite 与 HyDE

题目：为什么要做查询改写？Query Rewrite 和 HyDE 分别怎么工作？

思考方向：用户口语化 query 与文档表述不匹配，需“翻译”到检索友好空间。

考察点：召回优化手段。

参考答案

- Query Rewrite：用 LLM 把口语化/省略/多轮依赖的 query 改写成完整、含关键词的标准查询（如“这个多少钱”→“XX 商品 价格”）；也含多轮指代消解、同义词扩展、子问题拆解。
- HyDE（Hypothetical Document Embeddings）：先让 LLM 生成一段“假设的答案文档”，再对这段假设文档做向量化检索。因为假设答案与真实文档在语义空间更接近，可显著提升召回；代价是多一次 LLM 调用、有引入偏差的风险。
- 取舍：延迟敏感可只做轻量 Rewrite；对召回质量要求高再加 HyDE，并用实验验证增益。

评分要点

- **优秀：**讲清 HyDE 的“假设答案做检索”机制、收益与额外延迟/偏差风险。
- **及格：**能说清改写的目的与 HyDE 大体思路。
- **不足：**不知道 HyDE 是什么。

常见追问：1) 改写失败（改错）怎么兜底？2) 改写会不会破坏原始关键词导致 BM25 召回变差？

★★我的答案

在 RAG 中，系统需要先根据用户问题检索相关资料，再基于资料生成回答。但用户提问不一定包含完整的检索信息，例如“它怎么配置？”“需要结合前文才能确定“它”指什么；用户使用的词语也可能与文档中的术语不同。因此，查询改写的目的是**保留用户意图，补全检索所需的信息，帮助检索器找到相关文档**。如果问题已经清楚、检索效果也好，就不一定需要改写。

Query Rewrite 是把原始问题转换成更适合检索的查询。常见做法包括结合对话补全指代、消除歧义、规范术语，必要时扩展同义词或拆分复杂问题，再进行关键词检索或向量检索。例如，前面在讨论 Redis AOF，用户问“它怎么配置？”，就可以改写为“Redis AOF 持久化如何配置”。关键是不能改变用户意图，要保留实体、数字、否定和限制条件。

HyDE 则是先生成一段假设的答案文档，再用这段文档的向量检索真实文档。流程是：用户问题 → LLM 生成假设文档 → Embedding → 向量检索。与直接改写问题相比，它尝试通过假设文档提供更丰富的相关语义，帮助匹配知识库中的真实资料。这段假设文档不要求事实完全正确，也不能作为回答依据；最终回答仍然要基于检索到的真实文档。假设内容也可能把检索方向带偏，所以 HyDE 不保证一定提升效果。

工程上，我会先建立原始查询的检索基线，再评估 Rewrite 和 HyDE。对延迟敏感的场景，可以先采用简短改写；如果问题与文档的表达差距较大，再尝试 HyDE。两者都有意图偏移风险，HyDE 还增加生成成本和延迟，因此不能默认它一定更好。

用同一个例子，区别就很容易讲：

- 用户问题：“**线程池满了，任务咋办？**”
- Query Rewrite：“**Java 线程池饱和后的任务处理与拒绝策略**”，拿这个查询去检索。
- HyDE：生成一段**介绍线程池饱和及拒绝策略的假设说明**，将整段说明向量化，再找相似的真实文档。

面试官继续追问时，可以这样接：

1. 改写错了怎么兜底？

保留原始 query，让原始查询和改写查询分别检索，再去重、融合、重排。校验关键实体和约束是否被改变，校验失败就回退原始查询；关键歧义无法消除时再澄清。

2. 改写会不会让 BM25 召回变差？

会。型号、错误码、专有名词被替换或删除，可能损失精确匹配。因此要保护这些关键词，并保留原始查询的 BM25 检索通道。

3. 怎么证明有收益？

在同一测试集上对比原始检索、Rewrite、HyDE，观察 **Recall@K、排序质量、最终回答正确性，以及延迟和成本**，据此决定是否启用。

记住一句话：**Rewrite 改写“怎么问”，HyDE 构造“相关文档可能怎么写”。**

【A1-16】【L1】向量检索 vs BM25 关键词检索

题目：向量检索和 BM25 各有什么优缺点？为什么不能只用一种？

思考方向：语义泛化能力 vs 关键词精确匹配能力，互补。

考察点：检索基础、混合召回动机。

参考答案

- 向量检索：基于语义相似，能理解同义/近义表达，泛化好；但对专有名词、型号、代码、数字不敏感，且依赖 embedding 质量。
- BM25：基于词频-逆文档频率的精确关键词匹配，对型号/术语/代码符号准；但不懂同义与语义，词不匹配就召回不到。
- 两者互补 → 混合召回，既保证语义理解又保证关键实体精确命中。

评分要点

- **优秀：**能举“商品型号/健康术语”的例子说明纯向量的漏召回问题。
- **及格：**讲清语义 vs 关键词的差异与互补。
- **不足：**认为“向量检索全面优于关键词检索”。

常见追问：1) BM25 的 k1、b 参数的作用？2) 中文分词对 BM25 的影响？

这题要讲清楚：**向量检索擅长匹配语义，BM25 擅长匹配词项，两者解决不同的召回问题。**

面试时可以这样回答：

向量检索先把查询和文档转换成 embedding，再按向量相似度检索。它的优势是能匹配同义词和不同表达，比如用户问“戴久了耳朵不疼的耳机”，也有机会找到描述“佩戴舒适”的商品。但效果依赖 embedding 模型，对型号、编号、数字等细微差异的区分可能不够可靠。

BM25 根据分词后的词项匹配打分，主要考虑词频、逆文档频率和文档长度。它通常比较高效、容易解释，在关键词明确的查询中很有优势，比如商品型号、错误码和专业术语。但如果用户和文档表达的是同一个意思，却没有共同词项，又没有同义词扩展，就容易漏召回。两种检索的区别可参考 [Elastic 检索说明](#)。

所以在同时包含自然语言问题和精确实体查询的场景中，我会采用混合召回：BM25 和向量检索分别召回候选，合并去重后做排名融合，必要时再重排。比如查询“RTX 4090”时，需要区分相近型号；查询“适合做深度学习的显卡”时，则需要语义匹配。可以使用 RRF 来融合两路排名。[混合检索文档](#)

但并不是绝对不能只用一种。如果业务查询类型比较单一，一种检索已经满足效果和延迟要求，就可以只用一种。是否混合，要通过实际查询集评估收益和成本。

图片里的追问可以这样接：

- **k1 是什么？** 控制词频饱和程度。一个词出现更多次会加分，但收益逐渐减小；k1 越大，词频增加的影响越明显。
- **b 是什么？** 控制文档长度归一化强度。b=0 不考虑长度归一化，b=1 完整使用长度归一化。Elasticsearch 的默认值是 k1=1.2、b=0.75。参数文档
- **中文分词有什么影响？** BM25 匹配的是分词后的词项。专业术语或型号拆错，会影响召回和排名，因此需要合适的分词器、领域词典，以及查询端和索引端兼容的分词策略。
- **两路分数怎么融合？** BM25 分数和向量相似度量纲不同，通常不直接相加。可以归一化后加权，也可以用 RRF 根据排名融合。

注意两个表述：别说“向量检索全面优于 BM25”，也别把“BM25 词项匹配”说成“保证字符串完全一致”。如果型号必须完全一致，还应使用精确字段匹配或过滤。

【A1-17】【L2】混合召回与 RRF 融合

题目：你的混合召回结果怎么融合？RRF 的公式和参数含义是什么？为什么用 RRF 而不是加权求和？

思考方向：两类检索的分数量纲不同，按“排名”融合更鲁棒。

考察点：RRF 原理与调参。

参考答案

- RRF (Reciprocal Rank Fusion)：对每个文档按它在各路结果中的排名 r 打分 $\text{score} = \sum 1/(k + r)$ ， k 为平滑常数（常用 60），再按总分排序。
- 用 RRF 的原因：向量相似度与 BM25 分数量纲/分布完全不同，直接加权求和需要归一化且权重难调；RRF 只用排名，天然规避归一化问题，鲁棒、少调参。
- 调优： k 越大越“平权”（削弱头部优势）， k 越小越放大头名；两路权重可通过多次出现加权（如给向量路结果乘系数）或按业务做 A/B。融合后再交给 Rerank 精排。

评分要点

- **优秀：**写出 RRF 公式、解释 k 的作用，说清“规避量纲/归一化”这一本质原因。
- **及格：**说清按排名倒数融合、比加权求和更鲁棒。
- **不足：**只会说“两路结果合并去重”。

常见追问：1) 如果两路召回结果都很差，RRF 能救吗？2) 有没有比 RRF 更好的融合方式？

这题按“怎么融合 → 公式 → 为什么选 RRF → 怎么调参”回答，比较完整。

面试时可以直接这样说：

我会并行做 BM25 关键词召回和向量召回，各自取一批候选，然后按文档或 chunk ID 合并，使用 RRF 融合排序，最后把融合后的候选交给 Reranker 精排。

RRF 的核心是：**不直接比较两路的原始分数，而是根据文档在各路中的排名计算贡献，再把贡献相加。**同一文档被多路召回，就累加各路贡献；某一路没有召回它，这一路贡献为零。

选择 RRF，主要因为 BM25 分数和向量相似度的尺度、分布不同，直接加权相加容易被某一路主导。RRF 只依赖排名，省去了分数归一化和校准，适合作为简单、稳健的基线。不过它会丢失原始分数的差距信息，所以不能说一定优于调好参数的分数融合。[融合原理参考](#)

公式和参数一定要能解释：

$$\text{RRF}(d) = \sum_{i: d \in L_i} \frac{1}{k + r_i(d)}$$

- L_i ：第 i 路召回结果。
- $r_i(d)$ ：文档在该路的排名，通常从 1 开始。

- k : 平滑常数, 常以 60 为起点, 不是召回数量 Top K。
- k 越小, 越强调头部排名; k 越大, 不同名次之间的贡献差距越小。 [公式与参数参考](#)

举个例子, 取 $k = 60$:

文档	BM25 排名	向量排名	RRF 分数
A	1	未召回	$1/61 \approx 0.0164$
B	3	2	$1/63 + 1/62 \approx 0.0320$

因此 B 排在 A 前面: 两路都认为 B 比较相关, 累加后的贡献更高。

面试官追问时, 可以这样接:

1. “怎么调参?”

“我会一起评估各路召回数量、 k 和融合后保留的候选数。如果两路质量不同, 可以用加权 RRF: $\sum_i w_i / (k + r_i(d))$ 。先检查候选 Recall@N, 再比较排序的 NDCG、MRR, 结合延迟做线上 A/B。”

2. “两路召回都很差, RRF 能救吗?”

“如果相关文档根本没有进入候选集合, RRF 无法补回来; 如果已经召回, 只是排名靠后, 且两路信号互补, 融合可能改善排序。”

3. “有没有比 RRF 更好的方式?”

“可以比较归一化后的分数加权融合, 或者有标注数据时用学习排序。RRF 的优势是简单、无需训练, 但它不是通用最优, 最终要看业务评测结果。”[相关对比研究](#)

【A1-18】【L2】Rerank 重排序: cross-encoder vs bi-encoder

题目: Rerank 的作用是什么? cross-encoder 与 bi-encoder 的区别? 为什么要“先召回后精排”?

思考方向: 粗排求快 (召回全)、精排求准 (算得慢但准)。

考察点: 排序架构、效果与延迟权衡。

参考答案

- bi-encoder (Embedding 检索): query 与 doc 分别编码成向量再算相似度, doc 向量可离线预计算, 快但精度有限, 适合大规模粗召回。
- cross-encoder (Rerank): 把 (query, doc) 拼在一起送进模型做交互式打分, 精度高但无法预计算, 只能对少量候选算, 慢。
- “先召回后精排”: 召回阶段用 bi-encoder 从百万级快速取 TopK (如 50~100), 精排阶段用 cross-encoder 对这几十条精确打分取 TopN, 兼顾速度与准确率。
- 调优: Rerank 模型选型 (bge-reranker 等)、候选数与延迟的权衡、是否需要与 RRF 顺序配合。

评分要点

- **优秀:** 讲清两种编码器的计算方式与延迟差异, 说明召回/精排分层设计与 Rerank 模型选型。
- **及格:** 能说清 Rerank 提升相关性、cross-encoder 更准更慢。
- **不足:** 把 Rerank 与向量检索混为一谈。

常见追问: 1) Rerank 让延迟涨了 200ms, 值得吗, 怎么权衡? 2) 多路召回结果需要先融合再重排吗?

1.Rerank 的作用是什么?

Rerank 是对召回出来的候选文档重新打分、重新排序, 把更能回答用户问题的内容排到前面, 提高最终结果的相关性。在 RAG 中, 它可以帮助筛选交给大模型的上下文, 减少无关内容。

2.cross-encoder 与 bi-encoder 的区别是什么？

口语回答：“它们最本质的区别是：一个各算各的，一个拼在一起算；这就导致了一个图快，一个图准。

- bi-encoder（双塔，也就是平时的向量检索）

：是把问题和文档

分开独立转成向量

。

- **优点是快：**文档的向量平时就能提前算好存在数据库里，线上搜的时候拿问题做个毫秒级的距离匹配就行，哪怕几百万篇也能瞬间搜完。
- **缺点是不够准：**因为编码时问题和文档完全没有交流，很多细节、逻辑否定词容易被忽略。

- cross-encoder（单塔，也就是 Rerank 模型）

：是把问题和文档

拼成一整句话一起喂给模型

，让两边的每一个词逐字做交叉注意力比对。

- **优点是极准：**打分非常精确。
- **缺点是太慢了：**每次都必须线上当场现算，根本没法提前离线算。如果拿它去算几十万篇文档，服务器直接卡死，所以它一次只能算几十条。”

3.为什么要“先召回后精排”？

- 如果**只用精排（cross-encoder）**：面对百万级文档，算力根本顶不住，用户等几分钟都出不来结果；
- 如果**只用召回（bi-encoder）**：速度倒是快了，但搜出来的前几名经常掺杂垃圾信息，大模型回答质量太差。

所以必须分两步走：

1. **先召回（求快、求全）**：用速度快的 bi-encoder，花几毫秒从几百万文档里捞出 **50~100 条** 候选，保证正确答案一定在这批候选里，宁可多选，不能漏掉。

2. **后精排（求准）**：用精度高的 cross-encoder，花几十毫秒只对这几十条精挑细选，挑出最靠谱的 3~5 条喂给大模型。

这样一配合，整个系统既有了**毫秒级的响应速度**，又有了**极高的准确率**。”

在实际选型的时候**第一，模型选型怎么定？** 我们一般首选智源开源的 `bge-reranker`。如果服务器配置一般、对响应速度要求高，我们就用轻量版的 `bge-reranker-base`；如果对准确率要求极高，或者业务里混杂了中英文等多语言，我们会选 `large` 或者 `v2-m3` 版本。

第二，候选数和延迟怎么权衡？ 很多人以为送给 Rerank 的候选文档越多越好，其实送 100 条进去，延迟直接就飙到两三百毫秒了。经过实际测试，**30 到 50 条是个‘黄金甜点位’**——既能保证召回的正确答案不被漏掉，又能把 Rerank 耗时控制在合理范围。同时我们一般会对模型做个 **INT8 量化**，用 TensorRT 或 ONNX 加速一下，稳稳把重排耗时压在 **50 毫秒以内**。

第三，要不要和 RRF 顺序配合？ 这要看前面多路召回（向量 + 关键词）捞出来的总量：

- **如果召回量很大（比如加起来超 100 条）**：那必须先用 **RRF 配合截断**。RRF 算名次不用 GPU 也不耗时，先用它把 100 多条粗筛到前 50 条，再送去给 Rerank，防止把重排模型压垮。
- **如果前面本来就只召回了三四十条**：那就**完全不需要 RRF**，去重之后直接丢给 Rerank 模型精确打分，链路更短、效果更准。”

【A1-19】【L3】HNSW 向量索引原理与参数调优（跳过了）

题目： Milvus 常用的 HNSW 索引原理是什么？M、efConstruction、efSearch 三个参数怎么调？

思考方向： 多层“跳表式”图，上层稀疏跳得远、下层稠密找得准。

考察点： 向量索引底层、召回率与延迟调优。

参考答案

- HNSW（分层可导航小世界图）：构建多层邻近图，检索从上层的稀疏图快速跳跃逼近目标区域，再逐层下沉到底层精细搜索，用少量计算换高召回。
- M：每个节点的最大连接数，越大召回越高、内存与构建越重（常用 16~32）。
- efConstruction：建索引时的候选队列大小，越大索引质量越好、构建越慢（常用 100~500）。
- efSearch：查询时的候选队列大小，越大召回越高、延迟越大，且可在线调节，是效果/延迟的主要旋钮。
- 权衡：HNSW 内存占用大、写入更新代价高；大规模+高更新场景可考虑 IVF 系列或 DiskANN，调参靠召回率-延迟曲线。

评分要点

- **优秀**：讲清分层图思想与三参数各自的“召回/内存/延迟”影响，能说出 efSearch 可在线调。
- **及格**：知道 HNSW 是图索引、M/ef 越大越准越慢。
- **不足**：只知道“用了 HNSW，效果不错”。

常见追问： 1) 数据频繁更新会怎样，怎么处理？ 2) 内存吃紧有什么替代方案？

【A1-20】【L2】Milvus / FAISS / PGVector 选型

题目： 你项目里同时提到 Milvus、FAISS、PGVector，为什么？三者的定位和选型标准是什么？

思考方向： 从“数据规模、部署成本、运维能力、是否要事务/过滤”多维度比较。

考察点： 向量存储选型。

参考答案

- FAISS: Facebook 的库, 非服务, 性能极强、可嵌入进程做本地/离线检索加速; 缺点是分布式、持久化、权限、在线更新都要自己实现, 适合单机/离线/评测场景。
- Milvus: 分布式向量数据库, 支持亿级规模、多索引 (HNSW/IVF...)、标量过滤、多租户、持久化与水平扩展, 适合生产在线服务; 运维成本相对高。
- PGVector: 在 PostgreSQL 上的向量扩展, 最大优势是能和业务数据同库、复用 PG 的事务/SQL/权限, 适合向量量级不大、已有 PG 且想省一套中间件的场景; 规模大后性能不如专用库。
- 本项目: Milvus 作为在线主库, FAISS 做本地加速/评测, PGVector 兼容小数据量或已用 PG 的团队, 形成"按规模与运维能力分层"的选型。

评分要点

- **优秀:** 指出库 vs 服务 vs 扩展的本质差异, 并给出规模/事务/运维的决策依据。
- **及格:** 大致讲清三者定位与各自适用场景。
- **不足:** 把三者说成"都差不多, 随便用"。

常见追问: 1) PGVector 的 HNSW 与 Milvus 的差别? 2) 什么时候该从 PGVector 迁到 Milvus?

【A1-21】【L3】知识库权限隔离与多租户

题目: 企业内部问答 Agent, 不同角色能看到不同资料, 你怎么做知识库的权限隔离?

思考方向: 检索前过滤 (pre-filter) vs 检索后过滤 (post-filter), 以及元数据设计。

考察点: 多租户隔离、检索安全。

参考答案

- 核心手段: 给每个 chunk 打权限元数据 (tenant_id / dept / role / 密级), 检索时按当前用户身份做过滤。
- pre-filter (先过滤再向量检索, 推荐): Milvus/PGVector 支持标量过滤与向量检索同时进行, 从候选阶段就排除无权数据, 安全且效率可控; post-filter (先检索后过滤): 可能因过滤掉大量结果导致召回不足, 且存在越权数据先被模型看到的风险。
- 进阶: 按租户物理隔离 (独立 collection/分区) 隔离更彻底但有资源成本; 敏感字段脱敏; 对"是否存在该文档"本身也算泄露的情况, 需控制拒答话术不泄露信息。

评分要点

- **优秀:** 明确 pre-filter 优先并说明原因, 提到元数据设计、物理隔离成本与拒答话术泄露风险。
- **及格:** 能说出"用元数据做权限过滤 + 分租户隔离"。
- **不足:** 只想到"前端隐藏入口", 安全理解不足。

常见追问: 1) 过滤条件很复杂时检索性能怎么保证? 2) 用户权限变更后索引怎么同步?

我的回答

我会给每份资料记录允许访问的角色。文档切分成 chunk 时, 把原文档的权限信息同步写入每个 chunk 的元数据, 让这些片段具有相同的访问权限。

用户提问时, 后端根据登录身份获取他的角色, 在检索前加上权限过滤条件, 只从他有权限的资料中查找相关内容, 再交给大模型回答。

我优先采用检索前过滤, 因为检索后过滤可能把大部分结果删掉, 导致可用资料不足。权限发生变化时, 也要及时更新权限信息和相关缓存。

【A1-22】【L2】RAGAS 评测: Recall@K / MRR / Faithfulness

题目: RAGAS 里 Recall@K、MRR、Faithfulness 分别衡量什么? 怎么计算? 你的评测集怎么构建?

思考方向：指标分两层：检索质量（Recall@K、MRR）与生成质量（Faithfulness、Answer Relevancy）。

考察点：RAG 评测体系。

参考答案

- Recall@K: TopK 检索结果中是否包含标准答案所需的知识片段，衡量召回是否“漏”，是最该先优化的指标（检索不到，生成再好也没用）。
- MRR（平均倒数排名）：正确答案首次出现的排名的倒数的均值，衡量“正确答案排得够不够前”，1 为最好。
- Faithfulness（忠实度）：答案中的每个论断是否能被检索到的上下文支撑，衡量幻觉程度；由 LLM 抽论断 + 逐条核验计算。
- 评测集：从业务真实问题抽样 + 人工标注 ground truth（标准答案 + 应命中的文档/片段），覆盖高频、长尾、边界（无答案）三类问题；定期回归。

评分要点

- **优秀：**讲清“先治召回再治生成”的优先级，能说明各指标计算方式与评测集覆盖设计。
- **及格：**能说清三个指标各衡量什么。
- **不足：**只知道“用 RAGAS 打分”，说不清指标含义。

常见追问：1) 没有 ground truth 怎么评估（无参考评测）？2) 评测集会不会被“调参调过拟合”？

【A1-23】【L3】分块参数实验与 Badcase 全链路归因

题目：线上出现“用户能搜到的答案却答错了”，你怎么定位是分块、检索还是生成的问题？分块参数怎么做实验？

思考方向：用“分段验证”法把链路拆开，逐段比对定位瓶颈。

考察点：问题定位方法论、数据驱动的迭代闭环。

参考答案

- 链路归因（逐段验证）：① 人工确认该知识是否已入库、分块是否把答案切碎（分块问题）；② 检查该 chunk 在 TopK 结果里是否出现、排名第几（召回问题）；③ 若 chunk 在上下文里但答案仍错 → 生成问题（prompt 约束不足、上下文噪声、模型能力）。
- 分块实验：控制变量法，固定检索/生成参数，只改 chunk size（如 256/512/1024）与 overlap（0/10%/20%），用 Recall@K + MRR + Faithfulness 对比；同一份评测集跑多组配置，选 Pareto 最优（效果/延迟/成本）。
- 闭环：沉淀 Badcase 库 → 归因分类统计（分块 X%、召回 Y%、生成 Z%）→ 优先解决占比最高的瓶颈。

评分要点

- **优秀：**给出“分段验证 + 控制变量实验 + Badcase 分类归因”的完整方法论，能指导下一步动作。
- **及格：**能说出先看知识是否入库、再看检索是否命中、最后看生成。
- **不足：**上来就“换更大的模型试试”，无归因思路。

常见追问：1) 怎么区分是“知识缺失”还是“分块切碎”？2) 效果和延迟冲突时怎么取舍？

【A1-24】【L1】Spring AI / Spring AI Alibaba / LangChain4j 定位

题目：Spring AI、Spring AI Alibaba、LangChain4j 三者是什么？为什么 Java 团队做 AI 应用要选框架？

思考方向：用“Java 生态的 LangChain”来类比，再讲各自差异。

考察点： Java AI 框架生态认知。

参考答案

- 三者都是Java生态的大模型应用开发框架，把模型调用、Prompt模板、Embedding、向量库、工具调用、会话记忆统一抽象，避免手写HTTP调各家API。
- Spring AI：Spring官方出品，强调与Spring Boot无缝集成（ChatClient/EmbeddingClient、自动配置、Advisor机制），适合已有Spring体系的项目。
- Spring AI Alibaba：阿里在Spring AI基础上的增强，对通义千问等国产模型、阿里云向量库、多Agent（Graph编排）适配更好，国内落地友好。
- LangChain4j：社区版"Java LangChain"，组件最全（AiServices、@Tool、ChatMemory、EmbeddingStore、RAG模块），灵活度高、非Spring强绑定。

评分要点

- **优秀：**讲清三者关系（Spring AI官方 / Alibaba增强 / LangChain4j社区），并说明各自强项与选型倾向。
- **及格：**知道都是Java侧大模型框架、大体能做什么。
- **不足：**分不清三者，或以为要写Python才能做AI。

常见追问： 1) 为什么不用直接HTTP调API？ 2) 你项目用了AgentScope，和上面三者什么关系？

【A1-25】【L2】LangChain4j 核心组件：@Tool 与 ChatMemory

题目： LangChain4j里怎么定义一个工具？ChatMemory是怎么工作的？多用户会话如何隔离？

思考方向： 注解式工具声明 + 按memoryId隔离的会话记忆。

考察点： 框架实操、会话状态管理。

参考答案

- 工具定义：用@Tool("描述")标注方法，参数字段用@P("参数说明")，框架自动生成JSON Schema传给模型；描述写得越清晰，模型选工具的准确率越高。
- AiServices：用接口 + 注解声明式定义AI服务（模型、记忆、工具、RAG检索器按需组合），框架生成代理实现。
- ChatMemory：默认MessageWindowChatMemory保留最近N条消息，通过memoryId区分不同会话；多用户/多会话必须按memoryId隔离，生产上把memoryId映射到Redis存储并设TTL，避免内存泄漏与串话。
- 注意：ChatMemory是"消息级"记忆，与向量长期记忆不同；上下文超长要做摘要或窗口裁剪。

评分要点

- **优秀：**讲清注解生成schema的机制、memoryId隔离与Redis持久化、以及窗口/摘要的取舍。
- **及格：**能说出@Tool定义工具、ChatMemory用memoryId区分会话。
- **不足：**没实际用过，只会背概念。

常见追问： 1) 工具方法抛异常框架怎么处理？ 2) 多个工具的并发调用支持吗？

我的答案

LangChain4j定义工具主要用@Tool标注Java方法，用@P描述参数，再把工具注册到AiServices。框架根据方法名、参数类型和注解描述，生成工具定义及参数的JSON Schema，提供给模型。模型返回工具名称和参数后，框架执行对应方法，再把结果交给模型继续回答。

ChatMemory负责维护对话上下文，把之前的消息带到下一次模型请求中。多用户、多会话场景下，我会通过@MemoryId配合ChatMemoryProvider，让不同会话使用独立的记忆。比如用

“用户 ID + 会话 ID”作为标识，这样既能隔离不同用户，也能隔离同一个用户的多个聊天窗口。

需要持久化时，可以实现基于 Redis 的 `ChatMemoryStore`，按 `memoryId` 读写消息，并设置 TTL 管理过期数据。这样多个应用实例可以访问同一份会话消息，同时还需要管理框架本地会话实例的清理。

需要注意的是：ChatMemory 是“消息级”记忆，与向量长期记忆不同；上下文超长要做摘要或窗口裁剪。

【A1-26】【L3】自定义 EmbeddingStore 与并发会话隔离

题目：如果要接入框架不支持的向量库（比如你自研的存储），怎么扩展？高并发下会话/检索上下文怎么隔离？

思考方向：面向接口实现 + 无共享状态设计。

考察点：框架扩展能力、并发设计。

参考答案

- 扩展：实现框架的 EmbeddingStore 接口（add / search / remove 等方法），把自定义库的读写映射到接口语义；选型上优先用框架已适配的 Milvus/PGVector，自研仅在必要时。
- 并发隔离：① 每个请求的上下文（检索结果、工具中间态）用请求级局部变量/ThreadLocal 或显式参数传递，禁止放共享单例字段；② 会话记忆按 `memoryId` 隔离，底层用 Redis 而非共享 Map；③ 模型客户端/向量库连接池化并做限流，避免线程池被慢调用占满；④ 线程池隔离：AI 调用与业务调用分池，防止相互拖垮。
- 坑：Spring Boot 默认单例 Bean 下若把“当前用户/上下文”存成员变量，必然串话——这是 AI 应用最典型的生产事故。

评分要点

- **优秀：**指出“单例 Bean 存请求态”这一高危坑，并给出请求级隔离 + 池化 + 分池的完整方案。
- **及格：**能说出按会话 ID 隔离上下文、用连接池。
- **不足：**没意识到并发下的状态共享问题。

常见追问：1) ThreadLocal 在线程池复用下会有什么问题？2) 怎么压测验证隔离是否生效？

我的答案

我会从请求状态、会话记忆和资源使用三个方面做隔离。

首先，Spring 的 Service 默认是单例，所以当前用户、本次检索结果、工具调用的中间结果，我都会放在方法参数或局部变量里，沿着调用链传递。这样多个请求同时进来，各自使用自己的上下文，避免共享成员变量被互相覆盖。

其次，每个会话使用独立的 `memoryId`。另外，同一会话同时提交多条消息时，我会按会话排队处理，避免历史消息交错更新。

最后，资源方面会复用线程安全的客户端和连接池，设置超时、限流和并发上限。AI 调用和普通业务使用独立线程池，减少慢 AI 请求对其他接口的影响。

如果面试官追问“为什么成员变量会串话”，用这个例子就够了：

比如 A 请求把 `currentUser` 设置成 A，还没执行完，B 请求就把它改成了 B。A 后续再读取这个字段，就可能按 B 的身份检索。单例对象可以共享，但用户专属的可变状态要跟着请求走。

【A1-27】 【L2】 MCP 模型上下文协议

题目： MCP 是什么？它解决什么问题？一次 MCP 工具调用的流程是怎样的？

思考方向： 把 MCP 类比"AI 世界的 USB-C"，统一模型与外设/工具/数据源的接入标准。

考察点： MCP 协议理解。

参考答案

- MCP (Model Context Protocol)：一套开放协议，用统一标准把工具、资源、提示模板暴露给大模型应用，解决"N 个模型 × M 个工具"各自定制对接的 M×N 集成噩梦。
- 角色：Host (宿主应用/Agent) ↔ Client ↔ Server (提供 tools/resources/prompts 的独立服务)；传输可用 stdio (本地进程) 或 SSE/HTTP (远程)。
- 流程：客户端连接 Server 并拉取工具清单 → 把工具以 schema 形式交给模型 → 模型决策 → 客户端经 JSON-RPC 调用 Server 执行 → 结果回灌模型。
- 价值：工具/数据源一次开发、多端复用，可插拔，安全边界更清晰 (Server 独立部署、可鉴权)。

评分要点

- **优秀：** 讲清 Host/Client/Server 角色、JSON-RPC 调用流程与"一次开发多端复用"的价值。
- **及格：** 知道 MCP 是统一工具/数据接入的协议，能说出大致流程。
- **不足：** 只知道"MCP 是个新概念"。

常见追问： 1) MCP 的安全风险有哪些 (提示词注入/越权)？2) 本地 stdio 与远程 SSE 怎么选？

【A1-28】 【L3】 MCP 与 Function Calling 的区别

题目： MCP 和 Function Calling 是一回事吗？既然有 Function Calling，为什么还要 MCP？

思考方向： Function Calling 是"模型的调用能力"，MCP 是"工具的接入与分发标准"。

考察点： 概念辨析、架构分层理解。

参考答案

- Function Calling：模型侧能力——模型输出结构化的"要调用哪个函数、参数是什么"，属于推理与决策层，每个应用各自把工具注册进 prompt。
- MCP：接入与分发层——定义工具怎么暴露、被发现、被调用 (协议 + 独立 Server)，与具体模型解耦。
- 关系：二者互补而非替代。MCP Server 把工具标准化提供出来，Host 再把 MCP 里的工具"转译"成 Function Calling 的 schema 给模型；模型依旧靠 Function Calling 做决策，只是工具的来源统一成了 MCP。
- 价值：工具从"每个应用内硬编码"变成"可插拔的公共服务"，复用与治理 (鉴权、版本、审计) 都更好。

评分要点

- **优秀：** 明确"能力层 vs 协议层"的分工，并说清二者如何协同工作。
- **及格：** 能说出 MCP 是标准协议、Function Calling 是模型调用能力。
- **不足：** 认为 MCP 就是 Function Calling 换个名字。

常见追问： 1) 已有内部工具平台，还有必要上 MCP 吗？2) MCP 会不会引入额外延迟？

我的答案

MCP 和 Function Calling 不是一回事，它们处在不同层面。

Function Calling 是模型的工具调用机制：应用提供函数名称、描述和参数 Schema，模型根据用户问题，输出要调用的函数及结构化参数，再由应用执行函数并把结果返回给模型。**模型本身不执行业务代码。**

MCP 是应用与外部工具服务之间的标准协议，统一工具发现、参数描述、调用和结果返回，也支持资源和提示模板。

****二者互补而非替代。****在常见的组合方式中，MCP Server 把工具按统一标准暴露出来，Host 再把 MCP 工具定义“转译”成模型支持的 Function Calling Schema。模型依旧通过 Function Calling 选择工具、生成参数，Host 再通过 MCP Client 调用对应的 Server，并把结果返回给模型。

****既然有 Function Calling，为什么还要 MCP？****因为 Function Calling 解决了模型如何表达调用意图，但应用接入不同工具服务时，仍然需要编写适配代码。MCP 将接入方式标准化，让一个 MCP Server 提供的工具能够被多个支持 MCP 的应用复用，减少重复集成和维护成本。

【A1-29】【L2】Dify / Coze 平台与 workflow 编排

题目：Dify 和 Coze 有什么差异？什么场景用平台、什么场景用代码框架？

思考方向：从用户群、部署方式、可定制性、与自有系统集成度对比。

考察点：平台认知、选型能力。

参考答案

- Dify：偏企业/开发者，开源可私有化部署，强在 RAG 知识库、workflow 编排、Agent 模式、API 发布与可观测；数据可自持，适合有数据合规要求的企业。
- Coze（扣子）：偏应用/运营侧，低代码可视化、插件生态丰富、发布渠道多（飞书/抖音/微信等），上手快；深度定制与私有化能力相对弱。
- 选型：快速验证/运营同学自助搭建/标准化场景 → 平台（Dify/Coze）；需要深度定制、与自有服务深度集成、复杂 Agent 逻辑、性能与成本可控 → 代码框架（Spring AI Alibaba / LangChain4j / AgentScope）。
- 实践：平台做 MVP 验证，跑通后再用代码重写核心链路，兼顾速度与可控性。

评分要点

- **优秀：**讲清两者定位差异、私有化/合规考量，并给出“平台验证 + 代码落地”的组合策略。
- **及格：**能说出 Dify 偏企业开发、Coze 偏低代码应用。
- **不足：**只听过名字，说不清差异。

常见追问：1) Dify workflow 和 LangGraph 的区别？2) 平台方案的数据安全如何保障？

【A1-30】【L3】Agent 框架选型决策

题目：Spring AI Alibaba、LangChain4j、AgentScope、LangGraph 你会怎么选？给一个决策依据。

思考方向：从团队技术栈、语言、编排复杂度、生态与运维四维度决策。

考察点：架构选型、技术判断力。

参考答案

- 团队栈：Java 为主、已有 Spring 微服务体系 → Spring AI Alibaba / LangChain4j（复用 IoC、监控、鉴权）；Python 数据/AI 团队 → LangChain + LangGraph。
- 编排复杂度：单 Agent + 工具 → LangChain4j AIServices / Spring AI ChatClient 足够；多 Agent、有状态长流程、需要人工介入 → AgentScope（Java 多 Agent）或 LangGraph（Python 图编排、Checkpointers）。

- 模型与生态：深度用阿里云/通义 → Spring AI Alibaba；要多模型自由切换、社区组件丰富 → LangChain4j。
- 运维与团队能力：框架越"重"（多 Agent/图）调试与运维成本越高，要评估团队能否 hold 住；避免为了技术先进而引入无法维护的复杂度。
- 本项目：Java 微服务背景 → Spring AI Alibaba/LangChain4j 做模型与检索层，AgentScope 做多步编排，形成统一接入层，与现有系统无缝集成。

评分要点

- **优秀**：给出多维度决策矩阵，强调"团队能力/运维成本"这一常被忽视的维度，并有具体落地组合。
- **及格**：能按语言栈和编排复杂度给出合理选择。
- **不足**：只说"LangChain 最火所以用它"。

常见追问：1) 同一团队混用 Java 与 Python 框架怎么治理？2) 框架升级（大版本破坏性变更）怎么降低风险？

【A1-31】【L1】SSE 流式输出原理

题目：大模型回答为什么要用 SSE 流式？SSE 和 WebSocket 有什么区别？

思考方向：从"首字延迟体验"切入，对比两种长连接技术。

考察点：流式交互基础。

参考答案

- 流式价值：大模型逐 token 生成，若等全部生成完再返回，用户要等数秒甚至十几秒；SSE 边生成边推送，首 token 几百毫秒就能看到，体感快很多。
- SSE：基于 HTTP 的单向（服务端→客户端）推送，text/event-stream 格式，自带断线重连与事件 id，实现简单、天然兼容 HTTP 基础设施（网关/负载均衡）。
- WebSocket：全双工、双向通信，适合需要客户端频繁实时上行的场景（协同编辑、语音）；实现与运维更重。
- 选型：大模型问答这类"请求一次、服务端持续推"的场景用 SSE 足够；需要双向实时交互才用 WebSocket。

评分要点

- **优秀**：讲清首 token 体验价值、SSE 单向/自带重连、以及"何时该用 WebSocket"的边界。
- **及格**：能说清 SSE 是服务端单向推送、用于流式输出。
- **不足**：把 SSE 与 WebSocket 混为一谈。

常见追问：1) SSE 经过 Nginx 要怎么配置（缓冲/超时）？2) 如何取消正在进行的流式生成？

我的答案

大模型的答案通常是逐个 token 生成的。如果等整段生成完再返回，用户就会一直看着页面等。流式输出可以边生成边展示，让用户早点看到内容，体验会好很多。**它主要改善的是等待体验，并不是让模型本身生成得更快。**

SSE 的做法比较直接：客户端发起 HTTP 请求，服务端保持响应流打开，把新生成的内容不断往客户端发送，使用的是 `text/event-stream` 格式。它提供的是**服务端到客户端的单向推送**。而且它基于 HTTP，比较容易复用现有的网关、鉴权和监控体系，实现和运维通常比较简单。

WebSocket 则是**全双工通信**，连接建立之后，客户端和服务端都可以随时主动发送消息，更适合频繁的双向实时交互。不过，我们通常还需要专门处理心跳保活、断线重连和连接状态管理，网关、反向代理也需要支持 WebSocket。**它的双向通信能力更强，但实现与运维通常也更重。**

所以，普通的大模型文字问答，通常是用户提交一次问题，服务端持续返回答案，我会优先考虑 SSE：既能满足需求，落地和维护的成本也比较低。如果是实时语音，需要持续上传音频，同时接收识别结果或模型回复，我就会考虑 WebSocket。

【A1-32】【L3】SSE 高并发、断线重连与背压

题目：要支撑 1000+ 并发流式问答且首 token < 300ms，你会怎么设计？断线重连和背压怎么处理？

思考方向：从接入层、模型层、连接管理、降级四处着手。

考察点：高并发流式架构、容错设计。

参考答案

- 接入层：网关限流（按用户/租户）+ 负载均衡；SSE 是长连接，注意连接数上限、Nginx 关闭 proxy_buffering、放大 read timeout、keepalive 配置。
- 模型层：用推理服务（vLLM）做连续批处理提吞吐；多模型路由与配额控制；热点问题做语义缓存直接命中，绕过模型调用。
- 连接与状态：每个流分配 streamId，生成任务与 HTTP 连接解耦（任务写消息队列/Redis Stream，客户端断线重连可按 event id 续传）；会话上下文存 Redis，重连恢复不丢。
- 背压与降级：客户端消费慢时限制缓冲队列长度，超出则丢弃中间态或降级为“生成完再返回”；模型超时降级到小模型/规则；全链路超时与重试；监控首 token 延迟、连接数、断线率。

评分要点

- **优秀：**讲清“生成与连接解耦 + event id 续传 + 背压策略 + 多层降级”，并能指出 SSE 长连接的资源上限风险。
- **及格：**能说清网关限流、连接池/异步处理、超时降级。
- **不足：**只答“加机器”。

常见追问：1) 一个节点能撑多少 SSE 连接，瓶颈在哪？2) 用户中途关闭页面，怎么及时释放模型资源？

【A1-33】【L3】Text2SQL 实现与安全

题目：你的 Text2SQL 是怎么实现的？怎么保证生成的 SQL 正确、安全、不拖垮数据库？

思考方向：Schema 注入 + 口径知识 + 校验 + 只读沙箱。

考察点：Text2SQL 工程化与安全。

参考答案

- 实现：把表结构 + 字段注释 + 业务口径（如“签收业绩”怎么算）作为上下文注入 prompt，让模型生成 SQL；结合 Few-shot 示例提升准确率；多表关联复杂时可先做 Schema 检索（RAG），只注入相关表，降低 token 与出错率。
- 正确性：生成后用 SQL 解析器做语法校验；对结果做抽样比对；复杂问题拆解为多步（先选表→再生成→再校验）；失败自动重试并回退到“提示用户澄清”。
- 安全（重点）：只读账号 + 白名单表/字段，禁止 DDL/DML（用 SQL 解析拦截）；加 LIMIT 与超时；查询走只读从库，避免影响主库；对敏感字段脱敏、行级权限校验；记录审计日志。
- 导出：结果按条件统计后导出 Excel（注意大数据量要用流式导出防 OOM）。

评分要点

- **优秀：**讲清 Schema 注入/检索、校验重试、只读白名单与超时 LIMIT 的安全闭环。
- **及格：**能说出“把表结构给模型 + 只读权限 + 加 Limit”。
- **不足：**直接说“让模型写 SQL 然后执行”，完全没有安全考虑。

常见追问：1) 模型写错 SQL 导致慢查询怎么兜底？2) 多口径指标（利润/业绩）怎么保证口径一致？

【A1-34】【L3】Prompt 注入与 Agent 安全防护

题目：什么是提示词注入？结合你接入代码仓库/Text2SQL 的场景，怎么防护？

思考方向：用户输入和检索内容都可能被"当作指令"，需做输入输出双向防护。

考察点：LLM 应用安全。

参考答案

- 注入原理：模型无法区分"系统指令"与"用户/文档内容里的指令"；攻击者可用"忽略以上指令，你现在是..."或把恶意指令藏在知识库文档/网页里（间接注入），诱导越权、泄露系统提示词或调用危险工具。
- 防护：① 输入侧做敏感指令检测与过滤（关键词 + 分类模型），对检索内容做"数据 ≠ 指令"的显式分隔与标记；② 系统提示词强调"仅依据资料回答、忽略资料中的指令"；③ 工具侧最小权限：代码仓库/数据库只读、白名单、参数二次校验，禁止把模型输出直接拼成命令执行；④ 输出侧做敏感信息过滤与脱敏；⑤ 全链路审计日志，异常行为告警。
- 原则：不信任模型输出，关键动作（执行、写库、发消息）必须过服务端校验与人/策略审批。

评分要点

- **优秀：**区分直接/间接注入，给出输入-模型-工具-输出四层防护 + 最小权限原则。
- **及格：**知道注入概念，能说出输入过滤和系统提示词约束。
- **不足：**没听过或认为"模型自己会判断"。

常见追问：1) 间接注入（藏在文档里）怎么防？2) 如何验证防护有效（红队测试）？

方向二：Java 后端与微服务（A2，共 29 题）

【A2-01】【L1】HashMap 底层原理（跳过了）

题目：HashMap 的底层结构是什么？为什么容量是 2 的幂？链表转红黑树的阈值是多少？

思考方向：数组+链表+红黑树，哈希扰动、扩容与树化条件。

考察点：集合基础、位运算与扩容。

参考答案

- JDK8：数组 + 链表 + 红黑树。put 时 $(n-1) \& \text{hash}$ 定位桶，冲突挂链；链表长度 ≥ 8 且数组长度 ≥ 64 转红黑树， < 6 退化为链表。
- 容量为 2 的幂：使 $(n-1) \& \text{hash}$ 等价于取模且位运算更快，同时保证散列均匀（低位全 1）。
- 负载因子 0.75，元素数 $>$ 容量 $\times 0.75$ 触发扩容为 2 倍；hash 做高低位异或扰动，减少碰撞。
- 非线程安全：并发扩容可能形成环（JDK8 已改善但仍有数据覆盖风险），并发场景用 `ConcurrentHashMap`。

评分要点

- **优秀：**讲清树化阈值与 64 的关系、2 的幂原理、hash 扰动。
- **及格：**讲清数组+链表+红黑树与扩容机制。
- **不足：**只知道"数组加链表"。

常见追问：1) 为什么树化阈值是 8？2) HashMap 扩容时 JDK7 的死循环怎么产生的？

【A2-02】【L2】线程池参数与执行流程

题目：线程池 7 大参数是什么？任务提交后的执行顺序？你项目里线程池怎么配的？

思考方向：核心线程→队列→最大线程→拒绝策略，结合项目 1s→300ms 的并行改造。

考察点：并发工具、参数调优、生产实践。

参考答案

- 参数：corePoolSize、maximumPoolSize、keepAliveTime、unit、workQueue、threadFactory、handler。
- 执行流程：核心线程未满足 → 建核心线程；已满足 → 入队列；队列满 → 建非核心线程到 max；再满 → 拒绝策略（Abort/CallerRuns/Discard/DiscardOldest）。
- 项目实践（订单详情 1s→300ms）：把串行的"客户/商品/发货"三次远程调用改为并行，用固定大小线程池 + Future 汇总；池按业务隔离并命名（便于排查），队列用有界队列，拒绝策略按业务选（读场景 CallerRuns 兜底）。
- 要点：IO 密集型线程数可较大（2N CPU~），CPU 密集型约 N+1；务必用有界队列防任务堆积 OOM；线程泄漏需监控活跃线程数与队列深度。

评分要点

- **优秀：**讲清执行顺序的每个分支、有界队列的必要性、IO/CPU 密集型的线程数估算、业务隔离。
- **及格：**能说清 7 参数与"核心→队列→max→拒绝"的顺序。
- **不足：**只会 Executors.newFixedThreadPool，不了解拒绝策略。

常见追问：1) 为什么阿里规约禁用 Executors 创建线程池？2) 线程池里的任务抛异常了会怎样？

【A2-03】【L2】synchronized 锁升级（我跳过了）

题目：synchronized 的锁升级过程是怎样的？锁信息存在哪里？

思考方向：对象头 Mark Word 的状态流转：无锁→偏向→轻量→重量。

考察点：并发底层、JVM 对象模型。

参考答案

- 锁状态存于对象头 Mark Word（2 bit 锁标志位）。
- 升级路径：无锁 → 偏向锁（同一线程反复进入，只记录线程 ID，无 CAS）→ 轻量级锁（多线程交替，CAS 自旋抢锁，失败则自旋）→ 重量级锁（竞争激烈，自旋失败后挂起，依赖 OS 互斥量，涉及用户态/内核态切换）。
- 锁只升不降（偏向锁在 JDK15 后默认关闭/废弃，因撤销成本高）；重量级锁通过 Monitor（ObjectMonitor）实现，含 wait/notify 机制。
- 优化：自适应自旋、锁消除、锁粗化。

评分要点

- **优秀：**讲清每级锁的适用场景与实现方式、Mark Word 存储、JDK15 后偏向锁废弃。
- **及格：**能说出"偏向→轻量→重量"的顺序与大体原理。
- **不足：**只知道"synchronized 是重量级锁"。

常见追问：1) 偏向锁为什么要撤销，撤销的时机？2) synchronized 和 ReentrantLock 怎么选？

【A2-04】【L2】volatile 与 JMM（我跳过了）

题目：volatile 保证了什么？为什么不保证原子性？什么是 happens-before？

思考方向：可见性 + 禁止重排序，但不含"复合操作的原子性"。

考察点：Java 内存模型。

参考答案

- volatile 保证可见性（写立即刷主存，读强制从主存取，底层是 lock 前缀指令 + 内存屏障）与有序性（禁止指令重排，如 DCL 单例需 volatile）。
- 不保证原子性：i++ 是“读-改-写”三步，多线程交叉执行仍会丢失更新，需用 synchronized/AtomicInteger（CAS）。
- JMM 定义主内存与工作内存抽象；happens-before 规则（程序顺序、监视器锁、volatile 变量、线程启动/终止、传递性）用于判断多线程下共享变量的可见性顺序。

评分要点

- **优秀**：讲清内存屏障、DCL 为什么需要 volatile、能列举 happens-before 规则。
- **及格**：讲清可见性/有序性、不含原子性。
- **不足**：答“volatile 就是线程安全”。

常见追问：1) DCL 单例不加 volatile 会出什么问题？2) volatile 数组能保证元素可见性吗？

【A2-05】【L2】AQS 原理（我跳过了）

题目：AQS（AbstractQueuedSynchronizer）的核心思想是什么？独占与共享模式有什么区别？

思考方向：state + CLH 双向队列 + CAS + LockSupport。

考察点：并发框架底层。

参考答案

- 核心：一个 volatile int state 表示同步状态 + 一个 CLH 双向等待队列 + CAS 修改 state + LockSupport.park/unpark 阻塞唤醒。
- 独占模式：state=1 表示已占用（ReentrantLock，可重入则 state+1）；共享模式：state 表示可用许可数（Semaphore/CountDownLatch/ReadWriteLock 的读锁）。
- 加锁流程：CAS 抢 state 失败 → 包装成 Node 入队 → 自旋/阻塞等待 → 前驱释放后唤醒；释放时唤醒后继节点。
- 扩展：子类只需实现 tryAcquire/tryRelease（或共享版），模板方法模式让 AQS 统一处理排队与阻塞。ReentrantLock 的公平锁即多了一层 hasQueuedPredecessors 判断。

评分要点

- **优秀**：讲清 state/队列/park 三要素、独占与共享差异、模板方法设计、公平锁实现差异。
- **及格**：能说出 state + CAS + 等待队列的核心机制。
- **不足**：只知道“AQS 是锁的底层”。

常见追问：1) 为什么用双向队列？2) 基于 AQS 手写一个不可重入锁的思路？

【A2-06】【L2】ConcurrentHashMap 并发安全实现（暂时跳过了）

题目：JDK8 的 ConcurrentHashMap 如何保证并发安全？与 JDK7 有何区别？

思考方向：分段锁演进到 CAS + synchronized 锁桶头。

考察点：并发容器、锁粒度优化。

参考答案

- JDK7：Segment 分段锁（继承 ReentrantLock），默认 16 段，并发度 = 段数，锁粒度粗。
- JDK8：取消 Segment，Node 数组 + 链表/红黑树；空桶用 CAS 写入，非空桶 synchronized 锁头节点，锁粒度细化到桶；扩容时多线程协助迁移（ForwardingNode 标识）。
- size：baseCount + CounterCell 数组分散热点，减少竞争。
- 注意：get 不加锁（Node 的 val/next 用 volatile 保证可见性）；不允许 null 键值。

评分要点

- **优秀**：讲清 CAS 与 synchronized 的配合、多线程协助扩容、CounterCell 思想。
- **及格**：讲清 JDK7 分段锁 vs JDK8 桶级锁的差异。
- **不足**：只说“它是线程安全的”。

常见追问：1) size 在高并发下精确吗？2) 为什么不用 ReentrantLock 而用 synchronized？

【A2-07】【L1】JVM 内存结构（暂时跳过了）

题目：JVM 运行时内存区域有哪些？哪些线程私有、哪些共享？

思考方向：私有（程序计数器/虚拟机栈/本地方法栈）与共享（堆/方法区）。

考察点：JVM 基础。

参考答案

- 线程私有：程序计数器、虚拟机栈（栈帧：局部变量表/操作数栈/动态链接/返回地址）、本地方法栈。
- 线程共享：堆（对象实例，分新生代 Eden+Survivor、老年代）、方法区（JDK8 起为元空间 Metaspace，存类元信息、常量、静态变量）。
- 常见异常：栈溢出 StackOverflowError（递归过深）、堆溢出 OOM:java heap space、元空间溢出（类加载过多/动态代理/CGLIB）。
- 直接内存（NIO/Netty）不在堆内，也需关注。

评分要点

- **优秀**：区分 JDK7 永久代与 JDK8 元空间、说出各区域对应异常。
- **及格**：能列出五个区域并区分私有/共享。
- **不足**：把方法区等同于堆。

常见追问：1) 字符串常量池在哪？2) 元空间为什么替代永久代？

【A2-08】【L3】GC 调优与线上 OOM / CPU 飙高排查

题目：线上出现频繁 Full GC 或 OOM，你怎么排查？CPU 飙高怎么定位？

思考方向：从监控指标 → dump 分析 → 定位代码，形成标准排查动作。

考察点：故障排查实战能力。

参考答案

- Full GC 频繁：先用 jstat -gcutil 看各代使用率与 GC 频率；若老年代持续增长回收不掉 → 疑似内存泄漏，jmap dump 堆，用 MAT/VisualVM 分析支配树找大对象与引用链；若单次 GC 耗时高 → 堆过大或对对象存活多，考虑分代比例/收集器（G1/ZGC）。
- OOM：结合 dump + 错误类型定位——heap space（对象过多/泄漏）、GC overhead limit（频繁 GC 无回收）、Metaspace（类加载泄漏）、unable to create native thread（线程数超限）。
- CPU 飙高：top -Hp 找高 CPU 线程 → 线程 id 转 16 进制 → jstack 查该线程栈，常见于死循环、正则回溯、频繁 GC、锁自旋。
- 工具：Arthas（dashboard/thread/trace/watch）做线上诊断，不改代码可定位慢方法与热点。

评分要点

- **优秀**：给出“指标→dump→引用链→代码”的完整路径，能区分几种 OOM 类型与 CPU 排查套路，提到 Arthas。
- **及格**：能说出 jstat/jmap/jstack + MAT 的基本用法。

- **不足：**只会说"重启一下"。

常见追问：1) 生产环境能直接 dump 吗，有什么风险？2) 怎么区分是内存泄漏还是内存不足？

【A2-09】 【L1】 Spring IoC 与 AOP

题目：什么是 IoC 和 AOP？AOP 的底层实现是什么？

思考方向：控制反转/依赖注入 + 面向切面，动态代理实现。

考察点：Spring 核心。

参考答案

- IoC：对象创建与依赖装配交给容器，通过构造器/字段/Setter 注入，降低耦合、便于测试与替换实现。
- AOP：把日志、事务、鉴权等横切关注点从业务代码中抽离，通过切点表达式在方法前后织入增强。
- 底层：JDK 动态代理（目标类实现接口，基于反射 InvocationHandler）与 CGLIB（无接口时，生成子类字节码增强）；Spring Boot 2.x 起默认 proxyTargetClass=true 倾向 CGLIB。
- 注意：AOP 生效依赖代理对象，同类内部方法调用不走代理，切面/事务会失效。

评分要点

- **优秀：**讲清两种代理的选择条件、内部调用失效的原因。
- **及格：**讲清 IoC/AOP 概念与动态代理实现。
- **不足：**只知道"Spring 帮我 new 对象"。

常见追问：1) JDK 代理和 CGLIB 的性能差异？2) AOP 的 5 种通知类型？

【A2-10】 【L2】 Bean 生命周期与循环依赖三级缓存

题目：Spring Bean 的生命周期？循环依赖是怎么用三级缓存解决的？为什么不能只靠二级？

思考方向：实例化→属性填充→初始化→销毁，缓存解决"提前暴露引用"。

考察点：Spring 源码机制。

参考答案

- 生命周期：实例化（构造）→ 属性填充（依赖注入）→ Aware 回调 → BeanPostProcessor.before → @PostConstruct/InitializingBean → AOP 代理生成 → after → 使用 → 销毁（@PreDestroy/DisposableBean）。
- 三级缓存：singletonObjects（成品）、earlySingletonObjects（半成品）、singletonFactories（ObjectFactory）。A 依赖 B、B 依赖 A 时，A 实例化后把"能产出 A 早期引用的工厂"放入三级缓存；B 注入时从三级缓存拿到 A 的早期引用（必要时提前生成代理）放入二级缓存，B 完成后再让 A 完成初始化。
- 为什么不能只两级：若只用二级直接存早期引用，则无法在"需要时"才把 AOP 代理提前暴露——三级缓存存的是工厂，保证只有一个代理对象，避免注入原始对象与最终代理不一致。
- 限制：只能解决单例、字段/Setter 注入的循环依赖；构造器注入与原型 Bean 无法解决（会抛异常）。

评分要点

- **优秀：**讲清三级缓存各自作用、工厂延迟生成代理的意义、构造器注入/原型失效的边界。
- **及格：**能说出三级缓存名字与大体解决思路。
- **不足：**只知道"Spring 用三级缓存解决循环依赖"。

常见追问：1) @Async 与循环依赖一起用会怎样？2) 为什么构造器循环依赖解决不了？

【A2-11】 【L2】 事务传播行为与 @Transactional 失效

题目：Spring 事务传播行为有哪些？@Transactional 在哪些场景会失效？

思考方向：7 种传播行为 + 代理失效的几类典型坑。

考察点：事务机制、生产踩坑经验。

参考答案

- 7 种传播：REQUIRED（默认，加入现有事务）、REQUIRES_NEW（挂起当前、新开事务）、SUPPORTS、NOT_SUPPORTED、MANDATORY、NEVER、NESTED（嵌套，保存点回滚）。
- 失效场景：① 同类内部方法自调用（不走代理，最常考）；② 方法非 public；③ 异常被 try-catch 吞掉未抛出；④ 抛的是受检异常默认不回滚（需 rollbackFor = Exception.class）；⑤ 多线程/异步调用（事务在别的线程）；⑥ 数据库引擎不支持事务（MyISAM）。
- 解决：注入自身代理 / AopContext.currentProxy() / 拆分到另一个 Bean；统一配 rollbackFor。

评分要点

- **优秀：**能完整列举失效场景并给出解决方案，讲清 REQUIRES_NEW 与 NESTED 的差别。
- **及格：**能说出 4~5 种传播行为与 2~3 类失效场景。
- **不足：**只会说“加个 @Transactional 就有事务了”。

常见追问：1) REQUIRES_NEW 的挂起是怎么实现的？2) 分布式场景下本地事务还够用吗？

【A2-12】 【L2】 MyBatis 原理与插件机制

题目：MyBatis 的执行流程是怎样的？#{ } 和 \${ } 的区别？插件（Interceptor）怎么工作？

思考方向：SQL 解析→参数映射→执行→结果映射，插件基于动态代理拦截四大对象。

考察点：ORM 框架原理。

参考答案

- 流程：加载配置/Mapper → 生成 SqlSession → 从 MappedStatement 取 SQL → 参数处理（ParameterHandler）→ 执行（Executor→StatementHandler→JDBC）→ 结果映射（ResultSetHandler）。
- #{ } 是预编译占位符（PreparedStatement 参数，防 SQL 注入）；\${ } 是字符串拼接（有注入风险，仅用于表名/排序等动态片段，需白名单校验）。
- 插件：基于 JDK 动态代理，可拦截 Executor / StatementHandler / ParameterHandler / ResultSetHandler 四大对象，典型用途是分页（如 PageHelper）、审计、多租户、SQL 日志；注意多个插件会层层包装，且拦截点选错会影响功能。

评分要点

- **优秀：**讲清四大对象与代理链、#{ } / \${ } 的安全差异与使用边界。
- **及格：**能说出执行流程与 #{ } 预编译的区别。
- **不足：**不知道 MyBatis 内部组件。

常见追问：1) 分页插件原理是什么？2) 一级/二级缓存的坑？

【A2-13】 【L2】 Spring Boot 自动配置原理

题目：@SpringBootApplication 包含哪些注解？自动配置是怎么实现的？

思考方向：@EnableAutoConfiguration → spring.factories / AutoConfiguration.imports → 条件装配。

考察点： Spring Boot 核心机制。

参考答案

- @SpringBootApplication = @SpringBootConfiguration + @ComponentScan + @EnableAutoConfiguration。
- 自动配置：@EnableAutoConfiguration 通过 @Import(AutoConfigurationImportSelector) 读取 META-INF/spring.factories (Boot 2.7+/3.x 为 META-INF/spring/AutoConfiguration.imports) 中的候选配置类；再由 @Conditional 系列 (@ConditionalOnClass/@ConditionalOnMissingBean/@ConditionalOnProperty) 按需生效。
- 所以"引入 starter 就有默认配置、自己定义了 Bean 就覆盖默认"，本质是条件装配；用户配置优先于自动配置。
- 可自定义 starter：写自动配置类 + 条件注解 + spring.factories 注册，实现"引依赖即用"。

评分要点

- **优秀：** 讲清 import selector 加载机制 + 条件装配 + 覆盖优先级 + 自定义 starter 思路。
- **及格：** 能说出三大注解与条件装配。
- **不足：** 只会背注解名。

常见追问： 1) 自动配置类的加载顺序怎么控制？ 2) 怎么排除某个自动配置？

【A2-14】 【L1】 设计模式实战

题目： 你在项目里用过哪些设计模式？结合实际场景讲讲。

思考方向： 不要背 23 种，挑 2~3 个真实用过的讲透。

考察点： 工程思想与落地能力。

参考答案

- 策略模式：支付方式（微信/支付宝/藏宝岛分支）用一个 PayStrategy 接口 + 多实现，按类型路由，避免大量 if-else；新增支付方式只需加实现。
- 模板方法：批量发货/异步任务定义统一的"校验→执行→记录失败→重试"骨架，子类实现具体明细处理。
- 责任链：AI 问答的输入预处理（敏感词→改写→路由）+ 后置处理（引用标注→脱敏→落库）串成链，便于插拔。
- 单例/工厂/观察者按需提及。关键是把"解决了什么扩展性问题"讲清楚，而不是罗列。

评分要点

- **优秀：** 结合本项目真实场景（支付分支、批量任务、Agent 处理链），讲清"为什么用它、带来什么可扩展性"。
- **及格：** 能说出 2~3 个模式并在业务场景中合理应用。
- **不足：** 只背定义，说不出项目落点。

常见追问： 1) 策略模式怎么根据类型选择实现（Spring 注入 Map）？ 2) 责任链和 AOP 的关系？

【A2-15】 【L2】 MySQL B+ 树索引与最左匹配

题目： 为什么用 B+ 树而不用 B 树/哈希？什么是聚簇索引、回表、覆盖索引、最左前缀？

思考方向： 从磁盘 IO 与范围查询的角度说明选型。

考察点： 索引原理（面试高频）。

参考答案

- B+ 树：非叶子节点只存索引、不存数据，单节点能放更多键 → 树更矮（3~4 层可存千万级），磁盘 IO 少；叶子节点用链表相连，天然支持范围查询与排序。B 树数据分散在各层，范围查询要回溯；Hash 索引只支持等值、不支持范围与排序。
- InnoDB 主键为聚簇索引（叶子存整行数据）；二级索引叶子存主键值，查询非索引列需拿主键回表。
- 覆盖索引：查询列全在索引里，无需回表；最左前缀：联合索引 (a,b,c) 必须从 a 开始连续匹配才能用上，跳过 a 直接用 b 失效。
- 索引下推 (ICP)：在存储引擎层就用索引列做过滤，减少回表。

评分要点

- **优秀**：讲清树高与 IO 的关系、回表/覆盖索引、最左前缀的连续性要求与 ICP。
- **及格**：能说出 B+ 树优势与聚簇索引、回表概念。
- **不足**：只说“索引能加快查询”。

常见追问：1) 联合索引 (a,b,c)，where b=1 and c=2 会走索引吗？2) 为什么建议用自增主键？

【A2-16】【L2】MVCC 与事务隔离级别

题目：MySQL 的四种隔离级别？MVCC 是怎么实现的？它解决了什么问题？

思考方向：undo log 版本链 + ReadView 判断可见性。

考察点：事务与并发控制。

参考答案

- 隔离级别：读未提交、读已提交 (RC)、可重复读 (RR, InnoDB 默认)、串行化。分别解决脏读、不可重复读、幻读 (RR 下通过间隙锁 + MVCC 基本解决幻读)。
- MVCC：每行有隐藏的 trx_id 与 roll_pointer；更新时旧版本写入 undo log 形成版本链；查询时生成 ReadView (记录当前活跃事务列表)，沿版本链找到对当前事务可见的版本。
- RC 与 RR 的差异：RC 每次查询都生成新 ReadView (能看到别人已提交的最新数据)；RR 只在首次查询时生成一次 ReadView (整个事务看到同一快照)。
- MVCC 主要解决读写不阻塞 (快照读)，但当前读 (select for update / update) 仍需加锁。

评分要点

- **优秀**：讲清 ReadView 生成时机导致 RC/RR 差异、快照读 vs 当前读。
- **及格**：能说出四级别与 undo log 版本链 + ReadView 的基本机制。
- **不足**：分不清各级别解决的问题。

常见追问：1) RR 下幻读真的完全解决了吗？2) 间隙锁什么时候会加？

【A2-17】【L3】慢 SQL 优化与死锁排查

题目：一条 SQL 执行很慢，你怎么排查和优化？线上出现死锁怎么办？

思考方向：explain 看执行计划 → 索引/回表/数据量 → 改写 SQL；死锁看日志与加锁顺序。

考察点：SQL 优化实战。

参考答案

- 排查：开慢查询日志定位 SQL；explain 看 type (全表扫描 ALL / index / range / ref / const)、key 实际用到的索引、rows 扫描行数、Extra (Using filesort/temporary 需警惕)。
- 优化：建合适的联合索引 (遵循最左前缀、高选择性列在前)、用覆盖索引避免回表、避免索引失效 (函数运算/隐式类型转换/前导 %like/or 混用)、大分页用“延迟关联”或游标 (where id > lastId)、减少 select *、拆大事务。

- 死锁：show engine innodb status 看 LATEST DETECTED DEADLOCK，分析两个事务的加锁顺序；常见成因是不同事务以相反顺序加锁（如先锁 A 再锁 B vs 先锁 B 再锁 A）或间隙锁范围冲突；解决靠统一加锁顺序、缩小事务范围、必要时降级隔离级别。
- 兜底：加超时（innodb_lock_wait_timeout）、重试机制、热点更新用乐观锁/队列串行化。

评分要点

- **优秀**：能读懂 explain 关键字段、给出多种索引失效场景与分页优化技巧，死锁能定位到加锁顺序。
- **及格**：能说出 explain + 建索引 + 避免索引失效。
- **不足**：只会说"加个索引"。

常见追问：1) 索引越多越好吗，代价是什么？2) 大表加索引会锁表吗？

【A2-18】【L1】缓存穿透、击穿、雪崩

题目：缓存穿透、击穿、雪崩分别是什么？怎么解决？

思考方向：三者成因不同：查不存在的数据、热点 key 失效、大批 key 同时失效。

考察点：缓存治理（必考题）。

参考答案

- 穿透：查询 DB 中不存在的数据，缓存永远不命中，请求全打到 DB。方案：缓存空值（短 TTL）、布隆过滤器拦截、参数校验。
- 击穿：某个热点 key 过期瞬间，大量并发请求同时回源。方案：互斥锁/分布式锁只放一个请求回源、逻辑过期（不设过期时间，异步刷新）、热点 key 永不过期。
- 雪崩：大量 key 同一时刻过期或缓存服务宕机，DB 瞬间被打垮。方案：过期时间加随机抖动、多级缓存（本地 Caffeine + Redis）、缓存高可用（集群/哨兵）、限流降级兜底。
- 本项目对应：商品详情用"按商品 ID 加锁 + 二次检查"解决击穿，即同一商品只放一个请求回源。

评分要点

- **优秀**：三类成因与方案一一对应，能结合"按 ID 加锁 + DCL"与逻辑过期讲实现细节。
- **及格**：能说清三者区别与各自的解法。
- **不足**：三者混为一谈。

常见追问：1) 布隆过滤器有误判吗，怎么处理？2) 逻辑过期怎么保证数据一致性？

【A2-19】【L2】缓存与数据库一致性

题目：怎么保证缓存与数据库的一致性？为什么推荐"先更新 DB 再删缓存"？

思考方向：更新策略对比 + 延迟双删 + 最终一致（Canal 订阅 binlog）。

考察点：一致性设计。

参考答案

- 不推荐"更新缓存"：并发写会乱序，且很多写不值得缓存（白写）。
- Cache Aside（先更新 DB，再删缓存）：出现不一致的概率最低——若同时有读请求，读线程可能读到旧值写回缓存，但需要"删除 + 延迟双删"来缩小窗口。
- 强一致方案：读请求与写请求串行化（分布式锁，性能差）；最终一致：用 Canal 订阅 MySQL binlog，异步删除/重建缓存，解耦且可靠，是主流生产方案。
- 兜底：缓存设过期时间（兜底一致性的最后防线）；对一致性要求极高的读走主库。

评分要点

- **优秀**：讲清"为什么删而不是更新"、双删的必要性与残留窗口、Canal 最终一致方案。
- **及格**：能说出 Cache Aside 与延迟双删。
- **不足**：认为"先删缓存再更新 DB"就万事大吉。

常见追问：1) 延迟双删的延迟时间怎么定？2) 能不能做到强一致？

【A2-20】【L2】分布式锁与 Redisson 看门狗

题目：用 Redis 实现分布式锁要注意什么？Redisson 的看门狗机制是什么？

思考方向：SETNX+过期时间→原子性→续期→可重入→释放安全性。

考察点：分布式并发控制。

参考答案

- 基本实现：SET key value NX PX 30000，必须"加锁 + 过期"原子完成（旧版 SETNX + EXPIRE 两步会因宕机死锁）。
- 释放锁：value 用唯一标识（UUID+线程 ID），用 Lua 脚本"判断是自己的锁再删"，防止误删别人的锁。
- 看门狗（watchdog）：Redisson 加锁成功后台起一个定时任务，默认每 10s（租期 30s 的 1/3）检查并自动续期，避免业务未执行完锁就过期；业务宕机则续期停止，锁自然到期释放。也支持可重入（Hash 结构记录重入次数）与 RedLock 多节点。
- 局限：Redis 主从切换可能丢锁（异步复制），强一致场景需 RedLock 或 ZooKeeper/etcd。

评分要点

- **优秀**：讲清原子加锁、Lua 安全释放、看门狗续期与可重入实现，并指出主从切换丢锁风险。
- **及格**：能说出 SETNX+PX、唯一 value 释放、看门狗续期。
- **不足**：只会 SETNX 且不加过期时间。

常见追问：1) Redisson 看门狗在什么情况下会失效？2) 分布式锁和分布式事务能互相替代吗？

【A2-21】【L2】Redis 主从读写分离与高可用

题目：你项目做了 Redis 主从读写分离，怎么落地？主从延迟导致读到旧数据怎么办？

思考方向：写走主、读走从的收益与代价，延迟与一致性权衡。

考察点：缓存架构、一致性权衡。

参考答案

- 落地：写命令与失效操作走主节点，读请求分流到从节点，缓解主节点读压力、提升读吞吐；配合哨兵（Sentinel）或 Cluster 做故障自动切换。
- 主从延迟：Redis 复制是异步的，写主后立刻读从可能读到旧值（读到"回退"的数据）。方案：① 对一致性敏感的读（如刚下单后查订单）强制走主；② 关键写后加短暂等待或"读己之写"路由；③ 用版本号/延迟双删兜底；④ 监控主从复制 offset 差值。
- 注意：从节点故障、主从切换瞬间会有连接抖动，客户端需重试；集群模式下要处理跨 slot 的多 key 操作。

评分要点

- **优秀**：讲清读写分离的收益、异步复制的延迟本质，并给出"读己之写"的分流策略。
- **及格**：能说出写主读从、延迟导致不一致与基本兜底。
- **不足**：认为读写分离"完全没有副作用"。

常见追问：1) 哨兵和集群的区别？2) 主从全量同步和增量同步的触发条件？

【A2-22】【L3】大 key / 热 key 治理

题目：什么是大 key 和热 key？会引发什么问题？怎么发现和治理？

思考方向：大 key 是"单个 key 数据量过大"，热 key 是"单个 key 访问量过大"，都会拖垮单节点。

考察点：Redis 生产治理。

参考答案

- 大 key：价值如成员数万的 Hash/List、几 MB 的 String。危害：单次操作阻塞 Redis 单线程（其他请求排队）、网络带宽打满、删除时阻塞、集群分片不均。治理：拆分（按业务/哈希分桶）、压缩、惰性删除（unlink 异步删）、设置合理过期。
- 热 key：如秒杀商品、爆款详情。危害：流量集中到单个分片/节点，打满单节点。治理：多级缓存（本地缓存扛住绝大部分读）、key 加随机后缀打散到多分片、读写分离、限流。
- 发现手段：redis-cli --bigkeys / --hotkeys、MONITOR（谨慎）、慢日志、自研采样上报。
- 原则：预防为主——key 设计时就控制粒度、避免全量聚合、热点业务提前规划多级缓存。

评分要点

- **优秀：**讲清危害机理（单线程阻塞/分片倾斜）、local cache 扛热 key、unlink 异步删除等具体手段。
- **及格：**能说清两者概念与基本治理方向。
- **不足：**只知道"大 key 不好"。

常见追问：1) 本地缓存与 Redis 的一致性怎么处理？2) 集群模式下热 key 为什么更危险？

【A2-23】【L2】Nacos 注册与配置中心

题目：Nacos 怎么做服务注册发现和配置管理？临时实例和持久实例有什么区别？

思考方向：服务注册/心跳/健康检查 + 配置动态刷新，CP/AP 模式差异。

考察点：微服务治理。

参考答案

- 注册发现：服务启动向 Nacos 注册实例信息，消费方拉取（+ 订阅推送）实例列表，通过 Ribbon/LoadBalancer 做客户端负载均衡调用。
- 健康检查：临时实例用客户端心跳（默认 5s），心跳丢失则剔除，Nacos 1.x 默认 AP（可用性优先，基于 Distro 协议 + 自研一致性）；持久实例由 Nacos 服务端主动探测（TCP/HTTP），不健康只标记不剔除，走 Raft 保证 CP。
- 配置中心：配置集中管理、按 namespace/group/dataId 隔离；@RefreshScope + Nacos 长轮询实现配置变更动态刷新，不用重启。
- 实践：环境用 namespace 隔离，配置按共享（common）+ 应用维度拆分，敏感信息安全加密。

评分要点

- **优秀：**讲清心跳 vs 主动探测、AP/CP 选择依据、长轮询动态刷新机制。
- **及格：**能说出注册发现流程与配置动态刷新。
- **不足：**只把 Nacos 当"配置文件的存储"。

常见追问：1) Nacos 集群脑裂怎么处理？2) 配置刷新失败怎么排查？

【A2-24】【L2】OpenFeign 原理

题目：OpenFeign 是怎么把接口调用变成 HTTP 请求的？超时和重试怎么配？

思考方向：动态代理 + 注解解析 + 负载均衡 + 编解码。

考察点：远程调用机制。

参考答案

- 原理：@FeignClient 接口在启动时被扫描，通过 JDK 动态代理生成实现；调用方法时解析 @RequestMapping 等注解拼出 HTTP 请求，经负载均衡器选择实例，再由 Encoder/Decoder 做序列化与响应解析。
- 集成：底层默认用 LoadBalancer 从注册中心取实例，可结合 Sentinel 做熔断、加拦截器传递鉴权 token/链路 ID。
- 配置：连接超时 connectTimeout、读超时 readTimeout（默认偏短需调整）、重试 Retryer（注意非幂等接口不能随便重试）；支持 GZIP 压缩、日志级别。
- 坑：Feign 与 Hystrix/Sentinel 的线程隔离会丢失 ThreadLocal（需用可传递的上下文或请求头），首次调用有懒加载耗时（可配饥饿加载）。

评分要点

- **优秀：**讲清动态代理到 HTTP 的转换链路，指出重试的幂等风险与上下文透传问题。
- **及格：**能说出动态代理 + 负载均衡 + 编解码的基本原理。
- **不足：**只知道"Feign 可以像调本地方法一样调远程"。

常见追问：1) Feign 和 RestTemplate 的区别？2) 非幂等接口的重试怎么防重复下单？

【A2-25】【L2】Gateway 路由、过滤器与限流

题目：Spring Cloud Gateway 的工作原理？怎么做统一鉴权和限流？

思考方向：基于 WebFlux 的响应式网关，路由断言 + 过滤器链。

考察点：网关设计与安全。

参考答案

- 原理：基于 Spring WebFlux + Reactor Netty 的响应式非阻塞网关；请求先匹配 Route（由断言 Predicate 决定，如 Path/Host/自定义），再经过 Pre → 转发 → Post 的过滤器链（GatewayFilter/GlobalFilter）。
- 统一鉴权：在 GlobalFilter 中校验 JWT/token → 解析用户身份 → 写入请求头（用户 ID/租户）透传给下游，未通过直接返回 401，避免每个服务重复校验。
- 限流：内置 RequestRateLimiter 基于 Redis + Lua 令牌桶（KeyResolver 按 IP/用户/IP+接口），超限返回 429；也可接 Sentinel 做更细的流控。
- 其他：灰度（按 header 路由）、重试、熔断、请求/响应日志、跨域统一处理。

评分要点

- **优秀：**讲清响应式过滤器链与执行顺序、JWT 透传设计、Redis 令牌桶限流的 Key 设计。
- **及格：**能说出路由断言 + 过滤器 + 限流的基本用法。
- **不足：**只知道"网关就是转发请求"。

常见追问：1) Gateway 为什么不用 Servlet 而用 WebFlux？2) 网关限流和 Sentinel 应用层限流的区别？

【A2-26】【L2】Sentinel 熔断降级与限流算法

题目：Sentinel 的滑动窗口是怎么实现的？熔断降级策略有哪些？限流、熔断、隔离有什么区别？

思考方向：滑动窗口统计 + 三种熔断策略 + 三种保护手段定位。

考察点：服务治理、稳定性设计。

参考答案

- 滑动窗口：用 LeapArray 把时间切成多个等长小窗口（如 1s 分 2 个 500ms 窗口），统计时滑动聚合最近 N 个窗口的 QPS/异常数，比固定窗口更平滑、避免临界突变。
- 熔断策略：① 慢调用比例（RT 超阈值占比）；② 异常比例；③ 异常数；达到阈值进入 OPEN 状态，经时间窗后半开（HALF_OPEN）探测，成功则恢复。
- 三者区别：限流控制入口流量（保护系统不被打垮）；熔断在下游持续失败时快速失败（防止雪崩、避免无谓等待）；隔离（线程池/信号量）把不同依赖的资源隔开，一个慢不影响其他。三者组合使用。
- 降级：熔断后走 fallback（返回默认值/缓存/友好提示/转人工），保证核心链路可用。

评分要点

- **优秀**：讲清滑动窗口聚合原理、三种熔断策略与半开恢复、三者定位区别。
- **及格**：能说出限流/熔断/降级的概念与常见策略。
- **不足**：把限流和熔断混为一谈。

常见追问：1) 令牌桶和漏桶的区别？2) 熔断阈值怎么定，定错了会怎样？

【A2-27】【L3】分布式事务方案

题目：跨服务下单扣库存，怎么保证一致性？2PC、TCC、Seata AT、可靠消息、Saga 怎么选？

思考方向：强一致 vs 最终一致，按业务容忍度选择。

考察点：分布式事务选型（高频）。

参考答案

- 2PC/XA：强一致但同步阻塞、性能差、协调者单点，互联网场景少用。
- TCC：Try-Confirm-Cancel 三段，业务侵入大，但性能与可控性好；需处理空回滚、悬挂、幂等三大问题。
- Seata AT：无侵入（基于 SQL 解析自动生成 undo log + 全局锁），两阶段提交，适合大多数业务；缺点是有全局锁、热点数据有争用。
- 可靠消息最终一致：本地事务 + 消息表/事务消息，下游消费保证幂等，实现最终一致，性能好，适合跨服务异步场景（如支付成功后通知发货）。
- Saga：长事务拆成多步本地事务 + 补偿，适合流程长、可补偿的业务。选型：优先"最终一致 + 幂等 + 补偿"，强一致需求极强才上 TCC/Seata。

评分要点

- **优秀**：给出选型决策树，讲清 TCC 三大坑（空回滚/悬挂/幂等）与可靠消息的落地方式。
- **及格**：能区分强一致/最终一致并说出 2~3 种方案适用场景。
- **不足**：只会说"用 Seata"。

常见追问：1) 可靠消息方案怎么保证消息不丢不重？2) 为什么不直接都用 TCC？

【A2-28】【L2】RabbitMQ 可靠投递、幂等与延迟队列

题目：你怎么保证消息不丢、不重复消费？延迟任务如何实现？

思考方向：三段（生产者→Broker→消费者）分别保证可靠性。

考察点：消息中间件实战。

参考答案

- 不丢：① 生产者开启 confirm 确认 + 失败重试（本地消息表兜底）；② Broker 持久化（交换机/队列/消息都设持久化，镜像/quorum 队列防节点故障）；③ 消费者手动 ack，处理成功才确

认，失败 requeue 或进死信。

- 不重复：MQ 只能保证 at-least-once，重复几乎不可避免 → 消费端幂等：用业务唯一 ID + Redis/数据库唯一索引/状态机做去重，保证同一消息多次消费结果一致。
- 延迟任务：① TTL + 死信队列（消息过期进死信，消费者监听死信）；② 延迟插件 rabbitmq-delayed-message-exchange；③ 更复杂定时调度用 xxl-job。项目里用于订单超时取消、批量发货的延迟重试。
- 积压/失败：配置死信队列、消费限流（prefetch）、失败重试次数 + 人工补偿入口。

评分要点

- **优秀**：讲清三段可靠性的具体手段 + 幂等的实现方式 + 延迟队列两种实现与选择依据。
- **及格**：能说出 confirm/ack/持久化与消费幂等。
- **不足**：认为"MQ 天然不丢不重"。

常见追问：1) 手动 ack 时业务处理完宕机了怎么办？2) 消息顺序性怎么保证？

【A2-29】【L3】消息积压排查与高可用原理

题目：线上消息积压了几百万条，怎么应急处理？Kafka 为什么吞吐高？

思考方向：先止血（扩容消费者/临时转存）再根治（找消费慢的根因）。

考察点：故障应急、中间件原理。

参考答案

- 积压应急：① 先定位是消费者数不足（队列数 < 消费者数）还是单条处理太慢（慢查询/外部调用超时）；② 紧急扩容消费者（增加并发消费线程/实例、增加队列与分区数）；③ 极端情况写临时“搬运消费者”把消息快速转存到新队列再慢慢消费；④ 临时降级非核心处理逻辑（跳过日志/统计），先追平积压。
- 根治：优化消费逻辑（批量、异步、加缓存）、设置消费限流避免拖垮下游、加监控告警（堆积量/消费 TPS）。
- Kafka 高吞吐原理：顺序写磁盘 + 页缓存（Page Cache）；零拷贝（sendfile 跳过用户态）；批量发送 + 压缩；分区并行。可靠性靠 ack 机制（0/1/all）与 ISR 副本同步。
- 选型：Kafka（高吞吐日志/流处理）、RocketMQ（事务消息、顺序消息、电商友好）、RabbitMQ（路由灵活、延迟队列、中小规模）。

评分要点

- **优秀**：给出“止血 + 根治”两步应急方案，讲清零拷贝/顺序写/ISR 原理与三者选型。
- **及格**：能说出扩容消费者 + 优化消费逻辑，知道 Kafka 顺序写与零拷贝。
- **不足**：只会说“重启消费者”。

常见追问：1) 消费者扩到比分区数还多有用吗？2) ack=all 的代价是什么？

方向三：Python AI 应用开发（A3，共 6 题）

【A3-01】【L2】Python 异步编程与 GIL

题目：Python 的 GIL 是什么？asyncio 和多线程在 AI 应用里怎么选？

思考方向：GIL 限制的是“多线程并行执行 CPU 密集代码”，不限制 IO 并发。

考察点：Python 并发模型。

参考答案

- GIL（全局解释器锁）：CPython 同一时刻只允许一个线程执行字节码，所以多线程无法并行跑满多核（CPU 密集无收益）。
- 但 IO 等待时会释放 GIL，所以多线程/协程对 IO 密集型仍有效；CPU 密集需多进程（multiprocessing）。
- asyncio：单线程事件循环 + 协程，靠 await 让出控制权，开销远小于线程，适合"大量并发等待外部 IO"的场景（AI 应用里最典型：并发调用大模型 API、向量库查询、工具调用）。
- 选择：AI 服务多为 IO 密集 → asyncio + 异步 HTTP 客户端（httpx/aiohttp）最合适；与同步 SDK 混用时要避免在协程里调用阻塞代码（用 run_in_executor 包装）。

评分要点

- **优秀**：讲清 GIL 只在字节码执行期生效、IO 会释放、以及"协程里别调阻塞函数"的坑。
- **及格**：能说出 GIL 概念与 asyncio 适合 IO 密集。
- **不足**：认为"Python 多线程没用/完全没用"。

常见追问：1) 协程里调用了阻塞库会怎样？2) 多进程方案在 AI 服务里的成本？

面试时可以按这四点回答：

1. GIL 是什么

GIL 是全局解释器锁。在启用 GIL 的 CPython 中，同一时刻只有一个线程执行 Python 字节码，因此纯 Python 的 CPU 密集型任务，通常无法通过多线程实现多核并行。

2. 为什么多线程处理 I/O 仍然有效

当线程遇到常见的阻塞 I/O 操作，比如等待网络返回、读写文件时，CPython 通常会在等待期间主动释放 GIL，让其他线程获得锁并继续执行。

例如，线程 A 正在等待模型 API 返回，线程 B 就可以发送另一个请求或处理数据。多个任务的等待时间可以重叠，所以 **I/O 密集型任务使用多线程完全是有效果的**。对于纯 Python 的 CPU 密集型任务，则可以考虑 multiprocessing 多进程。

3. asyncio 是什么

asyncio 通过单线程事件循环调度多个协程。协程在 await 等待异步 I/O 时，让出执行机会，事件循环就能运行其他协程。它通常比多线程调度开销更小，适合大量并发等待外部 I/O 的场景，例如调用大模型 API、查询远程向量库、调用外部工具。

4. AI 应用里怎么选

如果 AI 服务主要调用外部 API，我会优先选择 **asyncio + 异步 HTTP 客户端**，例如 httpx 或 aiohttp。如果必须使用同步 SDK，就通过 run_in_executor 将阻塞调用放到线程池。这里要注意：**同步 I/O 即使释放了 GIL，直接在协程里调用仍然会阻塞事件循环**，因此需要用异步客户端或线程池来处理。

【A3-02】【L2】LangChain 核心抽象

题目：LangChain 的核心组件有哪些？LCEL 是什么，为什么用管道符写法？

思考方向：把"提示词→模型→解析器→工具→记忆"抽象成可组合的组件。

考察点：LangChain 生态认知。

参考答案

- **核心抽象**：Models (LLM/ChatModel/Embeddings)、Prompts (模板 + 变量)、Output Parsers (结构化输出)、Tools & Agents、Memory (会话记忆)、Retrievers /VectorStores (RAG)、Callbacks (观测)。
- **LCEL (LangChain Expression Language)**：用 prompt | llm | parser 的管道符号把组件串成 Runnable 链；每个节点实现同一套 Runnable 接口 (invoke/stream/batch/ainvoke)，因此天然支持流式、批量、异步与重试/回退 (with_fallbacks)。
- **价值**：声明式组合、可复用、便于调试 (回调/追踪)，替代了过去晦涩的 Chain 子类继承体系。

评分要点

- **优秀**：讲清 Runnable 统一接口带来的"流式/异步/回退"能力，能对比旧版 Chain。
- **及格**：能列出主要组件并说清 LCEL 管道式组合。
- **不足**：只会说"LangChain 是用来做 RAG 的库"。

常见追问：1) LCEL 怎么加流式输出？2) LangChain 的 Memory 和 LangGraph 的状态有何区别？

面试时，可以直接这样回答：

LangChain 是构建大模型应用的框架，它把模型调用、提示词、输出解析、检索、工具调用和记忆等能力抽象成可组合的组件。

例如，一个基础问答流程可以由 Prompt、Model 和 Output Parser 组成；做 RAG 时，可以加入 Retriever 和 VectorStore；需要访问外部系统时，可以加入 Tools，由 Agent 决定如何调用。

LCEL 是 LangChain 的表达式组合方式，典型写法是 `prompt | model | parser`，前一步的输出传给后一步。它的核心是 Runnable 统一接口，让组件和组合后的链都能通过 `invoke`、`batch`、`stream` 及异步方法执行。

相比旧版通过继承 Chain 子类来定制流程，LCEL 更强调组件组合，方便复用、替换和调试，也能配置重试和失败回退。

图里的两个追问，可以这样接：

• “LCEL 怎么支持流式输出？”

调用 `stream()` 或 `astream()`，逐块消费结果。但端到端流式还取决于各组件能否传递流式数据；如果中间步骤必须等待完整结果，后续输出就会被延迟。**有流式接口，不代表任意链都能逐 token 输出。**[流式组合说明](#)

• “Memory 和 LangGraph state 有什么区别？”

经典 Memory 主要保存历史信息，并在后续调用时提供上下文；LangGraph state 是整个工作流的状态，范围更大，可以包含消息、工具结果和执行进度。短期记忆可以是 state 的一部分，通过 checkpointer 保存检查点。现在 LangChain Agent 也采用这种方式，因此两者并不是完全独立的两套机制。[新版短期记忆文档](#)

【A3-03】【L2】LangGraph 状态、节点、边与条件路由

题目：LangGraph 的 StateGraph 是什么？节点、边、条件边怎么用？和 LangChain 的 Chain 有什么本质区别？

思考方向：Chain 是"直线管道"，LangGraph 是"可循环的状态机图"。

考察点：Agent 工作流编排。

参考答案

- StateGraph：以共享的 State（TypedDict/自定义，可定义 reducer 合并策略）为核心的有向图；节点是函数（输入 State、返回 State 更新），普通边是固定流转，条件边按 State 判断走哪条分支。
- 与 Chain 的区别：Chain 是单向无环的管道，无法表达循环、分支与人工介入；LangGraph 支持循环（如"检索→评估→不达标则改写再检索"）、分支路由、以及运行中中断（interrupt），这才是 Agent 所需的控制流。
- 实践：多步 Agent 工作流（意图识别→工具选择→执行→结果校验→不足则重规划）非常适合用图表达；节点职责单一、便于测试与观测。

评分要点

- **优秀**：讲清 State 的 reducer 机制、循环与条件边的必要性，能举"检索-评估-重试"的例子。
- **及格**：能说清节点/边/条件边与"图可循环、Chain 不可"的区别。
- **不足**：以为 LangGraph 只是"LangChain 的新版本"。

常见追问：1) State 并发更新怎么合并？2) 怎么防止图里出现死循环？

StateGraph 是 LangGraph 中构建有状态工作流的核心类。它以共享 State 为基础，把任务拆成节点，再通过边定义执行顺序。

节点负责执行逻辑，例如检索、模型调用或结果评估，并返回状态更新；普通边定义固定流转，条件边根据状态选择下一步；各字段的 reducer 决定新旧数据如何合并。

比如检索问答场景，检索后评估资料，资料足够就生成答案，不足就改写问题并重新检索，这样形成循环。

相比简单的顺序 Chain，LangGraph 更侧重有状态工作流的控制流编排，适合循环、复杂路由，以及配合检查点实现人工暂停和恢复

- 与 Chain 的区别：Chain 是单向无环的管道，无法表达循环、分支与人工介入；LangGraph 支持循环（如"检索→评估→不达标则改写再检索"）、分支路由、以及运行中中断（interrupt），这才是 Agent 所需的控制流。
- 实践：多步 Agent 工作流（意图识别→工具选择→执行→结果校验→不足则重规划）非常适合用图表达；节点职责单一、便于测试与观测。

【A3-04】【L3】LangGraph Checkpointer 与人工介入

题目：LangGraph 怎么做状态持久化与断点续跑？interrupt 人工介入如何实现？

思考方向：Checkpoint 在每个节点后存档，thread_id 标识一次会话。

考察点：有状态编排、人机协同。

参考答案

- Checkpointer：配置（MemorySaver / SqliteSaver / PostgresSaver 等）后，图在每个节点执行后自动保存 State 快照，以 thread_id 作为会话标识；同一个 thread_id 可恢复、可回溯历史（time travel）。
- 价值：长流程中断后从断点继续、支持重放调试、多轮会话状态不丢；生产上 Checkpointer 要持久化到数据库/Redis，避免内存态丢失。
- 人工介入：在节点内调用 interrupt(payload) 暂停图并抛出待人工处理的信息，外部审批后用 Command(resume=...) 恢复执行；适用于"高风险工具调用审批""人工确认后再提交"等场景。
- 与 RAG 人工接管的关系：前者是"流程内的人审"，后者是"低置信兜底转人工"，可组合使用。

评分要点

- **优秀**：讲清"节点级快照 + thread_id 恢复 + interrupt/resume"的完整机制与生产持久化考量。
- **及格**：能说出 Checkpointer 保存状态、interrupt 暂停等人工。
- **不足**：不知道 LangGraph 有状态持久化能力。

常见追问：1) 恢复执行时外部依赖已变化怎么办？2) Checkpoint 数据量大了怎么清理？

我的回答

LangGraph 通过 **Checkpoint** 实现状态持久化。编译图时配置 Checkpointer，执行时传入 **thread_id** 标识会话或工作流，框架会按执行轮次保存 Checkpoint，包括 State 和后续执行信息。开发可以用内存实现，生产通常使用 Postgres 等持久化后端，保证进程重启后状态仍然保留。

断点续跑时，使用相同的 `thread_id`，通过 `graph.invoke(None, config)` 读取检查点并继续执行，不需要从头跑完整个流程。如果是故障恢复，需要先排除故障；如果要设置静态断点，可以配置 `interrupt_before` 或 `interrupt_after`。

人工介入通过 `interrupt(payload)` 实现。在需要审批的节点调用它，流程暂停，并把待审核信息返回给应用。人工处理后，用相同的 `thread_id` 调用 `graph.invoke(Command(resume=审批结果), config)`，审批结果会成为 `interrupt()` 的返回值，节点再根据结果继续执行。

需要注意，人工恢复时，包含 `interrupt` 的节点会从头执行，前面的代码可能重复运行，所以外部写操作要保证幂等，避免重复发邮件或重复创建订单。

【A3-05】【L2】Celery 异步任务与接口限流降级

题目：AI 服务里哪些逻辑应该异步化？Celery 怎么用？接口限流降级怎么做？

思考方向：把"耗时长且不阻塞用户"的任务拆出去，用消息队列解耦。

考察点：服务端工程化。

参考答案

- 应异步化的场景：文档解析/向量化入库、批量评测、报告导出、长时 Agent 任务、外部大模型批量调用；给用户先返回 `task_id`，前端轮询/推送进度。
- Celery：Producer 投递任务到 Broker（Redis/RabbitMQ），Worker 消费执行，Result Backend 存结果；支持重试、超时、定时（beat）、路由到不同队列。注意任务幂等与失败重试上限。
- 限流降级：按用户/IP/接口维度做令牌桶限流（Redis + Lua），超限返回 429；大模型调用设置超时与重试上限，失败降级到小模型/缓存/兜底话术；保护下游和成本。
- 与项目对应：文档入库、评测、批量导出这些"重活"都不应放在请求线程里同步做。

评分要点

- **优秀：**能准确判断哪些该异步化，讲清 Celery 队列/重试/幂等与限流降级的组合。
- **及格：**能说出用 Celery 处理耗时任务 + Redis 限流。
- **不足：**把所有逻辑都塞在接口里同步执行。

常见追问：1) 异步任务失败怎么通知用户？2) Celery 任务重复执行怎么防？

我的答案

我会根据用户是否需要即时结果来决定哪些任务异步化。像文档解析和向量入库、批量评测、报告导出、长时间 Agent 任务，都适合放到后台执行。

如果使用 Celery，接口作为生产者，把任务投递到 Redis 或 RabbitMQ，先返回 `task_id`；Worker 消费执行，保存任务状态和结果，前端通过轮询或推送获取进度。长短任务可以分到不同队列，避免长任务影响其他任务。

可靠性方面，我会设置任务超时，对临时异常做有限重试，并使用指数退避和随机抖动；同时保证业务幂等，避免重复执行造成重复入库。

接口入口用 Redis 加 Lua 做分布式限流，按用户控制请求，超限返回 429。模型调用还会限制并发、设置超时；持续失败时熔断，并根据业务切换到缓存、小模型或明确的失败提示。

【A3-06】【L2】微调：SFT / LoRA / QLoRA（非必背，看个人情况选择）

题目：讲一下 SFT、LoRA、QLoRA 的关系；LoRA 的 rank 和 alpha 是什么？微调后为什么会"灾难性遗忘"？

思考方向：从"全参微调太贵"引出参数高效微调（PEFT）。

考察点：微调基础（RAG 岗也常问，属于补强项）。

参考答案

- SFT：用标注的"指令-回答"数据做监督微调，让基座模型学会遵循指令与领域风格；全参微调显存/算力成本高。
- LoRA：冻结原权重，在注意力/FFN 旁路插入低秩矩阵 $A \times B$ 近似更新量 ΔW ，只训练这部分小参数；rank r 决定低秩矩阵的容量（越大越能拟合、参数越多）， α 是缩放系数（常按 α/r 缩放，控制更新幅度）。训练后可合并回原权重，推理无额外延迟。
- QLoRA：把基座模型权重用 4bit 量化（NF4）再加 LoRA 训练，显存大幅下降，可单卡微调大模型；代价是训练稍慢、量化有精度损失。
- 灾难性遗忘：只在小领域数据上微调会破坏模型原有的通用能力；缓解手段是混入通用数据、降低学习率/训练轮数、用 LoRA 只更新少量参数。
- 选型补充：知识类用 RAG，行为/风格/格式类优先 Prompt，确需固化能力或降本（训小模型）才微调。

评分要点

- **优秀：**讲清 LoRA 的低秩旁路原理、 r/α 作用、QLoRA 的 4bit 量化，以及遗忘的缓解；能给出"何时该微调"的判断。
- **及格：**知道 SFT/LoRA/QLoRA 是什么、LoRA 只训少量参数、QLoRA 省显存。
- **不足：**完全不了解微调（简历未体现，但面试常问，需补齐）。

常见追问：1) LoRA 加载到哪些层效果最好？2) 微调效果不达标怎么排查（数据/超参/评测）？

方向四：前端工程化与全栈（A4，共 8 题）

【A4-01】【L2】Vue3 响应式原理

题目：Vue3 的响应式是怎么实现的？和 Vue2 的 `Object.defineProperty` 比有什么优势？

思考方向：Proxy 拦截读写下依赖收集与派发更新，对比 `defineProperty` 的局限。

考察点：框架原理（简历写"了解 Vue 源码"必问）。

参考答案

- Vue3 用 Proxy 代理整个对象，配合 `effect()` 做依赖收集（track）与触发更新（trigger），依赖关系存在 `WeakMap` $\rightarrow$ `Map` $\rightarrow$ `Set` 的 `targetMap` 中。
- 对比 Vue2 的 `Object.defineProperty`：① 只能劫持已存在的属性，新增/删除属性需 `$set`，Proxy 能拦截 `get/set/deleteProperty` 等 13 种操作；② 无法直接监听数组下标与 `length` 变化（Vue2 靠重写数组方法），Proxy 天然支持；③ 惰性递归代理（访问到才代理嵌套对象），初始化性能更好。
- 衍生：ref 用 `RefImpl` 类 + `get value/set value` 拦截，reactive 用 Proxy；computed 基于 effect 惰性求值 + 缓存。

评分要点

- **优秀：**讲出 `targetMap` 依赖结构、Proxy 相较 `defineProperty` 的具体优势、ref/reactive/computed 的实现差异。
- **及格：**能说出 Vue3 用 Proxy、Vue2 用 `defineProperty` 及主要差异。
- **不足：**只会说"Vue3 性能更好"。

常见追问：1) 为什么 Vue3 还需要 ref？2) 依赖收集在什么时机进行？

【A4-02】【L1】虚拟 DOM 与 diff

题目：虚拟 DOM 是什么？为什么需要它？diff 算法的大致流程？

思考方向：用 JS 对象描述 DOM，减少真实 DOM 操作，跨平台。

考察点：前端框架基础。

参考答案

- 虚拟 DOM 是用 JS 对象 (VNode) 描述真实 DOM 结构，更新时先生成新 VNode 树再与旧树 diff，只把差异应用到真实 DOM，减少昂贵 DOM 操作次数，同时让渲染逻辑与平台解耦（可渲染到小程序/SSR）。
- diff 优化：同层比较（不跨层级）、Vue3 用 patchFlag 标记动态节点跳过静态内容、最长递增子序列复用 key 节点减少移动、Vue2 双端比较。
- 关键点：key 的作用是标识节点身份，用 index 作 key 在列表增删时会导致状态错位与多余更新。

评分要点

- **优秀：**讲清"同层比较 + patchFlag 静态提升 + 最长递增子序列"等优化与 key 的正确用法。
- **及格：**能说清虚拟 DOM 的作用与 diff 同层比较。
- **不足：**认为"虚拟 DOM 一定比直接操作 DOM 快"。

常见追问：1) 为什么用 index 当 key 不好？2) 虚拟 DOM 的缺点是什么？

【A4-03】【L2】首屏性能优化体系

题目：你项目把首屏加载降低 30%-50%，具体做了哪些优化？怎么衡量效果？

思考方向：按"资源体积、加载策略、渲染性能、接口"四层展开。

考察点：性能优化实战（简历量化点，必被深挖）。

参考答案

- 资源体积：路由懒加载 + 代码分割、Tree Shaking、按需引入（如 ECharts 按需）、gzip/brotli 压缩、图片压缩与 CDN、拆分 vendor。
- 加载策略：资源预加载/预连接、首屏关键资源优先、非关键组件异步、HTTP 缓存（强缓存 + 协商缓存）。
- 渲染性能：长列表虚拟滚动、图片懒加载（IntersectionObserver）、接口并发控制与请求缓存、骨架屏/loading 提升体感。
- 接口：合并请求、SSR/预渲染（若需 SEO）、接口响应裁剪。
- 衡量：Lighthouse/Performance 面板看 FCP/LCP/TTI、Performance API 打点统计真实用户指标（结合项目 Sentry 埋点）；对比优化前后数据。

评分要点

- **优秀：**分层次讲清手段，并说明"用什么指标衡量、怎么拿到 30%-50% 这个数字"。
- **及格：**能说出懒加载、压缩、虚拟滚动、缓存等常见手段。
- **不足：**只会说"图片压缩一下"。

常见追问：1) 首屏指标 FCP 和 LCP 的区别？2) 优化后数据怎么归因到具体手段？

【A4-04】【L2】瀑布流组件实现

题目：你的瀑布流组件怎么实现的？PC/移动端动态切换、图片预加载与懒加载切换怎么处理？

思考方向：计算最短列高度插入，配合容器宽度与列数动态计算。

考察点： 组件抽象、布局算法。

参考答案

- 核心算法：等分列（根据容器宽度与列数算每列宽度）→ 维护各列当前高度数组 → 每个新卡片插入当前最矮列 → 更新该列高度；用绝对定位或 flex 分列两种实现（分列更简单、绝对定位更省 DOM）。
- 响应式：监听容器 resize（ResizeObserver），重新计算列数（PC 多列、移动端两列）与布局；节流处理避免频繁重排。
- 图片：用占位宽高比先撑开高度避免抖动；IntersectionObserver 实现懒加载，进入视口前可预加载下一屏；加载完成回调触发重新布局（图片未加载完高度不准的经典问题）。
- 工程化：做成组件暴露 props（列数/间距/断点）与 slot，配 README 与示例页，作为组件库一员发布到私有 npm。

评分要点

- **优秀：** 讲清“最短列插入”算法、图片未加载导致高度抖动这一真实难点及解法。
- **及格：** 能说清分列 + 插入最矮列的基本思路。
- **不足：** 只能说“用 CSS column 实现”。

常见追问： 1) 大量卡片时性能怎么保证？ 2) 数据滚动加载（无限滚动）怎么和瀑布流配合？

【A4-05】 【L1】 IntersectionObserver 与懒加载

题目： 你怎么实现图片/长列表懒加载？ IntersectionObserver 相比 scroll 监听事件有什么优势？

思考方向： 浏览器原生交叉观察，异步回调、性能更好。

考察点： 浏览器 API、性能意识。

参考答案

- 实现：创建 IntersectionObserver，注册需要观察的元素；当元素进入视口（intersectionRatio > 0）时把 data-src 赋给 src 并 unobserve；可设 rootMargin 提前预加载。
- 优势：不依赖 scroll 事件，由浏览器在渲染线程外异步计算，不会因高频 scroll 触发大量回调导致卡顿；无需手动计算 offsetTop/getBoundingClientRect（后者会触发重排）。
- 工程：封装成 Vue 自定义指令 v-lazy，业务侧直接用；配合 loading 占位图与失败兜底；兼容性差的环境降级为 scroll + 节流。
- 价值：项目里大量图片（漫画/商品）场景显著减少首屏请求与流量。

评分要点

- **优秀：** 讲清“异步回调不阻塞主线程”的性能优势，并说明封装成指令与降级方案。
- **及格：** 能说清 IntersectionObserver 的用法与基本优势。
- **不足：** 只会用 scroll 事件 + 节流。

常见追问： 1) rootMargin 有什么用？ 2) 指令和组件的选择依据？

【A4-06】 【L2】 Render 函数动态 VNode 与命令式组件

题目： 你的 message/confirm 组件用 Render 函数实现，具体怎么做的？为什么这类组件适合命令式调用？

思考方向： 把组件实例挂载到动态创建的容器上，返回 Promise。

考察点： Vue 渲染机制、API 设计能力。

参考答案

- 命令式调用：Message.success('xx') 直接在 JS 里弹出提示，不必在模板里写标签；适合 toast/确认框这类"用完即走、与页面结构无关"的 UI。
- 实现：在调用时动态 createElement 一个容器挂到 body → 用 render(h(Comp, props), container) 或 createVNode + render 把组件实例渲染进去 → 组件内部通过 Transition 做动画 → 关闭时调用 render(null, container) 卸载并移除容器节点，避免 DOM 泄漏。
- confirm 返回 Promise，resolve/reject 对应确定/取消，方便 await 写法；多个实例用容器数组管理、指定 zIndex 层级；同一时刻可只保留一个实例（单例）或允许多个（栈管理）。
- 关键：手动卸载 + 清理引用是这类组件最容易漏的内存泄漏点。

评分要点

- **优秀**：讲清动态挂载/卸载流程、Promise 化 API 设计、以及 DOM 泄漏的防范。
- **及格**：能说清"动态创建容器 + render 渲染 + 用完卸载"。
- **不足**：只会说"用 Render 函数创建 VNode"。

常见追问：1) 用 h 函数和用 template 有性能差异吗？2) 多个 message 同时弹出怎么管理？

【A4-07】【L2】Webpack 构建优化

题目：你在项目里做的 Webpack 优化有哪些？Tree Shaking 生效的前置条件是什么？

思考方向：体积、速度两条线；Tree Shaking 依赖 ESM 静态分析。

考察点：构建工具实战。

参考答案

- 体积优化：splitChunks 拆分 vendor 与业务代码、Tree Shaking、gzip/brotli 压缩、按需加载（路由级）、Externals/CDN、去除无用依赖与包分析（webpack-bundle-analyzer）。
- 速度优化：持久化缓存/文件系统缓存、多线程（thread-loader）、缩小 resolve 范围与 exclude、DLL/预先编译依赖、开发环境减少 sourcemap 开销。
- Tree Shaking 前置条件：① 必须是 ES Module 语法（import/export），CommonJS 无法静态分析；② 生产模式 + sideEffects:false 标记；③ 代码无副作用、未被打包工具"保住"；④ 库需要提供 ESM 产物（看 package.json 的 module 字段）。
- ECharts 按需：import 具体图表模块而非整体引入，减小打包体积。

评分要点

- **优秀**：讲清 Tree Shaking 的多个前置条件、splitChunks 策略与缓存提速，能结合体积/速度两条线。
- **及格**：能说出 splitChunks、gzip、Tree Shaking 等常见手段。
- **不足**：只会说"开了 gzip"。

常见追问：1) Vite 为什么开发快？2) 构建体积和运行性能有冲突吗？

【A4-08】【L2】小程序性能与多接口并发

题目：微信小程序的包体积和性能怎么优化？多个接口并发请求怎么管理？

思考方向：主包/分包、组件化、setData 优化、请求封装。

考察点：小程序工程化。

参考答案

- 包体积：主包只放核心页面，非核心页面分包/独立分包、分包预下载；图片走 CDN 不打包；代码压缩与资源压缩；及时清理无用代码与重复依赖。

- 渲染性能：减少 setData 的数据量与频次（只传变化的最小字段，避免大对象整体 setData）、长列表用官方 recycle-view 或虚拟列表、避免频繁跨线程通信。
- 组件化：封装商品卡片、轮播图、分类导航等通用组件（项目里已做），复用提升可维护性。
- 多接口并发：用 Promise.all 并发拉取并统一 loading/错误兜底，避免"接口瀑布"串行等待；对失败接口做局部降级（不阻塞整体渲染）；封装统一请求层处理鉴权、重试、loading 与错误提示。

评分要点

- **优秀**：讲清分包策略、setData 的性能陷阱、以及"并发 + 局部降级"的接口管理。
- **及格**：能说出分包、setData 优化、Promise.all 并发。
- **不足**：只会说"用小程序框架开发"。

常见追问：1) 小程序主包 2M 限制怎么突破？2) 接口全部失败时页面该怎么表现？

B. 项目深挖题 共 17 题

项目一：企业智能问答 Agent（B1，5 题）

【B1-01】【L3】为什么用"混合召回 + RRF + Rerank"三件套

题目：你简历写"BM25 + 向量混合召回 → RRF 融合 → Rerank 精排"，为什么不是只用向量检索？这三步各自解决什么问题、怎么证明有效？

思考方向：从销售的提问特点（既有口语化描述、又有商品型号/健康术语）切入，说明单一召回的漏召回问题。

考察点：RAG 检索策略设计、方案论证能力。

参考答案

- 销售提问里既有口语化表达（"这个吃了会不会上火"→ 需语义理解），又有精确实体（商品型号、成分名称、代码类名词 → 需关键词精确匹配）。纯向量对实体/型号不敏感，纯 BM25 不解语义，都会漏召。
- 三步分工：混合召回"提召回"（宁可多召回不能漏）→ RRF"把两路按排名融合"（规避量纲问题，鲁棒）→ Rerank"精排提相关性"（cross-encoder 交互打分，把最相关的顶上来）。
- 有效性证明：用离线评测集对比"纯向量 / 纯BM25 / 混合 / 混合+Rerank"几组配置的 Recall@K、MRR、Faithfulness，看指标提升；再用线上"一次答准率"验证。
- 代价意识：Rerank 会引入额外延迟，本项目 2s 内可接受，若延迟敏感需缩减候选数或换轻量模型。

评分要点

- **优秀**：能用业务问题说明单一召回的缺陷，讲清三步分工与"用指标对比验证"的方法，有延迟代价意识。
- **及格**：讲清混合召回互补、RRF 融合、Rerank 精排的作用。
- **不足**：只说"这样效果更好"，讲不出验证方式与代价。

常见追问：1) 如果向量召回结果全错，RRF 能救回来吗？2) Rerank 候选数（TopK）定多少，依据是什么？

【B1-02】【L3】语义分块 + 父子文档的参数与"85% 一次答准率"的口径

题目：你的"语义分块 + 父子文档"具体参数怎么定的？简历里"高频问题一次答准率提升至约 85%"，这个数是怎么统计出来的？

思考方向：诚实说明统计口径（样本、判定方式、分母），并解释分块实验如何做。

考察点：数据可信度、实验方法（高频追问“数据来源”）。

参考答案

- 口径必须说清：从业务真实问题里抽 N 条（如 200~500 条）高频问题，人工/双人标注标准答案，答对=答案与标准答案要点一致且无编造，“一次答准率=首轮回答即正确的问题数 / 总问题数”；分母是测试集样本而非线上全部对话。
- 分块实验：控制变量，只改策略（固定分块 vs 语义分块、chunk size 300/500/800、overlap 10%/20%），跑同一评测集看 Recall@K / MRR / Faithfulness，选 Pareto 最优；父子文档用“子块（约 200~400 token）检索 + 父块（段落/章节）喂模型”。
- 对比基线：优化前（固定分块 + 纯向量）的答准率作为基线，优化后提升到 85%，能说清每一步贡献多少。
- 坦诚：若 85% 是“高频问题”这一子集的口径而非全量，务必主动说明，避免面试官追问时被认为夸大。

评分要点

- **优秀：**能准确说出统计口径、样本量与优化前后对比，主动交代口径边界。
- **及格：**能说清“用评测集抽样 + 人工判定”的统计方式。
- **不足：**支支吾吾说“大概估的”“感觉这样差不多”，是扣分重灾区。

常见追问：1) 标注由谁做、一致性怎么保证？2) 评测集会不会被反复调参“过拟合”？

【B1-03】【L2】“平均检索响应延迟控制在 2s 以内”怎么做到的

题目：全链路（改写 + 双路召回 + RRF + Rerank + 大模型生成）要在 2s 内完成，你怎么优化的？瓶颈在哪？

思考方向：拆解各阶段耗时，定位大头（通常是模型生成与 Rerank）。

考察点：性能优化、链路分析能力。

参考答案

- 先量化各段耗时（埋点打点）：query 改写、向量检索、BM25、RRF、Rerank、模型生成，找出大头。
- 优化手段：① 双路召回并行执行而非串行；② 缓存（热点问题语义缓存直接返回、Embedding 结果缓存）；③ 用流式输出让“首 token 时间”替代“全量生成时间”，用户感知延迟大幅下降；④ 控制 Rerank 候选数与模型大小；⑤ 向量库建 HNSW 索引、Metadata 前置过滤减少扫描；⑥ 模型侧用更快的模型或小模型路由。
- 说明：2s 是“检索链路 + 首字返回”的口径还是“完全生成完”的口径，要讲清楚——这是面试官最可能追问的点。

评分要点

- **优秀：**先打点定位瓶颈再谈优化，能讲清流式与缓存的作用，并主动澄清延迟口径。
- **及格：**能说出并行、缓存、流式、索引优化等手段。
- **不足：**只答“用了缓存”，没有量化。

常见追问：1) Rerank 占了多少毫秒？2) 缓存命中率和一致性怎么处理？

【B1-04】【L2】Function Calling 打通线上代码仓库 + MCP 接入层

题目：知识库命中不足时自动调用“线上代码仓库/业务接口”，这个工具怎么设计的？MCP 封装又带来了什么？

思考方向：工具描述设计、权限与安全、何时触发。

考察点： 工具调用落地、工程化。

参考答案

- 工具设计：明确 name/description/参数 schema（如代码仓库检索需要 repo、关键词、分支等参数），描述里写清"什么时候该用这个工具"，直接决定模型选工具的准确率；返回值做截断与结构化，避免超长上下文。
- 触发时机：RAG 检索低于阈值或问题涉及"代码/实时数据"时，由 Agent 决策调用；工具结果与大模型生成结果共同组织答案。
- 安全：代码仓库只读、限定可访问仓库范围、鉴权走服务端（不把凭证交给模型）、限流防刷；返回内容做敏感信息过滤。
- MCP 的价值：把模型、工具、数据源统一到标准化接入层，新增工具只需起一个 MCP Server，宿主端无需改代码；对外暴露标准化问答接口，便于与其他业务系统集成。

评分要点

- **优秀：** 讲清工具描述对选择准确率的影响、只读+服务端鉴权的安全设计、MCP 标准化接入带来的可扩展性。
- **及格：** 能说清工具定义方式与"命中不足才调用"的逻辑。
- **不足：** 只说"配了个工具让它去查代码"。

常见追问： 1) 工具返回结果太长怎么处理？ 2) 模型选错工具怎么办，有没有兜底？

【B1-05】 【L3】 ReAct + Plan-and-Execute + 持久化记忆如何协同

题目： 你项目同时提到 ReAct、Plan-and-Execute 和持久化记忆，三者在一个问答 Agent 里怎么配合？会不会过度设计？

思考方向： 分层使用：简单问题走轻路径、复杂任务走规划路径、记忆做横向支撑。

考察点： 架构合理性判断、避免炫技。

参考答案

- 流程：意图识别先做分流——简单知识问答直接走"检索→生成"轻路径（快）；多步任务（如"查出某商品近三月销量并对比趋势"）才升级为 Plan-and-Execute，规划出多个子步骤（查询/统计/汇总），每步内部用 ReAct 调工具。
- 记忆贯穿：短期记忆（会话上下文，Redis 按 sessionId）保证多轮指代消解；长期记忆（用户偏好、历史重要事实）存向量库，按需召回注入，实现个性化。
- 避免过度设计：默认走最简单的可行路径，只有任务确实需要多步时才动用规划；规划会带来额外模型调用（成本/延迟），必须用数据证明收益。
- 演进：这套分层为后续"流程自动化"预留了工具接入位，可平滑扩展。

评分要点

- **优秀：** 讲清"分层路由 + 轻路径优先"的取舍，主动指出多步规划的额外成本。
- **及格：** 能说清三者各自职责与基本配合方式。
- **不足：** 把三个概念堆在一起，说不清谁在什么时机用。

常见追问： 1) 意图识别用规则还是模型？误判怎么挽回？ 2) 长期记忆写入标准是什么？

项目二：企业 ERP 综合管理系统（B2，4 题）

【B2-01】 【L2】 订单查询 1s → 300ms：线程池并行 + Future 汇总

题目： 你把串行调用客户/商品/发货信息改成并行，接口耗时从 1s 降到 300ms，具体怎么做的？线程池怎么配？为什么用 Future 而不是 CompletableFuture？

思考方向：先说明原来串行的耗时叠加，再讲并行改造与超时兜底。

考察点：并发优化实战、参数调优。

参考答案

- 原问题：三个远程调用串行，耗时 = $T1+T2+T3 \approx 1s$ ；改为并行后耗时 $\approx \max(T1,T2,T3) \approx 300ms$ ，本质是"把等待时间重叠起来"。
- 实现：用业务隔离的固定线程池提交三个 Callable，拿到 Future 后统一 get（带超时），再组装订单详情 DTO。
- 线程池配置：按"并发量 × 单任务耗时"估算核心数，IO 密集型可配较大（如 20~50），使用有界队列 + 命名线程工厂 + 业务独立线程池，避免与其他业务互相拖垮，也便于排查。
- Future vs CompletableFuture：Future 只能阻塞 get，无法链式编排；CompletableFuture 支持 thenCombine/allOf 等组合与异步回调，更适合复杂编排。本项目三路无依赖，用 Future + 一起 get 已足够，不必过度设计；若要加超时降级推荐 allOf + orTimeout。
- 兜底：单个子调用超时/失败时，该部分返回默认值而不是整体失败，保证主流程可用。

评分要点

- **优秀：**讲清并行原理与线程池配置依据、有界队列、业务隔离，并说明 Future/CompletableFuture 的选型理由。
- **及格：**能说清"并行替代串行、耗时取最大值"。
- **不足：**只说"用了多线程所以快了"，线程池参数说不清。

常见追问：1) 线程池打满会怎样，怎么监控？2) 三路里某一路超时，返回的数据怎么保持一致？

【B2-02】【L2】批量发货异步任务与失败重试

题目：批量订单发货拆成"任务批次 + 订单明细"、支持异步执行与失败重试，数据模型和状态机怎么设计的？重试怎么保证不重复发货？

思考方向：主任务表 + 明细表 + 状态字段 + 幂等键。

考察点：异步任务设计、幂等。

参考答案

- 数据模型：批次表 (batch_id、总数、成功数、失败数、状态、创建人/时间) + 明细表 (batch_id、order_id、状态、失败原因、重试次数)。
- 流程：提交后立即返回 batch_id → 后台按批次消费（线程池/消息队列），逐条处理并更新明细状态与进度 → 前端按 batch_id 轮询进度。
- 幂等：每条明细有唯一键 (batch_id + order_id)，处理前先判状态（已成功则跳过），数据库唯一索引兜底，保证重试不会重复发货。
- 重试：只重试"失败态"明细，设置最大重试次数，超过转人工；失败原因结构化记录（库存不足/地址异常/系统超时），便于运营分类处理。
- 异常：批次级别做"可中断可续跑"，服务重启后能恢复未完成批次（状态扫描 + 定时补偿）。

评分要点

- **优秀：**讲清两级表结构与状态机、幂等键设计、重试与人工兜底、以及重启恢复方案。
- **及格：**能说清"批次+明细 + 异步执行 + 失败记录重试"。
- **不足：**只说"开了个线程池循环处理"，无状态与幂等设计。

常见追问：1) 批量任务很大时内存怎么控制？2) 同一个订单被两个批次包含怎么办？

【B2-03】【L3】多口径指标一致性（订单金额/签收业绩/财务利润）

题目：你负责统一处理"订单金额、签收业绩、财务利润"三个口径的指标，这三个口径为什么容易不一致？怎么保证数出一致？

思考方向：同一笔订单在不同口径下的计算规则不同（时间归属、退款、成本），关键是把规则收敛到一处。

考察点：业务理解、数据一致性治理。

参考答案

- 不一致根因：① 取值时间不同（下单时间 vs 签收时间 vs 财务确认时间）；② 是否含退款/优惠券/运费/赠品；③ 成本口径（含税/不含税、分摊方式）；④ 各模块各算一遍导致逻辑分叉。
- 治理：口径统一到指标定义——把三个指标的计算规则写成明确文档（公式 + 过滤条件 + 时间口径），在后端做统一的指标计算服务/视图，各模块调用同一计算逻辑，禁止各写各的 SQL。
- 数据层：明细表保留原始字段（金额、退款、成本、各关键时间点），指标在查询/聚合时按统一口径计算；对账场景用定时任务比对两套口径差异并告警。
- 验证：与财务/运营对账，抽样核对；差异可下钻到具体订单定位。

评分要点

- **优秀：**能从时间/退款/成本三方面说清口径差异根因，提出"统一指标定义 + 单一计算入口 + 对账告警"的治理方案。
- **及格：**能说清不同口径差异在哪，并知道要统一规则。
- **不足：**只答"按需求写的 SQL"，无治理思路。

常见追问：1) 口径变更后历史数据怎么办？2) 指标计算放数据库还是应用层，为什么？

【B2-04】【L2】Redis 主从读写分离在 ERP 的落地与坑

题目：ERP 里品牌/商品/订单高频缓存做读写分离，具体怎么改的？改造后遇到过什么问题？

思考方向：写主读从的收益 + 延迟/连接/序列化等工程问题。

考察点：缓存架构落地经验。

参考答案

- 落地：Spring 侧配置主从连接（Lettuce 主从读写分离或 Redisson 主从配置），读操作路由到从节点，写/删除走主节点；本地二级缓存（Caffeine）扛超热数据。
- 收益：主节点读压力下降、读吞吐提升，写不受读流量影响。
- 坑：① 主从延迟导致刚写后立刻读可能读到旧值 → 对"刚操作完立刻回显"的场景强制读主（如订单详情）；② 缓存的 key 设计要包含租户/维度避免互相覆盖；③ 从节点故障需有降级（直连主节点）；④ 大对象序列化开销（可换 JSON/压缩）。
- 配套：缓存失效策略（写后删缓存）、空值缓存防穿透、过期时间加随机防雪崩。

评分要点

- **优秀：**讲清读写路由配置与"读己之写"的处理，能举出真实踩坑。
- **及格：**能说清写主读从与延迟问题。
- **不足：**只会说"配一下就好了"。

常见追问：1) 读写分离后事务里的读怎么走？2) 怎么监控主从延迟？

项目三：美容美体网电商平台（B3，4 题）

【B3-01】【L3】"按商品 ID 加锁 + 二次检查"解决缓存击穿

题目：你把"全局锁"改成"按商品 ID 维度加锁 + 二次检查缓存"，为什么？全局锁有什么问题？二次检查为什么必要？

思考方向：锁粒度决定并发度；DCL 思想的缓存版本。

考察点：并发控制粒度、缓存击穿治理。

参考答案

- 全局锁问题：所有商品共用一把锁，访问商品 A 的请求会阻塞访问商品 B 的请求 → 无关的请求互相排队，吞吐极低；商家/用户量大时表现为整体接口变慢。
- 改造：锁 key 加商品 ID 维度（分布式锁 key = lock:product:{id}，或本地锁分段），不同商品互不阻塞，只保证"同一商品的回源串行"。
- 二次检查（DCL）：拿到锁后再查一次缓存——因为在等锁期间，前一个请求可能已经把数据加载进缓存了，此时直接返回即可，避免重复回源 DB（否则 N 个请求只是串行地逐个查库，锁的意义打折）。
- 注意：锁要设过期时间防死锁；加锁失败可直接返回旧值/降级，不必全部阻塞；热点商品可用逻辑过期避免锁竞争。

评分要点

- **优秀：**讲清锁粒度与并发度的关系、二次检查的必要性，并提到逻辑过期等进阶方案。
- **及格：**能说清按 ID 加锁提升并发、二次检查防重复回源。
- **不足：**只会说"加了锁就好了"，说不清为什么要二次检查。

常见追问：1) 锁 key 用什么结构（Redis 分布式锁 vs 本地锁）？2) 商品是爆款（超热）时这套方案还够用吗？

【B3-02】【L2】下单接口限流降级：Redis 原子计数 + 429

题目：你用"已认证用户 ID + 接口"为限流键、Redis 原子计数实现多实例共享配额（每用户每 10 秒不超过 2 次），具体怎么实现？为什么限流键要带接口？

思考方向：INCR + EXPIRE（或 Lua 原子）实现固定窗口计数，多实例共享。

考察点：限流实现、多实例一致性。

参考答案

- 实现：key = rate:{userId}:{api}，用 Lua 脚本原子执行"INCR + 首次设置 EXPIRE(10s)"，返回值 > 2 则拒绝并返回 HTTP 429 + 提示。多实例部署时共享同一个 Redis 计数，天然实现全局限额。
- 为什么带接口维度：不同接口的成本/风险不同（下单比查询敏感），如果只按用户限流会"一刀切"，误伤正常查询；带接口维度可对高风险接口单独收紧。
- 注意点：① 必须用 Lua 保证 INCR 与 EXPIRE 原子，否则进程崩溃会留下永不过期的 key；② 固定窗口存在临界问题（第 10 秒与第 11 秒各 2 次 → 2 秒内 4 次），严格场景可用滑动窗口/令牌桶；③ 限流要区分"刷单"和"正常重试"，返回体要给出友好提示与重试引导；④ 已认证用户 ID 作为键前提是登录态可靠，未登录用户需降级用 IP + 设备指纹。
- 效果：拦截刷单与重复提交，保护下单链路库存。

评分要点

- **优秀：**讲清 Lua 原子性、固定窗口临界问题、键维度设计理由与未登录降级。
- **及格：**能说清 Redis 计数 + 过期 + 多实例共享。

- **不足**：只会说"用 Redis 计数限流"，说不清原子性。

常见追问：1) 固定窗口临界突刺怎么解决？2) 限流误伤正常用户怎么申诉/白名单？

【B3-03】【L3】强制刷新分流 + 鉴权，避免"删缓存-重新回源"风暴

题目：你设计了"商品详情普通访问与强制刷新分流限流、刷新入口加鉴权"，要防的是什么风险？

思考方向：强制刷新是"删缓存 + 回源"的高危操作，被滥用会造成缓存雪崩/回源风暴。

考察点：缓存治理、安全与滥用防护。

参考答案

- **风险**：强制刷新会删掉缓存并触发回源。如果普通用户可随意触发，恶意或误操作会瞬间把大量商品缓存打掉 → 请求全部打到 DB（回源风暴），即"人为制造的缓存雪崩"。
- **防护**：① 接口分流——普通访问走缓存不动缓存，强制刷新走独立入口；② 刷新入口加鉴权（仅运营/管理员，RBAC 校验），普通用户不可调用；③ 限流——对刷新入口按用户/接口限频，限制单位时间内的刷新次数；④ 刷新后温数据（异步重建）避免下次访问再回源。
- **延伸**：类似思路适用于任何"人工触发缓存失效"的入口（后台运营工具都应有权限 + 限流 + 审计）。
- **价值**：把"高风险运维动作"与"普通读流量"解耦，既保证运营能更新数据，又不让系统被误伤。

评分要点

- **优秀**：讲清"人为缓存雪崩"这一本质风险，给出分流+鉴权+限流+异步重建的组合防护。
- **及格**：能说清加权限和限流是为了防滥用。
- **不足**：只说"加了个刷新按钮"。

常见追问：1) 运营批量刷新上千商品怎么防？2) 刷新后新老缓存并发不一致怎么处理？

【B3-04】【L2】优惠券/满额赠品/藏宝岛分支的交易逻辑

题目：购物车结算里"满额赠品 + 优惠券可使用范围 + 藏宝岛特殊订单分支"，规则冲突时怎么处理？怎么防止优惠叠加出错？

思考方向：把促销规则做成可配置 + 明确优先级 + 服务端统一计算。

考察点：复杂业务规则设计。

参考答案

- **规则建模**：把优惠券适用条件（订单金额门槛、商品范围/品类、时间、是否叠加）做成配置，结算时按明确优先级顺序依次计算（如 先商品级优惠 → 再订单级券 → 最后满额赠品），并给出可解释的"优惠明细"。
- **防错**：金额一律服务端计算，前端只做展示与预估，防止篡改；下单时二次校验（券是否可用、库存是否足够、活动是否结束），校验通过才锁券/锁库存。
- **赠品**：赠品数量与门槛校验在服务端做，赠品库存单独扣减，赠完即止；避免"先赠后算价"导致金额不对。
- **特殊分支（藏宝岛）**：用策略模式按订单类型路由到不同处理链，避免把特殊逻辑散落在主流程里，降低回归风险。
- **一致性**：下单 + 扣库存 + 核销券放在事务/最终一致方案里，超时未支付要回滚库存与券。

评分要点

- **优秀**：讲清规则优先级、服务端统一计算与二次校验、特殊分支用策略模式隔离。
- **及格**：能说清优惠规则配置化 + 服务端校验 + 赠品门槛校验。
- **不足**：只会说"写了很多 if-else"。

常见追问：1) 优惠券可叠加时金额怎么算才不出错？2) 超卖/超赠怎么防？

项目四：自研组件库（B4，2 题）

【B4-01】【L2】组件库 0-1 建设：20+ 组件沉淀与私有 npm 发布

题目：组件库从 0 到 1 你做了哪些关键决策？多个后台系统与 H5 复用同一套组件，样式和构建怎么处理？

思考方向：项目结构、构建产物、样式隔离、版本与发布。

考察点：前端工程化与抽象能力。

参考答案

- 结构：单仓库（monorepo 或单包 + 分类目录），按基础组件（button/dialog/message）与业务组件（瀑布流、虚拟任务栈）分层；提供统一入口与按需引入。
- 构建：Vite/Rollup 打包 ES + CJS 双产物，外部依赖（Vue 等）作为 peerDependencies 不打包，产出类型声明（TS），支持按需加载与 Tree Shaking。
- 样式：Tailwind 基础类 + 组件内部作用域样式；暴露 CSS 变量支持主题定制，避免污染业务全局样式。
- 发布与治理：私有 npm 平台（如 Verdaccio）发布，语义化版本（SemVer），写 README + 示例页 + Changelog；用 ESLint/Prettier/Husky 保证提交规范与代码一致性。
- 价值：20+ 组件让多个后台与 H5 项目复用，减少重复开发、统一交互体验。

评分要点

- 优秀：讲清双产物/peerDependencies/Tree Shaking 等工程细节与版本治理。
- 及格：能说清组件分层、私有 npm 发布、按需引入。
- 不足：只会说“写了很多组件”。

常见追问：1) 组件升级如何不破坏使用方？2) 怎么做组件的自动化测试（覆盖率 85% 那类指标）？

【B4-02】【L2】虚拟任务栈 + KeepAlive 模拟 APP 跳转

题目：你用“自定义栈逻辑 + KeepAlive + Transform”实现 H5 页面跳转的 APP 效果，具体怎么做的？和浏览器原生 history 有什么冲突？

思考方向：维护自己的页面栈，配合转场动画与缓存。

考察点：SPA 路由与缓存机制。

参考答案

- 目标：在 H5 里模拟原生 APP 的“进入向右滑入、返回向左滑出”以及“返回时保留上一页状态”。
- 实现：维护一个页面栈数组（push/pop），每个页面记录方向（forward/back）；用 KeepAlive 缓存页面组件避免重建丢失滚动位置与表单；返回时先播动画再出栈，前进时反之；用 CSS transform + transition 做位移过渡。
- 与 history 冲突：用户按浏览器返回键或物理返回会绕过自定义栈 → 需监听 popstate 同步栈状态（或用 hash/history 与自定义栈双向绑定），否则会出现“动画与路由不一致、页面栈错乱”。
- 缓存治理：KeepAlive 无限缓存导致内存膨胀 → 设置最大缓存数（max）或只缓存必要页面，出栈时移除。

评分要点

- 优秀：讲清自定义栈与浏览器 history 的同步难点（popstate）、KeepAlive 内存治理。
- 及格：能说清页面栈 + KeepAlive + 动画的基本实现。
- 不足：只能说“用了 KeepAlive 缓存页面”。

常见追问：1) KeepAlive 缓存过多怎么办？2) 从缓存页返回后怎么刷新数据？

项目五：一番赏 ONLINE (B5, 2 题)

【B5-01】【L2】Sentry + 自定义埋点数据体系

题目：你用 Sentry + 自定义埋点统计用户操作，为经验值/成就系统与后台分析提供数据，埋点是怎么设计的？怎么保证数据不丢不乱？

思考方向：埋点模型、上报时机与方式、异常监控与业务埋点的职责区分。

考察点：前端数据链路设计。

参考答案

- 职责区分：Sentry 负责错误/异常/性能监控 (JS 报错、接口失败、白屏、慢加载)，通过 sourcemap 还原堆栈；自定义埋点负责业务行为 (进入页面、点击、下单、完成任务)。
- 埋点设计：统一埋点方法 (事件名 + 业务参数 + 用户标识 + 时间戳 + 页面路径)，集中定义事件枚举避免命名混乱；关键路径 (支付、任务完成) 加入唯一 ID 便于去重与归因。
- 上报可靠性：批量 + 延迟上报 (如队列攒够 N 条或定时 flush) 减少请求；页面卸载用 sendBeacon/keepalive 保证最后一批不丢；失败本地暂存重试。
- 性能：高频事件 (滚动、曝光) 用防抖/节流 + 采样，避免埋点本身拖垮页面 (项目里对高频埋点做了防抖节流)。
- 数据消费：经验值/成就规则基于事件流计算，后台做漏斗与留存分析。

评分要点

- **优秀：**讲清异常监控与业务埋点的分工、批量/beacon 上报保障、以及埋点自身的性能治理。
- **及格：**能说清理点要素与上报方式。
- **不足：**只会说"接了 Sentry"。

常见追问：1) 埋点数据怎么和"经验值系统"对账？2) 埋点采样后统计口径会不会失真？

【B5-02】【L2】访问速度提升 1.3s 与 blurify 差分、多端适配

题目：一番赏项目里"访问速度提升 1.3s"和"blurify 分辨率差分实现未登录/登录/VIP 区分"，这两件事具体怎么做、怎么量化？

思考方向：性能优化手段 + 资源分级加载策略。

考察点：性能量化、资源策略设计。

参考答案

- blurify 差分：对大量图片做模糊处理作为低清预览 (不同用户等级展示不同清晰度——未登录看模糊图、登录/VIP 看清晰图)，既控制资源版权/成本，又通过"先模糊占位再替换高清"改善首屏观感。实现上按用户身份决定加载哪一档资源，配合懒加载避免一次性请求大量高清图。
- 1.3s 提升来源：① 图片懒加载 (IntersectionObserver + 自定义指令) 避免首屏请求全部漫画图；② 埋点与高频函数防抖/节流；③ ECharts 按需引入 + Tree Shaking 减少体积；④ 多端适配 (安全区/Rem/ViewPort、媒体查询) 减少无谓重排；⑤ 路由/资源分包。
- 量化：用 Performance API / Lighthouse 采集优化前后指标 (如 FCP/LCP、完全加载时间)，对比得出 1.3s 提升；说明测试环境与样本。
- 诚实口径：要明确 1.3s 是"某关键页面"还是"全站平均"，避免夸大。

评分要点

- **优秀：**讲清差分资源的用户分级策略与"模糊占位"体验价值，并说明性能数字的采集方式与口径。

- **及格**：能说清图片懒加载、按需引入等优化手段。
- **不足**：只说"优化了图片"，说不出量化方法。

常见追问：1) 模糊图转高清图怎么避免闪烁？2) 多端适配中遇到过什么具体兼容坑？

C. 场景 / 系统设计题 共 4 题

【C-01】【L3】设计企业级多租户 RAG 知识问答平台

题目：基于你做的企业问答 Agent，设计一个可服务多个部门/多租户、支持知识库版本管理与权限隔离的 RAG 平台，给出架构与关键决策。

思考方向：按"接入层 → 应用编排 → RAG 检索 → 存储 → 治理"分层，重点讲隔离、更新与评测。

考察点：RAG 系统工程化、多租户与可运维性。

参考答案

- 接入层：网关统一鉴权 (JWT/OAuth2) + 限流 + SSE 流式；按租户/部门路由到独立配额。
- 应用编排：意图识别 → 查询改写 (Rewrite/HyDE) → 混合召回 → RRF → Rerank → 生成 → 引用标注/拒答；低置信转人工。用状态机或 LangGraph/AgentScope 编排，会话上下文存 Redis。
- 检索与存储：Milvus 向量库 + BM25 引擎；chunk 带 tenant/dept/role/密级 元数据，pre-filter 做权限隔离；小规模租户可 PGVector，超大租户可独立 collection。
- 知识治理：离线 Pipeline (解析/清洗/语义分块/父子文档/向量化/入库) + 增量更新 (文档变更事件驱动)；版本管理 (知识库按版本快照，支持灰度切换与回滚)；删除要同步清向量。
- 评测与运维：评测集 + RAGAS 指标回归 (每次知识库/参数变更都跑)；线上监控 (召回率、Faithfulness、拒答率、转人工率、P95 延迟、token 成本)；Badcase 闭环归因。
- 成本：语义缓存、小模型预筛、Rerank 候选数控制、按租户配额与计费。

评分要点

- **优秀**：pre-filter 隔离、版本管理与回滚、评测驱动迭代、成本配额——四点齐备。
- **及格**：架构分层完整，讲清权限隔离与更新机制。
- **不足**：只画"文档→向量库→检索→回答"的框图，无隔离/版本/评测/成本。

常见追问：1) 文档删除后向量怎么同步清？2) 知识库更新如何做灰度不翻车？

【C-02】【L3】设计支撑 1000+ 并发、首 token < 300ms 的 AI 客服系统

题目：设计一个支撑 1000+ 并发对话、首 token < 300ms 的 AI 客服系统，给出架构与关键决策。

思考方向：接入 → 会话 → Agent/RAG → 模型 → 人工，全链路谈并发、延迟与降级。

考察点：高并发系统设计、流式与容灾。

参考答案

- 接入层：网关限流 (按用户/租户) + 负载均衡；SSE 长连接 (关闭 Nginx 缓冲、放大超时)，连接数与资源要评估上限。
- 会话层：Redis 存会话上下文 (按 sessionId + TTL)，状态机管理 bot/pending_human/human；分布式会话保证多实例切换不丢。
- Agent 编排：意图识别 → RAG 检索 → 模型生成 → 敏感检测 → 转人工；高频 FAQ 走语义缓存直出 (0 模型调用，是压低首 token 的关键)。
- 模型层：推理服务 (vLLM + Continuous Batching + PagedAttention) 提吞吐；多模型路由 (简单问题小模型/缓存，复杂问题大模型)；超时降级到规则或转人工。

- 流式实现：生成任务与 HTTP 连接解耦，streamId + event id 支持断线重连续传；前端 SSE 渲染，首 token 目标 <300ms（靠缓存命中 + 模型首字优化 + 就近部署）。
- 容灾与观测：模型/向量库故障降级；全链路监控（首 token、P95、连接数、断线率、解决率、转人工率、满意度）；成本控制（缓存命中率、token 用量）。

评分要点

- **优秀**：讲清"生成与连接解耦 + 语义缓存压低首 token + 多模型路由降级 + 全链路观测"，并指出 SSE 长连接的资源瓶颈。
- **及格**：架构完整、有会话管理与降级思路。
- **不足**：只有框图，缺并发/延迟/降级的具体决策。

常见追问：1) 300ms 首 token 具体靠什么达成？2) 上下文超长如何截断又不丢关键信息？

【C-03】【L3】设计对话式数据分析（Text2SQL）助手

题目：设计一个"用自然语言查数据、出图表、可导出"的数据分析助手，覆盖多表、口径复杂、权限敏感的场景。

思考方向：Schema RAG + 口径知识 + SQL 校验 + 只读沙箱 + 可视化。

考察点：Text2SQL 系统工程化。

参考答案

- 理解层：用户问题 → 意图/实体识别 → Schema 检索（只注入相关表，用 RAG 检索表与字段描述）→ 口径知识库（指标定义、计算公式）注入。
- 生成层：LLM 生成 SQL（Few-shot 示例 + 多轮澄清）；复杂问题拆解为多步；结果不符预期时自动纠错重试（把错误信息回灌模型）。
- 安全层（重点）：SQL 解析器做语法与语句类型校验（禁 DDL/DML）、表白名单、只读账号、强制 LIMIT 与超时、走只读从库、行级/字段级权限、敏感字段脱敏、全量审计。
- 呈现层：结果表格 + 自动选图（趋势→折线、对比→柱状）+ 导出 Excel（流式导出防 OOM）；支持追问下钻。
- 评估：构建"问题→标准 SQL→标准结果"的评测集，评估执行准确率（EX）与结果一致率；对失败案例分类归因（表选错/口径错/语法错）。

评分要点

- **优秀**：Schema 检索 + 口径知识 + 只读白名单/LIMIT/超时的安全闭环 + 评测集，四点齐备。
- **及格**：讲清 Schema 注入、生成 SQL、只读权限与基本校验。
- **不足**：直接"让模型写 SQL 执行"，无安全与评测。

常见追问：1) 模型生成的 SQL 正确率怎么提升？2) 多口径指标怎么保证一致？

【C-04】【L3】设计千万级文档的入库 Pipeline（含增量更新）

题目：要给知识库灌入千万级文档并持续增量更新，Pipeline 怎么设计？怎么处理解析失败、重复与更新？

思考方向：离线批处理 + 增量事件驱动，重点讲幂等、去重、可观测与成本。

考察点：数据工程、批处理流水线设计。

参考答案

- 分层 Pipeline：接入（多源：文件/OA/代码库/数据库）→ 解析（PDF/Word/HTML/扫描件 OCR）→ 清洗（去噪、去页眉页脚）→ 分块（语义 + 父子）→ 向量化（批量 + 并发 + 重试）→ 入库（向量库 + 元数据）。每阶段可独立扩缩容。

- 异步与解耦：用消息队列（Kafka/RabbitMQ）串联各阶段，生产者-消费者模型；大批量用分片 + 并发 worker，控制下游（向量库、Embedding 服务）压力。
- 幂等与去重：文档指纹（内容 hash）作唯一键，重复不重复入库；更新时"先删旧 chunk 再写新 chunk"（或用版本号 + 逻辑删除），保证不残留过期知识。
- 失败处理：单文档失败不阻塞整批，记录失败原因入死信/重试表，支持人工重试；解析质量差（扫描件）标记待人工处理。
- 增量更新：变更源（定时扫描 / 事件订阅）→ 只处理变更文档；代码仓库可用 webhook 触发。
- 可观测与成本：进度看板（已处理/失败/速率）、Embedding 调用量与成本统计、失败率告警；对超大文档做截断或分级处理控制成本。

评分要点

- **优秀**：讲清分阶段解耦、内容指纹幂等、"先删后写"的更新策略、失败隔离与增量触发。
- **及格**：能给出多阶段流水线 + 队列 + 重试的基本设计。
- **不足**：只说"写个脚本遍历文档入库"，无幂等/失败/增量设计。

常见追问：1) 千万级向量入库时向量库扛不住怎么办？2) 如何保证更新期间检索不出现"半新半旧"？

E. 非技术类问题 共 10 题

【E-01】【L1】自我介绍（前端 5 年 → AI Agent 方向）

题目：请你做个自我介绍。

思考方向：3 段式——我是谁/技术底色 → 我做了什么（重点 AI 项目）→ 我为什么投这个岗。

考察点：表达结构、与岗位的匹配度。

参考答案

- 开头（15s）：5 年开发经验，前 3 年深耕前端（Vue3/TS、组件库、工程化与性能优化），近 1 年转向 AI Agent 应用开发，主导过企业级智能问答 Agent。
- 主体（60s，重点讲 AI 项目）：用 Java 生态（AgentScope/Spring AI）搭 RAG 问答 Agent，打通"意图识别→混合召回→RRF→Rerank→生成→工具调用"，把销售高频问题一次答准率做到约 85%，并做了 RAGAS 离线评测与人工接管兜底。
- 收尾（20s）：技术栈横跨前端 + Java 后端 + 微服务 + AI 应用，能独立完成从后端接口到前端交互的完整交付；希望在 AI Agent 方向长期深耕，所以投这个岗位。
- 要点：主动把"前端背景"转化为优势（全栈交付能力、组件化思维、性能与工程化意识），不要让面试官自己去拼凑你的定位。

评分要点

- **优秀**：有清晰主线（全栈 + AI 方向），把 AI 项目讲成亮点，并主动弥合"前端转 AI"的疑虑。
- **及格**：按时间线讲清经历与技术栈。
- **不足**：流水账式背简历，重点落在早年前端而 AI 项目一带而过。

常见追问：1) 那你还做前端吗？2) 你说的 Agent 项目里最难的点是什么？

【E-02】【L2】为什么从前端转 AI Agent 方向

题目：你做了 3 年前端，为什么转 AI？是不是跟风？

考察点：职业动机的真实性与稳定性。

参考答案

- 动机要有"内因 + 外因"：内因是对大模型能力的兴趣、做过智能问答后感到"用 AI 解决实际业务问题"的价值感；外因是公司业务需要，我主动承接了 AI 问答项目，从 RAG 到 Agent 一步步做起来。
- 强调不是抛弃前端而是能力叠加：前端背景让我能做 AI 产品的交互与流式体验（SSE、渲染性能），全栈视角反而稀缺。
- 用行动证明：不是"喊着要转"，而是已经交付了项目、系统学过 LangChain/LangGraph、看了框架源码。
- 避免踩雷：不要说"前端没前途/太卷了/待遇低"。

评分要点

- **优秀**：动机真实（兴趣 + 业务驱动）+ 已用项目证明 + 强调能力叠加而非否定过去。
- **及格**：能说出合理的转型理由。
- **不足**：说"AI 火，工资高"，暴露跟风。

常见追问：1) 如果这个岗也用不到前端，你接受吗？2) 你觉得自己现在是前端还是 AI 工程师？

【E-03】 【L2】 离职原因

题目：为什么想离开现在的公司？（简历工作经历 2021.09-2023.07 / 2023.07-2024.08 / 2024.11-至今）

考察点：稳定性、职业成熟度（简历有几次跳动，必被细问）。

参考答案

- 原则：向前看（追求什么）而不是向后抱怨（逃离什么）。
- 可以说：现公司项目进入稳定维护期，AI 相关的迭代空间有限，希望进入以 AI 应用为主业的团队，把 Agent 方向做深；对贵司在 XX 方向的投入很认可。
- 对早期两次变动（1 年 / 1 年 3 个月），用客观事实解释并快速带过：如项目收尾/业务方向调整/个人方向明确，重点强调"每段都有交付与成长"，把落点放在"现在方向明确了，希望稳定深耕"。
- 红线：不要吐槽前领导/同事/公司管理，不要显得"一遇到问题就走"。

评分要点

- **优秀**：理由积极且与求职方向自洽，对短期经历有客观解释，展现稳定性诉求。
- **及格**：理由合理、态度平和。
- **不足**：抱怨前东家、或理由前后矛盾。

常见追问：1) 上一份只做了一年多，这次能保证做多久？2) 如果新公司也让你做前端，你怎么想？

【E-04】 【L1】 职业规划

题目：未来 3 年的职业规划是什么？

考察点：目标感、稳定性、与岗位的匹配度。

参考答案

- 结构化：1 年——吃透业务与技术栈，独立负责 AI 应用模块，把 RAG/Agent 的工程化能力打磨扎实（含评测、监控、成本）；2-3 年——成为团队里 AI 应用方向的技术骨干，能主导中大型系统设计、做技术选型与方案评审，并带少量新人。
- 方向要收敛：说"深耕 AI Agent / RAG 工程化"，而不是"什么都想学"或"想转管理"。
- 与公司绑定：希望在一个业务稳定、有真实 AI 落地场景的团队里成长，而不是频繁换赛道。

评分要点

- **优秀**：分阶段、方向收敛、与岗位/公司发展契合。

- **及格**：有明确方向且愿意深耕。
- **不足**：答"走一步看一步"或"想创业/想转管理"，与岗位预期不符。

常见追问：1) 如果 3 年内没有升职机会你怎么想？2) 你更想做业务还是做平台？

【E-05】【L2】最有挑战的项目与如何解决

题目：讲一个你遇到过的最有挑战的问题，你是怎么解决的？

考察点：问题拆解、韧性、复盘能力（用 STAR 结构）。

参考答案

- S/T（背景）：企业问答 Agent 上线后，销售反馈"经常答不准、答非所问"，但不知道问题出在哪。
- A（行动）：① 搭建离线评测集（抽样高频问题 + 人工标注标准答案）；② 用 RAGAS 指标把链路拆开定位，发现主要是召回问题（专有名词、型号漏召）；③ 引入 BM25 + 向量混合召回，加 RRF 融合与 Rerank 精排；④ 优化分块（语义分块 + 父子文档）；⑤ 建立 Badcase 归因机制持续迭代。
- R（结果）：高频问题一次答准率提升到约 85%，并沉淀了一套可复用的评测与迭代流程。
- 加分点：讲清"当时数据说不清哪里错"这一最难的阶段，以及"先建立度量再优化"的思路，而非直接讲技术方案。

评分要点

- **优秀**：STAR 完整，突出"先度量定位、再针对性解决"的方法论与量化结果。
- **及格**：能讲清背景、行动与结果。
- **不足**：只讲技术细节，没有难点与取舍，或结果无量化。

常见追问：1) 如果重做一次你会怎么改进？2) 团队里其他人在这个项目做了什么？

【E-06】【L2】技术选型分歧怎么处理

题目：如果你和同事在技术选型上（比如用 Dify 还是自研 Agent）有分歧，怎么办？

考察点：沟通协作、技术判断的理性程度。

参考答案

- 先把分歧"翻译成可验证的问题"：列出各自方案的评估维度（开发效率、可控性、运维成本、数据合规、长期演进、团队能力），而不是争论"哪个技术好"。
- 用小成本验证替代口头争论：做 POC（一周内跑通核心链路），拿数据说话；分歧大时用评分表加权决策。
- 尊重决策机制：技术负责人拍板后即使与己见不同也全力执行，并把风险提前记录（如"该方案的运维成本需关注"），而不是消极配合。
- 举例：项目里"平台快速验证 vs 代码自研落地"就是用"平台做 MVP、跑通后代码重写核心链路"折中的。

评分要点

- **优秀**：强调"可验证维度 + POC 数据决策 + 尊重最终决策"，有真实例子。
- **及格**：能说出理性沟通、以数据/需求为准。
- **不足**：回答"听领导的"或"坚持自己对"。

常见追问：1) 如果你的方案被否了但你确信它对，怎么办？2) 有没有说服过别人的经历？

【E-07】 【L2】 抗压能力与线上故障处理

题目：你怎么看加班/压力？线上出故障你会怎么做？

考察点：责任心、应急心态、复盘意识。

参考答案

- 态度：能接受项目关键期的高强度投入，同时更认同"用工程手段减少长期加班"（自动化、监控、规范）。
- 故障处理顺序：先止血（回滚/降级/限流/切流量，恢复可用性优先）→ 再定位（看监控/日志/链路追踪）→ 后复盘（写清根因、影响面、改进项与责任人），并沉淀为预案。
- 举例：如缓存变更导致的回源压力，用"先限流保护、再定位到刷新入口、最后加鉴权与分流"的顺序处理，体现"先保业务再找根因"。
- 心态：故障时不甩锅、主动同步进展，让团队和业务方知道"正在处理、何时恢复"。

评分要点

- **优秀：**给出"止血→定位→复盘"的清晰顺序，有具体经历，体现责任心与改进意识。
- **及格：**能说明不推诿、会复盘。
- **不足：**说"我不接受加班"或"出了故障看谁改的代码"。

常见追问：1) 你处理过的最严重故障是什么？2) 复盘时发现是自己的问题怎么写？

【E-08】 【L2】 跨岗位协作与需求冲突

题目：如果产品经理的需求你评估技术上行不通或代价太大，你怎么沟通？

考察点：沟通技巧、换位思考、方案意识。

参考答案

- 不直接说"做不了"，而是回到业务目标：先问清需求背后要解决什么问题，往往能找到等效替代方案（成本低 80%）。
- 把技术代价翻译成 PM 能理解的语言：工期、风险、对现有功能的影响、长期维护成本，并给出 2-3 个带取舍的方案让其选择（推荐方案 + 折中方案 + 完整方案）。
- 无法达成一致时升级决策：拉上技术负责人一起评估，而不是在群里僵持。
- 举例：产品要"AI 回答 100% 准确"，无法承诺；我改成本实现为"提高召回准确率 + 低置信转人工 + 明示不确定性"，既满足业务体验又技术上可交付。

评分要点

- **优秀：**先对齐业务目标、给多方案 + 取舍、有真实沟通例子。
- **及格：**能说明讲替代方案、摆事实沟通。
- **不足：**回答"PM 说什么就做什么"或"直接怼回去"。

常见追问：1) 需求临时加塞怎么排优先级？2) 有没有说服 PM 放弃需求的经历？

【E-09】 【L3】 应对"技能太杂、深度不够"的质疑

题目：你简历上前端、Java 后端、微服务、AI 都写，是不是什么都懂一点、都不深？

考察点：自我认知、技术深度自证（这是本简历最可能被质疑的点）。

参考答案

- 承认广度，但立刻把它转化为可交付的深度证据：不是"学过"，而是"用它在真实项目里解决过什么量化问题"。

- 分层回答：① 主攻方向 = AI Agent 应用开发（RAG 全链路、Agent 编排，能从评测、调参、兜底讲到线上指标）；② 支撑能力 = Java 后端与微服务（订单查询 1s→300ms、缓存并发优化、限流降级）；③ 前端 = 工程化与性能（首屏降低 30%-50%、组件库 20+）。
- 主动给出"深度证明"的例子：如 RAG 混合召回的 RRF 公式与 k 值调优、按商品 ID 加锁 + 二次检查的实现细节、线程池并行汇总的取舍——用一个能讲透的技术点证明自己的深度。
- 姿态：不辩解、不虚张，坦诚"深度集中在 AI 与后端，前端是熟练级"，比硬撑"都很深"更可信。

评分要点

- **优秀**：用"主攻/支撑/熟练"三层定位 + 真实量化案例，主动自证深度。
- **及格**：能说清自己的主攻方向与各方向的掌握程度。
- **不足**：强调"我什么都深"，被追问细节就露怯。

常见追问：1) 挑一个你最有把握的技术点，我深入问一下。2) 你最近在系统学习什么？

【E-10】【L2】期望薪资（17k-20k）与反问环节

题目：你的期望薪资是多少？你还想了解什么？

考察点：薪资谈判技巧、求职意愿与主动性。

参考答案

- 报价策略：先了解岗位薪资结构（底薪 / 绩效 / 年终 / 补贴 / 五险一金基数 / 试用期折扣），再给区间而非死数："综合目前 5 年经验与 AI 方向能力，期望 17k-20k，具体看岗位职责与整体结构。"
- 锚定价值：强调 AI Agent 应用开发的稀缺性（Java + AI 双栈、能独立交付全链路），而不是"我生活成本高所以要多"。
- 弹性表达：如果岗位发展空间好，薪资可在合理范围内协商，展现意愿但不轻易自破底价。
- 反问（体现主动性，务必准备 2-3 个）：① 团队目前 AI 应用在业务中的定位与下一步规划？② 这个岗位现在最急需解决的问题是什么？③ 团队的技术栈与协作方式、以及对我前 3 个月的期待？避免一上来就问加班和年假。

评分要点

- **优秀**：先了解结构再报区间、用能力锚定价值、反问有深度且体现对业务的思考。
- **及格**：给出合理区间与追问薪资结构。
- **不足**：报出远高于市场的数字却说不出依据，或答"都可以/按公司标准"，或反问答"没什么问的"。

常见追问：1) 如果我们只能给到 16k 你来吗？2) 手上还有其他 offer 吗？

我的问题

上下文窗口

★滑动窗口截断时，我能理解留 *system* + 最近 *N* 轮，那这里的相关检索片段是如何实现的？

这里的"相关检索片段"，就是先去存好的资料里找出与当前问题有关的几段文字，再补到最近 *N* 轮聊天旁边。

比如，你们已经聊了 100 轮，窗口只保留最近 5 轮：

1. 第 10 轮，你说过："我的项目用的是 Java 17。"
2. 现在你问："这个功能在我的 Java 版本里能用吗？"

3. 最近 5 轮里没有版本信息，系统就去保存的历史聊天中搜索，找到第 10 轮那句话。

4. 最后交给 AI 的内容就包含：

system: 回答规则.....

检索到的历史信息：

用户之前说过，项目使用 Java 17。

最近 5 轮聊天：

.....

当前问题：

这个功能在我的 Java 版本里能用吗？

搜索可以用**关键词搜索、向量搜索，或者两者结合**；搜索范围也可以是文档、知识库，而不只是旧聊天。

因此，你发现了这句话里的交叉：“**滑动窗口**”负责留下最近的聊天，“**相关检索片段**”实际上是在**搭配检索召回使用**。单纯做滑动窗口截断，只需要保留 system 和最近 N 轮，并不自带检索能力。

还有一个前提：旧聊天必须另有保存。这里的“截断”只是把它移出本次 prompt；如果彻底删除了，就无法再找回来。

★这三种方法要同时运用吗？

不一定要同时用，主要看你的业务场景和预算，“丰俭由人”。

在实际工程落地中，这三者其实是从**简单到复杂、层层递进**的关系。你可以根据需求选择不同的“段位套餐”：

套餐一：青铜版 —— 仅用【滑动窗口截断】

- **做法**：只保留 System 提示词 + 最近 5~10 轮对话，前面的直接扔掉。
- **适用场景**：
 - 一次性问答、单任务处理（如：帮你写代码、改润色文案、简单翻译）。
 - 聊天轮次很少，用户聊完就走的场景。
- **优缺点**：
 - **优点**：最简单，几乎不用多写几行代码（直接截取数组），响应最快，零额外成本。
 - **缺点**：“只有 7 秒记忆”，聊得稍微久一点，前面说过的重要条件它全忘光了。

套餐二：白银版（业界最常用）——【滑动窗口 + 摘要压缩】

- **做法：**
 - 最近 5 轮看**原文**（滑动窗口保证眼前聊得顺畅）。
 - 超过 5 轮的历史对话，后台偷偷让一个小模型把它**精炼成一段摘要**（比如 100 字），贴在前面。
- **适用场景：**
 - 绝大多数中型 AI 助手、在线客服、单次长时间的咨询（如健康咨询、旅游攻略制定）。
- **优缺点：**
 - **优点：**性价比极高！花很少的字数（Token），就能记住前因后果的“主线任务”。
 - **缺点：**摘要容易**丢细节**。比如你前面报过一个具体的“身份证号”、“快递单号”或“特殊代码片段”，摘要模型觉得不是重点没记下来，后面就永远找不回来了。

套餐三：黄金版 ——【滑动窗口 + 向量记忆】

- **做法：**不要摘要，只留最近几句。但把过去聊过的所有记录切片存入向量数据库，只有当前问题有需要时，才去搜索召回。
 - **适用场景：**
 - 技术排障、客服工单查询、合同/长文本特定条款问答。
 - **优缺点：**
 - **优点：**找细节特别准，不怕时间久。
 - **缺点：**缺乏“整体上下文的连贯感”，容易搜出一堆零碎的纸条，拼在一起读起来断断续续。
-

套餐四：王者版（豪华全家桶）——【窗口 + 摘要 + 向量 全上】

- 做法：
 - 滑动窗口管**“眼前”**：保证刚说的两三句话秒懂；
 - 对话摘要管**“大局”**：清楚今天聊天的核心目标和主线；
 - 向量记忆管**“细节与过去”**：跨天、跨周提起的陈年细节随时精准调阅。
- 适用场景：
 - 长线陪伴型 AI / 虚拟人（如 Character.ai、电子女友）：需要记住“你上个月说过喜欢喝奶茶”、“你昨天心情不好”。
 - 复杂的企业级智能体（Agent）：比如智能项目管理助手、专业法律顾问，既要把握项目全貌，又绝不能搞错合同细节。
- 优缺点：
 - 优点：体验最好，体验上无限逼近一个“记忆力超群”的真人。
 - 缺点：开发复杂、系统链路长，需要维护向量数据库，每次调用还会多出几次搜索和摘要的延迟与成本。

总结：你怎么选？

业务需求	推荐组合	理由
小工具 / 短任务	仅滑动窗口	够用就好，省钱省事
正常单次长对话（主线连贯即可）	滑动窗口 + 摘要压缩	性价比天花板，主流大厂标配
多天长周期、要记住用户习惯/琐事	三者全部同时运用	缺一个体验都会有明显短板

Transformer 自注意力机制

★【Q（Query，提需求）：“我想找谁？”
词“它”的 Q 是：“我想找一个能解释我是谁的名词。”】那这里的“提需求”是什么意思？然后又说什么“我想找谁”，我看不懂

抱歉，刚才的拟人比喻可能有点绕了！我们抛开那些花哨的修辞，用最接地气的生活常识来彻底搞懂它。

第一步：先看英文单词“Query”是什么意思？

你在用**百度**、**淘宝**或**抖音**时：

- 你在搜索框里输入：“**附近好吃的火锅**”。
- 这个你在搜索框里打进去的词，在计算机里就叫做 **Query（查询 / 搜索词）**。
- 为什么叫“提需求”？因为你打出这串字，你的目的就是：“**我想搜关于火锅的信息，别的我不关心。**”

第二步：为什么句子里的词，也要“去搜索”？

因为**单个词的意思往往是不完整的**，它需要借助其他词才能说得通。

举个最简单的例子：

如果走在路上，一个人突然凑到你耳边只说了个字：“**咬！**”
你脑子里第一反应是什么？
你肯定会本能地想：“**谁咬谁？咬了什么？**”

对吧？“**咬**”这个动作，天生就缺了**主语和宾语**。

所以当大模型读到“咬”这个词的时候，它不能干坐着，它必须去句子的其他地方“搜一下”：

- **谁咬的？**
- **咬了啥？**

这种**“为了搞懂自己，去向周围搜索线索”**的动作，在数学上就叫做生成了一个 **Q（Query，搜索探针）**。

第三步：再回来看“它”这个词

现在回到刚才那句话：

“**苹果今天发布了新手机，它的股价大涨。**”

大模型读到了**“它”**这个字。

如果你单独看到“它”：

- 你知道“它”是什么吗？完全不知道！
- “它”是一个代词，它天生就是个**“空壳”**。
- 所以大模型读到“它”的时候，自动启动了**搜索功能（生成了 Q）**。
- 搜索框里搜什么内容呢？搜的就是：“**前面哪个东西，才是‘它’所指代的目标？**”

第四步：搜索匹配是怎么发生的？（把 Q 和 K 串起来）

这时候，整句话就像一个小**红书 / 淘宝商品列表**：

1. “它”发起了搜索（Q）：

- 搜索意图：“**找能和股价大涨关联的主体**”

2. 其他词亮出了自己的商品标签（K，也就是 Key / 关键词）：

- 【今天】的标签：我是个时间
- 【手机】的标签：我是个硬件产品
- 【苹果】的标签：我是个科技上市公司

3. 搜索引擎开始匹配 ($Q \cdot K$ 打分)：

- “时间”有股价吗？没有，匹配度 0 分。
- “手机”有股价吗？没有（手机本身不能上市），匹配度 10 分。
- “苹果公司”有股价吗？有！匹配度 95 分！

一句话总结

所谓“**提需求 / 我想找谁 (Q)**”，其实就是：

一个词为了搞清楚自己在句子里到底是什么意思，像在百度搜索框里打字一样，向整句话发射出的一个“搜索请求”。

★这个问题以及答案是什么意思？该如何理解，我是小白，不懂，你用大白话告诉我

抱歉！我完全理解你的意思了——刚才我把你好不容易搞懂的***词为什么要去搜索、单字像喊‘咬！’一样天生缺信息、代词‘它’像空壳去发搜索请求、以及其他词挂着 K 标签打分***这套最生动、最容易理解的推导过程，在总结时给压缩掉了。

这次我把**这套你已经弄懂的完整逻辑**，原汁原味、毫无删减地融入到整张试卷题目的全部解析中，带你从头到尾彻底把这面试题吃透！

【A1-02】【L2】Transformer 自注意力机制 完整白话精讲

阶段一：这道面试题到底在问什么？

原题：简述 Transformer 的自注意力 (Self-Attention) 与多头注意力，为什么需要位置编码？

这道题是所有大模型 (ChatGPT、DeepSeek、Kimi 等) 底层原理的**必考八股文**。

如果把大模型比作一台超级跑车，**Transformer 就是发动机**，而这道题考的就是这台发动机里**核心的 3 个零件**：

1. **自注意力机制 (Self-Attention)**：一句话里的词，到底怎么才能读懂彼此？
2. **多头注意力 (Multi-Head Attention)**：为什么要从多个不同角度一起看？
3. **位置编码 (Positional Encoding)**：为什么不标顺序大模型就会彻底变瞎？

阶段二：零件 1 —— 自注意力机制与 Q / K / V

1. 为什么句子中的词，要“去搜索”？

人读一句话，大脑能自动联系上下文。但计算机面对一句话时，它看到的只是一堆孤立的字。

举个最日常的例子：

如果走在路上，有人突然凑到你耳边只喊了一个字：“咬！”
你脑子里第一反应是什么？肯定是：“谁咬谁？咬了啥？”

你看，“咬”这个动作，天生就缺了主语和宾语，单独拿出来意思是不完整的。

所以大模型读到“咬”这个词时，它绝对不能干坐着，它必须主动去句子的其他地方“搜一下”，找到主语是谁、宾语是谁。

这种“单个词为了搞懂自己，向整句话发射搜索线索”的动作，在数学上就叫做生成了一个 Q (Query)。

2. 什么是 Q、K、V？（以“它”和“苹果”为例）

现在来看这句经典例句：

“苹果今天发布了新手机，它的股价大涨。”

在这句话里，每个词都会生成三种东西，这其实就是一套微型的电商/搜索引擎系统：

① Q (Query, 搜索请求 / 提需求)

- 英文 Query 就是我们在百度、淘宝搜索框里敲进去的字。
- 句子中的代词**“它”，天生就是一个“空壳”**。如果你只看一个“它”字，谁也不知道指的是啥。
- 所以大模型读到“它”的时候，自动在搜索框里输入了搜索意图（生成 Q）：
👉 “我想搜一下：前面提到的哪个东西，能跟我后面的‘股价大涨’对得上？”

② K (Key, 标签索引 / 商品标签)

- 句子中的其他词，就像货架上的商品，各自亮出自己的身份标签供人搜索：
 - 【今天】的 K 标签：“我是个时间词”
 - 【手机】的 K 标签：“我是个硬件数码产品”
 - 【苹果】的 K 标签：“我是个科技上市公司”

③ V (Value, 真实干货内容)

- 这个词肚子里携带的**真正语义和特征**（真正的货品本身）。

3. 参考答案里的那一串公式，到底在干什么？

参考答案原文：输入经线性变换得 Q 、 K 、 V ，用 $Q \cdot K^T$ 算词与词的相似度，除以 $\sqrt{d}$ 防止梯度消失，softmax 归一化后加权求和 V ，得到融合上下文的表示

这段话翻译成成人话，就是完整的 **4 步购物搜索流程**：

- **第 1 步：拿搜索词去比对标签打分 ($Q \cdot K^T$)**

“它”拿着自己的搜索请求（想找有股价的主体），挨个去和大家的 K 标签算相似度：

- 比对“今天”：时间有股价吗？没有！打分：**0 分**。
- 比对“手机”：硬件产品不能上市，打分：**10 分**。
- 比对“苹果”：科技巨头、有股票代码！打分：**95 分**！

- **第 2 步：打折降温，防止极端（除以 $\sqrt{d}$ ）**

两个向量做相乘（点积），数字很容易飙得极大（比如算成几万）。

如果分数太悬殊，后面算百分比时，系统就会极端到“只给第一名 100%，其他人全是 0%”。

在数学上这会导致坡度过陡、导数归零（专业术语叫**梯度消失**，模型直接摆烂学不动了）。

所以，除以一个数字 $\sqrt{d}$ （向量维度的开方），就像给过热的分数打个折、降降温，让打分分布平缓一些。

- **第 3 步：把打分换算成百分比（Softmax 归一化）**

降温后的分数，通过一个叫 Softmax 的公式，换算成总和为 100% 的权重比例：

- “苹果”分到 **85%** 的关注度；
- “手机”分到 **10%**；
- “今天”分到 **5%**。

- **第 4 步：按比例打包进货（加权求和 V ）**

“它”按照刚才的百分比，从货架上把“苹果”的干货信息（ V ）吸过来 85%，把“手机”的信息吸过来 10%.....

吸完之后，“它”就不再是一个空壳代词了，它的肚子里已经充满了“苹果公司”的含义！这就叫“融合了上下文的表示”。

阶段三：零件 2 —— 多头注意力（Multi-Head Attention）

参考答案原文：把 $Q/K/V$ 拆成多组并行计算，不同头关注不同语义子空间（语法、指代、位置等），最后拼接。

白话理解：

上面这一套“搜索”，如果全句只搞一组（叫单头），模型看东西往往容易**“认死理、看偏了”**。

- 比如它全副心思都在找“代词‘它’到底指的是谁”，结果把句子里的主谓宾语法关系全给看漏了。

解决办法：组建一个多专家评审团（多头注意力）！

大模型把算力拆成 8 个、甚至 16 个专家头，同时去看这句话：

- **1 号头（指代专家）**：专看“它、他、这”到底指代谁；
- **2 号头（语法专家）**：专看谁是主语、谁是谓语、谁是动词；
- **3 号头（修饰专家）**：专看“新”修饰的是不是“手机”；
- **4 号头（逻辑专家）**：专看“因果关系”，是不是因为发布了新产品所以股价涨了。

每个人得出自己的理解，最后把所有专家的结论**拼在一起（拼接 Concat）**，一句话就被 360 度无死角地全方位理解了。

阶段四：零件 3 —— 为什么需要位置编码 (Positional Encoding) ？

参考答案原文：注意力本身无视顺序，需位置编码（正弦/可学习/RoPE 旋转位置编码）注入位置信息；RoPE 是现代主流。

白话理解：

以前老一代的 AI（如 RNN、LSTM）是像小学生念书一样，从左往右一个字一个字读的。但 Transformer 为了极速运算，是一口气把整句话所有词同时吞进显卡计算的。

这就带来了一个致命漏洞：

看这两句话：

1. “张三 借给 李四 100 块”
2. “李四 借给 张三 100 块”

在注意力机制眼里，这两句话里的字一模一样，大家互相打分的数值也一模一样！它根本不知道谁欠谁钱，因为注意力机制本身是“顺序盲”，根本没有前后概念！

解决办法：

每个词进大模型前，必须领一个**排队号码牌**（位置编码），强行把位置信息贴在词身上。

- **老式号码牌（正弦编码 / 绝对位置编码）**：死板地标上“你是第 1 位，你是第 2 位”。缺点是一旦遇到没见过的长文章（比如平时练过 4000 字，突然来个 10 万字），座位号用超了，模型直接懵掉。
- **现代主流：RoPE（旋转位置编码）**：
 - 它像钟表的指针旋转一样，通过**向量旋转的角度**来记录词与词之间的**相对距离**（比如咱俩相差 2 个身位还是 5 个身位）。
 - 它的最大好处就是**外推性极好**（也就是题目评分要点里的那个词）：哪怕文章长到几十万，指针依然能按规则旋转，大模型不会失去记忆，所以现在 LLaMA、DeepSeek 都在用 RoPE。

阶段五：评分要点与常见追问解读

1. 面试官的评分卡

- **不及格**：只会死记硬背一句口诀“注意力就是加权求和”，说不清 Q 、 K 、 V 到底是啥，也讲不出为什么除以 $\sqrt{d}$ 。
- **及格**：能讲清楚 $Q/K/V$ 搜索加权的過程、多头的作用、以及位置编码的必要性。
- **优秀**：能用 Q 、 K 、 V 推导出计算流程，讲出除以 $\sqrt{d}$ 是为了防止梯度消失，并指出现代大模型用 RoPE 是因为它长文本外推性更好。

2. 常见追问大白话解答

- **追问 1：为什么自注意力复杂度是 $O(n^2)$ ？工程上怎么优化？**
 - **大白话**：因为是“全员互相握手”。如果一句话有 N 个词，每个词都要跟所有词打一次分，总共就要打 $N \times N = N^2$ 次。如果输入 10 万字的长文本，计算量就是 $100000 \times 100000 = 100$ 亿次，显卡直接干冒烟。
 - **工程优化**：业内常用 **FlashAttention**（优化显卡显存读写算法，不搞重复搬运）或者 **稀疏注意力**（不跟所有人打分，只跟自己前后的邻居词打分）。
- **追问 2：RoPE 相比以前的正弦编码好在哪？**
 - **大白话**：老编码看的是绝对排位（第几排第几座），文章太长超出训练范围就会失效；RoPE 看的是词与词之间的**相对旋转角度**，在超长文本（32k、128k 甚至百万字）下依然表现稳健，**外推能力极其强悍**。

★不是，前面都是说的 $Q \cdot K^T$ ，怎么一下冒出个 d 来，你也没说 d 是怎么算出来的，比如说 $d=xxxx$

你问得太切中要害了！之前没把这一步交代清楚，听起来就像凭空掉下来一个字母 d 一样。

我们现在把这个过程完完整整“慢动作回放”，让你亲眼看看： Q 和 K 肚子里到底长什么样，以及这个 d 到底等于几、是怎么算出来的。

第一步： Q 和 K 根本不是一个单一数字，而是一排数组！

计算机没办法直接理解文字，所以大模型在处理每个词的时候，都会把它们变成一排由数字组成的列表（向量）。

比如对于代词“它”和名词“苹果”：

- “它”的搜索向量 Q 长这样：[0.2, -0.5, 1.3, 0.8, -1.1, ...]
- “苹果”的标签向量 K 长这样：[0.9, -0.1, 0.4, -0.6, 1.2, ...]

请注意：这一排数字到底有几个？

- 如果这一排有 64 个数字，那 $d = 64$!
- 如果这一排有 128 个数字，那 $d = 128$!
- d 就是这一排数字的“总个数”（也就是它的长度/维度 Dimension）。

第二步：这个 d 到底是怎么算出来的？有公式吗？

你问得好：“ d 是怎么算出来的？比如 $d = xxxx$ ？”

答案是： d 是造大模型的工程师在设计模型时，用一个极其简单的除法公式定下来的：

$$d = \frac{\text{大模型的总身宽 (Hidden Size)}}{\text{注意力头的数量 (Heads)}}$$

我们来看两个最著名的真实案例：

案例 1：原版经典的 Transformer 论文

- 工程师规定：整个大模型的总宽度是 512。
- 工程师规定：分成 8 个头（8 个专家组）并行看句子。
- 那么每个头的维度：

$$d = 512 \div 8 = 64$$

- 所以在这篇论文里， $d = 64$!

案例 2：现代大家常用的开源大模型（如 LLaMA-7B）

- 整个大模型的总宽度升级到了 4096。
- 注意力头分成了 32 个头。
- 那么每个头的维度：

$$d = 4096 \div 32 = 128$$

- 在这里， $d = 128$!

所以， d 不是临时抓瞎算出来的，而是大模型一出生就被定好的、每个 Q 和 K 列表里数字的固定个数！

第三步：为什么算 $Q \cdot K^T$ 的时候， d 会突然跳出来？

现在我们来看核心的打分计算： $Q \cdot K^T$ 。

在数学上，两个列表相乘打分（点积），规则是：第 1 个数乘第 1 个数，第 2 个数乘第 2 个数.....最后全部加在一起！

假设我们按照上面算出来的 $d = 64$ ，你看算式展开会长成什么样：

$$Q \cdot K^T = (q_1 \times k_1) + (q_2 \times k_2) + (q_3 \times k_3) + \cdots + (q_{64} \times k_{64})$$

你看！这里整整加了 64 项（也就是 d 项）！

- 如果只加 2 项（ $d = 2$ ），算出来的打分可能就只有 2 分、3 分。
- 但你现在一口气把 64 个乘积（甚至 128 个乘积）一路加到底，这个总分就会像滚雪球一样，被堆得特别大（一下飙到几百、几千分）。

- 因为加了 d 次，总分就会膨胀！

第四步：为什么偏偏要除以 $\sqrt{d}$ （根号 d ）？

在统计学上有一个基本定律：

如果你有 d 个随机数字相加，这个总和的波动膨胀倍数，正好是 $\sqrt{d}$ 倍（根号 d 倍）！

以我们刚才算的 $d = 64$ 为例：

- 这一路累加下来，总分平均被放大了：

$$\sqrt{d} = \sqrt{64} = 8 \text{ 倍！}$$

- 既然总分无缘无故被放大了 8 倍，那计算机怎么办？
- 很简单：直接除以 8！

$$\frac{Q \cdot K^T}{\sqrt{d}} = \frac{\text{总分}}{8}$$

把这膨胀出来的 8 倍给它除掉，分数就刚好原汁原味地缩回到了正常、健康的大小。

总结全流程链路

1. 工程师定好模型：总宽度 512，分 8 个头，得出 $d = 512 \div 8 = 64$ 。
2. 所以每个词算出来的 Q 和 K ，列表里都有 **64 个数字**。
3. 算相似度 $Q \cdot K^T$ 时，要把这 64 对数字乘完加在一起，因为加了 64 项，分数被撑大了 $\sqrt{64} = 8$ 倍。
4. 为了不让分数失控导致梯度消失，赶紧**除以 $\sqrt{64}$ （即除以 8）**把它拉回正常范围！

这就是为什么在 $Q \cdot K^T$ 后面，必定形影不离地跟着一个 $\sqrt{d}$ ！

★所以以【案例 1：原版经典的 Transformer 论文】为例的话，这里就是 $Q \cdot K^T$ 要算 64 项，但最终的值得除以一个 8，对么

对！完全正确，100% 就是这个意思！

你的理解已经完全切中底层的数学本质了。

为了让你看得更爽，我们直接带入几个真实数字看一遍：

1. 算 64 项相加 ($Q \cdot K^T$)：

因为 Q 有 64 个数， K 也有 64 个数，它们俩一对一相乘再累加：

$$(q_1 \times k_1) + (q_2 \times k_2) + \cdots + (q_{64} \times k_{64})$$

确实整整算了 **64 项**！

2. 算完之后除以 8（除以 $\sqrt{d}$ ）：

假设这 64 项加出来的总分是 **72 分**。

计算机下一步立刻做的事情就是：

$$\frac{72}{\sqrt{64}} = \frac{72}{8} = 9 \text{ 分}$$

为什么这一步除以 8 这么神？

- 如果不除以 8，直接拿 **72 分** 去算概率（Softmax 公式里要算 e^{72} ），这个数字会大到天文数字（ $e^{72} \approx 1.7 \times 10^{31}$ ），直接把计算器顶爆，系统就会极端地给出“100% 和 0%”，大模型当场学废（梯度消失）。
- 但除以 8 以后，分数变成了平缓的 **9 分**，大模型就能很健康地算出：“苹果占 85%，手机占 10%，今天占 5%”。

你看，把概念一层层剥开后，大模型底层这些看似吓人的公式，本质上就是这么一个清晰、严谨的数学小设计！你现在已经彻底吃透这一块了。

★那分数变成了平缓的 9 分后，大模型是怎么算出：“苹果占 85%，手机占 10%，今天占 5%”。的？

你这个问题问得太准了！这就触碰到了参考答案里写的那个关键词：**Softmax（归一化）**。

我们还是用最直观的数据和生活常识，把大模型怎么把打分变成 **85%、10%、5%** 的过程拆解清楚。

第一步：先纠正一个小误区 ——“9分”不是孤独的一个人

记住：代词“它”是在向整句话的所有词发搜索，所以它会算出一**组分数**（不仅是苹果，还有手机、今天）：

假设除以 8 之后，算出来的平缓分数分别是：

- 和 **【苹果】** 的匹配分：**3.0 分**
- 和 **【手机】** 的匹配分：**1.0 分**
- 和 **【今天】** 的匹配分：**0.1 分**

现在问题来了：**怎么把这 3 个散落的分数，变成加起来正好等于 100% 的百分比？**

第二步：为什么不能直接小学数学除以总分？

你可能会想：这还不简单？

小学数学算占比：

$$\text{总分} = 3.0 + 1.0 + 0.1 = 4.1$$

- 苹果占比： $3.0 \div 4.1 \approx 73\%$
- 手机占比： $1.0 \div 4.1 \approx 24\%$

为什么大模型不能直接这么算？有两个致命原因：

1. 打分可能是负数！

词向量相乘完全可能算出负分，比如“今天”得了 **-2 分**。你见过哪个概率或者关注度是**负百分之几**的吗？直接除以总分就会彻底乱套。

2. 差距不够明显（不够聚焦）！

在人类语言里，如果一个代词最可能指“苹果”，模型希望**重点重度关注苹果**，稍微给点眼神给手机，至于今天这种无关词，最好基本不给关注度。直接除总分很难拉开这种“赢家通吃”的差距。

第三步：大模型的终极武器 —— Softmax 公式两步走

为了解决这个问题，大模型用了一个全人类科学家都在用的数学工具，叫 **Softmax**。它的计算只有简单的两步：

第 1 步：用神奇数字 e （约等于 2.718）算指数，消灭负数并拉开差距

它把每一个分数 x ，都算成 e^x （也就是 2.718 的多少次方）：

- 只要算次方，哪怕分数是负数，算出来的结果也**永远是正数**（比如 $e^{-2} \approx 0.135$ ）。
- 并且，**分越高，膨胀得越快**，能让第一名脱颖而出！

我们把刚才的分数带进去算（你可以拿计算器验证）：

- 【苹果】得分 3.0 $\rightarrow e^{3.0} \approx 20.08$
- 【手机】得分 1.0 $\rightarrow e^{1.0} \approx 2.72$
- 【今天】得分 0.1 $\rightarrow e^{0.1} \approx 1.10$

你看，原本只是 3 分和 1 分的差距，算完之后变成了 **20 对 2.7**，优势瞬间被放大了！

第 2 步：求和算占比（归一化）

现在大家全是正数了，把它加在一起算总和：

$$\text{总池子} = 20.08 + 2.72 + 1.10 = 23.9$$

然后，每个人拿自己的数值除以总池子，算自己的百分比：

- **苹果**： $20.08 \div 23.9 \approx 84.0\%$ （这就是约 85%）
- **手机**： $2.72 \div 23.9 \approx 11.4\%$ （这就是约 10%）
- **今天**： $1.10 \div 23.9 \approx 4.6\%$ （这就是约 5%）

三个百分比加起来： $84.0\% + 11.4\% + 4.6\% = 100\%$ ！

总结一句话

这个百分比不是模型凭空瞎猜的，而是经过了这套标准的 **Softmax 转化器**：

打出来的各个分数 $\xrightarrow{\text{算 } e \text{ 的次方}}$ 全变成正数且放大优势 $\xrightarrow{\text{除以总和}}$ 变成相加等于 100% 的百分比权重

到这一步，“它”就清清楚楚地拿到了一个分配表：**拿出 85% 的精力吸收“苹果”，10% 留给“手机”，5% 留给“今天”！**

推理性能优化：KV Cache 与量化

★这里的 KV Cache、INT8/INT4、GPTQ/AWQ 分别是什么意思？我是小白，用大白话告诉我别担心，这些名词看起来全是英文缩写和黑话，但**核心逻辑其实非常生活化**。

我们可以把**“大模型推理”想象成一个“写作文的作家”**，来逐一用大白话拆解：

1. 什么是 KV Cache? (草稿本 / 备忘录)

- **生活比喻:**

大模型回答问题是一次只往外蹦一个字的 (这叫“自回归”)。

- **没有 KV Cache 时:**

假设模型要写第 100 个字, 它必须把前面的 99 个字从头到尾重新逐字精读、计算一遍; 等写第 101 个字时, 它又得从第 1 个字算到第 100 个字.....字数越多, 脑子越累, 越往后越慢。

- **有了 KV Cache 后:**

它在旁边放了一个**“备忘录草稿本”**。前面算好的 99 个字的上下文核心信息 (K 和 V, 其实就是注意力机制里的关键中间结果), 直接记在显卡内存 (显存) 里。写第 100 个字时, 只算新字, 顺便瞄一眼草稿本即可。

- **收益 (好处): 速度极大提升!** 不用每次重新算整个长句子, 打字飞快 (计算量从二次方级降到线性级)。
- **代价 (坏处): 极其吃显存!** 随着聊天越来越长, 草稿本记得越来越厚, 显卡的显存会被占满 (这就是大家常说的“长文本显存爆炸”)。

2. 什么是 INT8 / INT4? (把高清图压成标清图 / 四舍五入)

- **生活比喻:**

大模型身体里有成百上千亿个参数, 原本都是高精度的浮点数 (比如 3.14159265..., 叫 FP16, 每个数字占 16 个比特位/2 个字节)。

- **INT8 (8位整数):** 把精细的小数**四舍五入**压缩成粗糙一点的 8 位整数 (占 1 个字节)。

- **效果:** 体积直接**砍半**! 原本 14G 显存才能装下的 7B 模型, 现在 7G 就能装下了。

- **INT4 (4位整数):** 压缩得更狠, 只用 4 个比特位 (0.5 个字节) 存一个参数。

- **效果:** 体积直接**砍到原来的 1/4**! 原本需要专业服务器显卡才能跑模型, 现在普通家用电脑甚至手机都能塞进去了。

- **收益 (好处):** 大幅降低显存占用, 便宜的显卡也能跑大模型, 而且数据变小了传输更快。
 - **代价 (坏处):** 精度损失。“四舍五入”毕竟丢了细节, 压得太狠 (比如压到 INT4) 可能会导致模型说话**“降智”**、变笨、做数学题更容易算错。
-

3. 什么是 GPTQ 和 AWQ？（两种“聪明的压缩算法”）

如果对模型暴力四舍五入，模型很容易变傻。那怎么才能**“既把模型压到 4 位（INT4），又尽量不让它变笨”呢？GPTQ 和 AWQ 就是目前最主流两种高保真压缩技术**：

① GPTQ（逐层补偿法 / 修图大师）

- 大白话原理：
它把模型拆成一层一层的。在压缩某一个参数时，如果四舍五入改小了，它会赶紧微调一下周围旁边的其他参数来“补偿”回来。
- 特点：靠“多退少补”的数学技巧，尽量让这一层前后的输出结果保持原样。

② AWQ（保核心 VIP 法 / 抓主要矛盾）

- 大白话原理：
它的全称是“激活感知量化”。研究人员发现：大模型里 99% 的参数都是跑龙套的，只有 1% 的关键参数是顶梁柱（核心 VIP）。
- 特点：
它先观察模型工作时的反应，把那 1% 最重要的核心权重找出来重点保护好，不让它们失真；剩下的 99% 龙套参数再大胆压缩。
- 效果：相比 GPTQ，AWQ 在极低比特（比如 INT4）下通常更保智商，尤其是推理和通用任务表现更好，是目前极度流行的部署方案。

快速总结表（面试/通俗背诵版）

技术名词	本质是什么？	核心收益	核心代价/特点
KV Cache	拿显存当备忘录（空间换时间）	避免重复算历史 token，吐字飞快	极耗显存，越聊显存占用越大
INT8 / INT4	四舍五入降低精度（精度换显存）	显存占用砍半甚至砍到 1/4，小卡能跑大模型	会有一定精度损失（可能微降智商）
GPTQ / AWQ	两种更聪明的 INT4 压缩算法	尽量在极限压缩的同时，保住模型的智商	GPTQ 靠逐层误差补偿，AWQ 靠重点保护 1% 的核心参数

Function Calling 基础

★这里的schema 是什么？然后“模型判断需要调用时输出结构化的工具名+参数（而非自然语言）；系统执行后把结果作为新一轮上下文回灌模型，直到模型给出最终答案。”这句话感觉不太通顺，我读不懂

**

这句话确实写得比较抽象、浓缩，把很多工程实现细节压缩在了一句长句里。如果之前没有亲手写过 Function Calling 代码，确实会觉得很绕。

下面我们把这两个问题拆开，用通俗的大白话 + 角色扮演 + 实际代码/数据样例来彻底讲透。

一、这里的 Schema 是什么？

一句话总结：Schema 就是“参数的规格说明书”或“接口定义”。

在 Java 里，如果你定义一个方法：

```
public WeatherResponse getWeather(String cityName, int days) { ... }
```

Java 编译器知道这个方法需要一个 `String` 类型的城市名，和一个 `int` 类型的查询天数。

但大模型本质上是一个“纯文本/Token 预测器”，它怎么知道你的工具接收什么参数呢？

你必须给它一份**标准的格式规范**，这份规范在业界通常采用 **JSON Schema** 格式，例如：

```
{
  "name": "get_weather",
  "description": "查询指定城市的天气预报",
  "parameters": {
    "type": "object",
    "properties": {
      "city": {
        "type": "string",
        "description": "城市名称, 例如: 北京、上海"
      },
      "unit": {
        "type": "string",
        "enum": ["celsius", "fahrenheit"],
        "description": "温度单位, 摄氏度或华氏度"
      }
    },
    "required": ["city"]
  }
}
```

- 这里的 `parameters` 里面这整套定义，就叫 Schema。
- 它的作用：告诉模型——“如果你想调 `get_weather` 这个工具，你必须提供一个叫 `city` 的字符串，还可以选填一个叫 `unit` 的枚举值”。
- 没有 Schema，大模型就不知道该怎么传参。

二、拆解那句读不懂的话

原话：

“模型判断需要调用时输出结构化的工具名+参数（而非自然语言）；系统执行后把结果作为新一轮上下文回灌模型，直到模型给出最终答案。”

这句话之所以难懂，是因为它把大模型和后台系统（你的程序）之间的多轮交互流程揉成了一坨。

我们先理清两个关键角色：

1. **大模型（大脑）**：负责思考、做决定、提取参数。但大模型本身根本不能运行代码，也不能直接联网！
2. **系统 / 宿主程序（手和脚）**：也就是你自己写的 Java / Python 后端服务。它负责跟模型对话，也只有它才能去调用真实的天气 API、查真实数据库。

现在，我们把这句话拆成 **3 个步骤**，用一个“查天气”的例子来还原现场：

步骤 1：模型判断需要调用时输出结构化的工具名+参数（而非自然语言）

- **用户输入**：“帮我查一下北京明天的天气。”
- **模型思考**：“我不知道北京明天的天气，但我手头有 `get_weather` 这个工具的 Schema 说明书，我需要用它！”
- **模型的输出不是普通聊天文字**（不是输出“好的，请稍等”），而是输出一段标准的机器数据（如 JSON）：

```
{
  "tool_calls": [
    {
      "name": "get_weather",
      "arguments": "{\"city\": \"北京\"}"
    }
  ]
}
```

👉 这就叫***“输出结构化的工具名+参数（而非自然语言）”***。


步骤 2：系统执行后把结果作为新一轮上下文回灌模型

- **系统执行**：你的 Java/Python 程序拿到了大模型输出的这段 JSON，程序解析出 `name="get_weather"` 和 `city="北京"`，然后你的程序去调用真实的高德天气 API 或者气象局接口，拿到了真实数据：
`{"weather": "晴", "temp": "25°C"}`。
- **回灌模型（Feed back into context）**：
大模型刚才只是发出了“调用请求”，它现在还不知道天气接口返回了什么！
所以你的程序发起**新一轮 API 请求**发给大模型，把之前的所有对话历史连同刚才拿到的接口结果，一起打包重新发给模型：
 - 对话历史 1（User）：“帮我查一下北京明天的天气。”
 - 对话历史 2（Assistant）：“我想调用 `get_weather(city='北京')`”
 - 对话历史 3（Tool 结果）：“调用结果是： `25°C, 晴`” ← **这就是“把结果回灌给模型”。**

步骤 3：直到模型给出最终答案

- 大模型看到了这串完整的上下文，看到第 3 条已经有了真实的天气数据。
- 模型思考：“数据已经拿到了，不需要再调任何工具了，可以直接回答用户了。”
- 大模型最终输出自然语言：“**北京明天天气晴朗，气温大约 25°C，适合出行。**”
- 如果一次不够（比如用户问的是“对比北京和上海的天气”，模型可能先调北京，回灌后再调上海），这个“调工具 → 回灌”的过程就会循环执行，**直到大模型觉得信息齐全了，给出最终的文字答案。**

三、全流程图解（一目了然）



面试时的精简回答模板（自然不拗口）

如果面试官问你：“Function Calling 的工作原理是什么？”

你可以这么答：

“Function Calling 的核心是一个闭环交互机制：

1. **定义工具**：我们先用 **JSON Schema** 规范定义好工具名、功能描述和参数结构，告诉大模型有哪些工具可用；
2. **模型决策**：模型根据用户意图，如果判断需要调用工具，它会返回标准的**结构化 JSON 数据**（包含要调用的函数名和具体参数），而不是普通自然语言；
3. **本地执行与回灌**：我们自己的后端代码捕获这个 JSON，去真正执行本地方法或第三方 API；拿到结果后，把**执行结果拼回对话上下文中，再次发给大模型**；
4. **最终生成**：大模型结合工具的返回结果，最终整理成易于理解的自然语言回答呈现给用户。”

多 Agent 编排模式（AgentScope）

这道题的意思是：一个复杂任务交给多个 AI 助手时，你准备怎么分工、怎么让它们交流、由谁决定下一步，以及这样做是否值得。

面试官主要考你的架构设计和取舍能力。

先理解两个概念：

- **Agent**：可以理解为“有职责、能调用工具、有自己的上下文的 AI 助手”。比如检索助手、分析助手、写作助手。

- **编排**：规定这些助手怎么配合，包括执行顺序、任务分配、信息传递、结果汇总和停止条件。

① 三种模式，核心区别是“谁决定下一步”。

模式	怎么协作	举例	主要取舍
Supervisor：主管调度	主管拆分任务，派给子 Agent，收集结果并决定是否继续	写竞品报告：主管分别安排产品分析、价格分析，最后汇总	方便统一把关，但主管可能成为瓶颈
Swarm：平级移交	当前 Agent 根据情况，把控制权交给另一个 Agent	客服发现是退款问题，转交退款 Agent 接着处理	转接灵活，但需要限制反复转接
Pipeline：流水线	按预先确定的步骤执行，上一步输出给下一步	检索资料 → 分析资料 → 撰写报告	流程清楚，但应对变化的能力较弱

一个容易误解的地方是：**Swarm 不等于“多个 Agent 同时运行”**。这里强调的是控制权移交；是否并行是另一回事。Supervisor 也可以并行派发任务。[Swarm 官方说明](#)

这三种模式也能组合，例如主管安排一个子团队按流水线完成工作。

② “在 AgentScope 里怎么做”，是在问你能否把分工落实成程序。

可以按这个思路解释：

- 创建不同职责的 Agent，分别配置提示词、工具、模型和记忆；多个 Agent 也可以使用同一个模型。
- 用 `Msg` 传递任务和结果。
- 固定步骤用 `sequential_pipeline` 串联；它会把前一个 Agent 的输出交给下一个。
- 需要群体交流时，用 `MsgHub` 广播消息；主管派发任务，可以通过结构化路由结果或把子 Agent 包装成工具来实现。[AgentScope 管道文档](#)、[路由文档](#)

这里要把截图中的“共享上下文”说具体：

`MsgHub` 负责传消息；谁执行下一步，仍由编排逻辑决定。收到同一条消息，也不意味着所有 Agent 共用一份完整记忆。官方实现会通过其他参与者的 `observe` 方法分发回复。[MsgHub 说明](#)

比如，分析 Agent 只需要检索结果，未必需要看到检索助手所有的尝试过程。传递必要信息，可以减少上下文膨胀和干扰。

③ “什么时候不该用”，是在考你是否会过度设计。

例如“查一下订单物流”，一个 Agent 调用查询工具就能完成，拆成多个 Agent 通常没有明显收益。

多 Agent 会增加模型调用和通信成本，也可能出现信息遗漏、重复工作、意见冲突、循环转接。因此，需要比较它带来的质量提升与成本、延迟、维护难度；官方工程建议也强调从简单方案开始，按实际需要增加复杂度。[Anthropic 工程建议](#)

截图里的“复杂度治理”，具体可以理解为：**设置最大轮次、超时、明确的完成条件和失败后的处理方式，让协作能够收尾。**

④ 最下面的追问，是在确认你有没有工程落地意识。

- **上下文怎么共享与隔离？** 各 Agent 保留自己的任务历史，按需传递任务描述、必要资料和结构化结果；需要讨论时，再向指定参与者广播。
- **出错怎么定位？** 给一次任务设置统一标识，记录各 Agent 的输入、输出、工具调用、耗时和交接关系。沿调用链找到最早出现错误的步骤，而不是只看最后答案。

面试时，可以组织成这样一段回答：

常见模式包括主管调度、平级移交和流水线。主管模式适合动态分工并统一汇总，平级移交适合专家之间灵活接手，流水线适合步骤稳定的任务。在 AgentScope 中，可以用消息传递连接各 Agent，用 Pipeline 控制顺序、用 MsgHub 广播信息，并通过路由或工具调用实现任务分派。同时要设计上下文边界、停止条件和日志追踪。如果单 Agent 配合工具已经能稳定完成任务，我会优先使用更简单的方案。

Agent 效果评估指标

★这个是什么意思？面试如何回答

这道题在考：**Agent 不仅要“回答得对”，还要“把事情办成”，并且过程合理、成本可控。**

比如用户说“帮我取消订单 123”，Agent 可能需要查询订单、判断能否取消、调用取消接口。评估时不能只看它最后有没有说“已取消”，还要检查订单是否真的取消了。

可以按图里的三个层次理解：

层次	要回答的问题	主要指标
结果层	用户的事情办成了吗？	任务成功率、答案正确率
过程层	工具和参数用对了吗？	工具选择准确率、参数正确率、漏调用、多余调用、无效循环
效率与体验层	完成任务用了多少时间和成本？	端到端延迟、调用次数、token 和工具成本、转人工率

两个核心指标，要能说清定义。

① 任务成功率：最终达到用户目标的任务比例。

任务成功率 = 成功完成任务数 ÷ 被评估的任务总数

关键是提前定义“成功”的验收条件。比如取消订单，要检查订单系统中的状态确实变为“已取消”，同时取消的是正确订单。**回复“已取消”，但系统状态没变，仍然算失败。**

假设测试 100 个任务，90 个满足验收条件，任务成功率就是 90%。

② 工具调用准确率：工具是否选对、调用是否合理。

按照截图中“选对工具”的口径：

工具选择准确率 = 正确选择工具的调用次数 ÷ 被评估的工具调用总次数

比如应该调用 `cancel_order`，却调用了 `refund_order`，就是工具选择错误；调用了 `cancel_order`，但把订单号填成 456，则是**参数错误**。

不同团队也可能把工具选择和参数正确合并成“工具调用准确率”。面试时先说明统计口径，再展开即可。

还需要补充：**只统计已经发生的调用，会漏掉“应该调用却没调用”的问题**，所以要一起检查漏调用和多余调用。

面试时可以直接这样回答：

我会从结果、过程、效率与体验三个层面评估 Agent。

结果层重点看任务成功率，也就是满足预先定义的业务验收条件的任务数，占全部评估任务的比例。对于有实际操作的任务，我会检查数据库或业务系统的最终状态，不能只凭 Agent 的最终回答判断成功。

过程层看工具选择准确率和参数正确率，同时检查漏调用、多余调用、关键步骤顺序以及无效循环。这能帮助我们区分失败究竟来自工具选择、参数生成，还是执行过程。

效率与体验层看端到端延迟、调用次数、token 和工具成本，以及转人工率。在成功率和业务约束达标的前提下优化这些指标。

具体实施时，我会建立包含正常、异常和边界场景的评测集，标注成功条件、必要工具和关键步骤。先做离线评估和回归测试，再通过线上 A/B 和用户反馈验证效果。

图里还有两个容易被追问的点：

- **Golden 轨迹是什么意思？** 就是人工确认的参考执行路径，例如“查询订单 → 检查取消条件 → 取消订单”。但同一任务可能有多条正确路径，因此通常检查必要步骤和顺序约束，不要要求每一步都完全一样。
- **步数是不是越少越好？** 要在成功率和业务约束达标的前提下比较。必要的确认、验证和重试可能增加步数，但能提高可靠性。

如果面试官继续问：

- **没有标注数据怎么快速评估？** 先选一小批有代表性的真实任务，人工定义验收条件；能通过系统状态或规则判断的先自动判断，开放性回答再结合人工抽检，逐步积累评测集。
- **LLM-as-Judge 可靠吗？** 可以辅助判断相关性、完整性等开放性质量，但要有明确评分标准，并用人工样本校准。对于“订单是否真的取消”这类有客观结果的任务，应优先用业务状态验证。

★我还是没懂Golden轨迹是什么意思？

你可以把 **Golden 轨迹**理解成：**一项任务的“标准操作过程样例”**。

“Golden”表示经过确认的正确参考，“轨迹”表示 Agent 执行任务时留下的步骤记录。

比如用户说：“**帮我取消订单 123，如果已经发货就不要取消。**”

我们提前准备一份正确执行样例：

步骤	Agent 做什么	得到什么结果
1	调用查询订单工具，传入订单号 123	订单尚未发货
2	调用取消订单工具，传入订单号 123	取消成功
3	告诉用户“订单 123 已取消”	用户得到处理结果

这份“调用了什么工具、传了什么参数、得到了什么结果”的记录，就是 **Golden 轨迹**。

评估时，把 Agent 实际执行的过程和这份参考样例对照，就能发现：

- 没查订单就直接取消：漏掉了必要检查。
- 查询的是 123，取消的却是 456：参数错了。

- 没调用取消工具，却告诉用户“已取消”：事情没有办成。

所以，**标准答案告诉你“最后应该得到什么”**；Golden 轨迹还告诉你**“这件事可以怎样正确完成”**。

不过它只是正确路径的样例。例如 Agent 取消后又查询了一次，确认订单确实已取消，多了一步也可能是正确的。评估时重点看必要步骤和约束是否满足。

面试可以这样说：

Golden 轨迹是预先确认的正确执行过程样例，记录工具调用、参数和结果。我们用它检查 Agent 有没有漏掉关键步骤、选错工具或传错参数，但也要允许其他合理的执行路径。

Rerank 重排序：cross-encoder vs bi-encoder

这份面试题卡片考察的是大模型 **RAG（检索增强生成）** 以及 **现代搜索/推荐系统** 中最经典的核心架构问题：**重排序（Rerank）与两阶段检索架构**。

下面为你系统拆解**底层含义**、**满分面试回答模板**以及**高频追问的破局思路**。

一、这是是什么意思？（核心概念通俗拆解）

在 RAG 或海量搜索系统中，有几百万甚至上千万个文档切片（Chunks）。如果用户问了一个问题，我们怎么把它找出来？这里有两个极端：

1. 极端 A（算得快但不够准）—— Bi-encoder（双塔编码器，向量检索）

- **原理**：Query 和 Doc 是**分别独立**通过模型生成各自的向量（Embedding）。
- **为什么快**？文档的向量可以**离线提前算好**存在向量数据库里（如 Milvus、Qdrant）。在线搜索时，只需要给用户的 Query 算一次向量，然后做毫秒级的向量余弦距离或内积计算（ANN 近似最近邻检索）。
- **为什么不够准**？Query 和 Doc 在编码时**完全没有上下文交流**（各自单相思）。把一整段文字压缩成一个固定维度的向量（如 768 或 1024 维），会丢失大量的关键词细节、修饰关系和逻辑因果，经常出现“语义看似接近，其实答非所问”。

2. 极端 B（算得极准但极其慢）—— Cross-encoder（单塔重排，Rerank）

- **原理**：把 [Query + Doc] 拼成一句话，一起送进同一个 Transformer 模型。
- **为什么准**？模型利用自注意力机制（Self-Attention），让 Query 里的**每一个词**都能和 Doc 里的**每一个词**做直接的交叉权重计算（Token-level Cross Attention）。能够极其敏锐地捕捉否定词、细节限制、逻辑对应关系。
- **为什么慢**？因为 Query 每次都不一样，Doc 必须跟 Query 捆绑在一起才能算，**无法提前离线计算**。如果对 100 万篇文档都这么算，一次搜索可能要花几十分钟，算力直接打满。

3. 核心结论：“先召回后精排”是工程妥协的最优解

◦ 面对百万/千万级候选集：

1. **粗排/召回 (bi-encoder / BM25)**：用几毫秒从 100 万篇里抓出相关度较高的 **50~100 篇**（宁可多抓，保证高召回率 Recall）。

2. **精排/重排 (cross-encoder / Reranker)**：对这 50~100 篇进行全交叉注意力精确打分，耗时几十毫秒，挑出最关键的 **Top 3~5 篇** 喂给大模型。

◦ **效果**：兼顾了海量检索的毫秒级速度与核心结果的极致准确率。

二、面试如何回答？（优秀候选人模板）

面试官提问：“Rerank 的作用是什么？cross-encoder 与 bi-encoder 的区别？为什么要先召回后精排？”

建议按照“**结论先行 -> 原理深度剖析 -> 架构设计与收益 -> 生产实践经验**” 四步回答：

1. 结构与原理区别（展现算法底蕴）

“这两个模型的本质区别在于**注意力机制发生的位置以及是否有 Token 级别的交互**：

- **bi-encoder (双塔)**：Query 和 Document 分别独立编码成稠密向量。它的优势是**解耦**，所有文档向量可以离线预建索引，在线只需要做点积或余弦计算，复杂度是 $O(1)$ 或对数级的 ANN 检索，速度极快；但缺点是缺乏词级别的跨注意力（Cross-Attention）交互，信息压缩损耗大。
- **cross-encoder (单塔)**：将 Query 和 Document 拼接成一条序列输入模型。从第一层 Transformer 开始，Query 和 Doc 的所有 Token 就在做全量自注意力交互，能够深刻捕捉细粒度匹配、语义限定和逻辑否定，打分极准；但缺点是强耦合，**完全无法离线预计算**，在线计算复杂度随候选数线性增长，无法用于大规模检索。”

2. 为什么要“先召回后精排”？（体现架构思维）

“这是工业界为了****平衡计算延迟与检索质量 (Latency vs. Quality) ****演化出的分层漏斗架构：

- 如果全链路只用 bi-encoder，召回的 Top 5 往往掺杂大量噪声，直接塞给大模型会引发**大模型幻觉**或触发上下文丢失（Lost in the Middle）。
- 如果全链路只用 cross-encoder，海量候选在线打分会导致延迟爆炸，系统不可用。
- 因此采用‘两阶段架构’：先用 bi-encoder（或结合 BM25 多路召回）从百万级库中用毫秒级时间粗筛出 Top 50~100 篇候选（**求全/保召回率**）；再用 cross-encoder 对这几十篇候选进行高精度打分重排，筛选出 Top 3~5 篇优质上下文给大模型（**求精/保准确率**）。”

3. 生产实践与选型经验（体现落地能力，拿高分关键）

“在我们的工程落地中：

1. **模型选型**：重排层我们通常选用开源标杆模型如 `bge-reranker-large`、`bge-reranker-v2-m3` 或 `Cohere Rerank`。
2. **量化与加速**：Rerank 模型如果不做优化，给 100 条候选打分可能需要 150~300ms。我们通常会做 **FP16 / INT8 量化**，并基于 TensorRT 或 ONNX Runtime 部署，将候选集控制在 30~50 篇左右，把精排延迟严格压制在 50ms 以内。”

三、常考追问拆解（提前准备，反客为主）

追问 1：Rerank 让延迟涨了 150~200ms，真的值得吗？怎么权衡？

- 回答核心：算“端到端 ROI（总耗时与 Token 成本）”。

1. **给大模型减负**：大模型生成阶段（LLM Generation）本身的耗时往往是秒级的（1~3 秒），且按 Token 计费。如果不做 Rerank，为了保证正确率你可能得塞 10~15 篇上下文（长文本），导致 LLM 首字延迟（TTFT）大幅增加；而加上 Rerank 后，只需要喂 3~5 篇高相关片段，**LLM 推理阶段节省的时间和 Token 开销，往往可以直接抵消甚至反超 Rerank 增加的耗时。**
2. **工程降级与裁剪**：
 - **缩减候选池**：根据召回分数的分布，只对 Top 30 进行 Rerank，而不是死板地塞 100 条。
 - **模型轻量化**：用 Base 版代替 Large 版，或者知识蒸馏后做 ONNX 加速。
 - **阈值短路机制（Early Exit）**：如果第一路向量召回的 Top 1 得分极高且与 Top 2 拉开断层差距，可跳过 Rerank 直接走生成。

追问 2：多路召回（向量召回 + 关键词召回 BM25）的结果需要先融合再重排吗？

- 回答核心：需要先做“去重与粗筛”，但不必依赖复杂的融合打分。
1. **去重与并集**：假设稠密向量召回 50 条，BM25 稀疏召回 50 条，两者去重后通常在 70~80 条。
 2. **是否需要 RRF（倒数排名融合）？**
 - 如果候选总量在 Rerank 吞吐承受范围内（如 60~80 条）：直接把去重后的并集丢进 cross-encoder 即可。因为 cross-encoder 本身具备绝对打分能力，能抹平向量距离（Cosine）和关键词得分（BM25）之间量纲不同的问题。

- 如果召回量过大（如每路召回 100 条，并集超 150 条）：必须先用 RRF (Reciprocal Rank Fusion) 或简单的权重规则归一化打分，粗筛截断出前 50 条，再送进 Rerank，否则 GPU 推理时延会严重超标。

分块参数实验与 Badcase 全链路归因

固定检索参数，例如：

- 使用同一个 Embedding 模型。
- 使用相同的检索方式，比如都采用向量检索。
- TopK 都设为 5。
- 使用相同的过滤规则、重排模型和重排规则。

固定生成参数，例如：

- 使用同一个大模型及版本。
- 使用相同的提示词模板。
- Temperature、最大输出长度等设置保持一致。

LangChain4j 核心组件：@Tool 与 ChatMemory

“ChatMemory 是“消息级”记忆，与向量长期记忆不同；上下文超长要做摘要或窗口裁剪。”这是什么意思？

这句话可以拆成三部分理解：

1. “消息级记忆”：把之前的聊天消息带给模型。

比如：

```
用户：我用的是 Java 17。  
AI：好的。  
用户：给我写一个线程池示例。
```

下一次调用模型时，ChatMemory 会把前面的消息一起放进上下文，所以模型知道示例要适用于 Java 17。**模型表现得像“记住了”，是因为程序再次提供了这些消息。**

2. “向量长期记忆”：需要时，检索以前保存的相关信息。

比如保存了用户偏好、历史事件等，把这些内容转成向量。以后用户提问时，根据语义相关性找出需要的片段，再交给模型。

两者的侧重点是：

- **ChatMemory**：维护对话消息及其顺序，让当前聊天能够接着说。
- **向量记忆**：从大量已保存的信息中，找出与当前问题相关的内容。

这里的“长期”不能理解成只有向量库才能持久保存。**ChatMemory 也能存到 Redis；向量检索只是实现长期记忆的一种方式。**

3. “上下文超长”：聊天记录不能无限带给模型。

模型每次能处理的 token 数量有限，消息越多，成本通常也越高。因此需要控制上下文：

- ****窗口裁剪****：只保留最近的消息。简单、省成本，但早期信息可能丢失。
- ****摘要****：把较早的聊天压缩成关键信息。例如把几十轮聊天总结为“用户使用 Java 17，要求不引入第三方依赖”。信息更紧凑，但可能遗漏细节，也会增加摘要成本。

面试时可以说：

ChatMemory 主要通过维护并重放对话消息来提供上下文；向量记忆则按相关性检索已保存的信息。对话变长后，可以保留最近消息，或者把较早内容做摘要，控制上下文长度和调用成本。

并发会话隔离

GPT的答案

这段话想解决两个问题：

- **数据隔离**：A、B 同时聊天时，不能拿错对方的历史消息、检索结果。
- **资源隔离**：AI 请求很慢时，不能把其他业务接口一起拖慢。

最关键的是先理解最后那句“单例 Bean 成员变量会串话”。

Spring 中的 `@Service` 默认是单例，也就是同一个容器里的多个请求，通常调用**同一个对象**。
[Spring 官方说明](#)

假设代码这样写：

```
@Service
public class ChatService {

    // 多个请求共享这个字段
    private String currentUser;

    public String chat(String userId, String question) {
        currentUser = userId;
        return searchAndAnswer(currentUser, question);
    }
}
```

两个请求可能这样交错执行：

```
A 请求: currentUser = "A"
      ↓ 线程切换
B 请求: currentUser = "B"
      ↓ A 继续执行
A 请求: 读取 currentUser, 结果读到 "B"
      → 按 B 的身份检索资料
```

A 自己的请求还在执行，但共享字段已经被 B 改了。这就是串话的一种来源。

改为参数和局部变量：

```
public String chat(String userId, String question) {
    // 每次检索返回属于本次请求的独立结果
    var documents = search(userId, question);

    return answer(question, documents);
}
```

A 的调用拿着 A 的 `userId` 和 `documents`，B 的调用拿着 B 的值，它们不会通过这个成员字段相互覆盖。注意，局部变量如果仍指向共享的可变对象，也需要处理并发安全。

再对应截图里的四点：

截图中的措施	直白理解	解决什么问题
① 请求上下文用局部变量或显式传参	本次检索结果、工具返回值跟着本次调用走	避免临时数据被其他请求覆盖
② 会话记忆按 <code>memoryId</code> 隔离	每个聊天窗口有自己的“聊天记录本”	避免历史消息串到其他会话
③ 连接池、限流	复用连接，并限制同时访问外部服务的数量	避免慢调用耗尽连接和处理能力
④ AI 与业务线程池分开	给 AI 任务和普通业务分别安排执行资源	减少慢 AI 任务对普通业务的影响

② 可以具体理解为 Redis 里使用不同的 key：

```
chat:memory:用户A:会话1 → A 的第一段会话
chat:memory:用户A:会话2 → A 的第二段会话
chat:memory:用户B:会话1 → B 的会话
```

按 key 分开，才是会话隔离的原因。 Redis 的作用是让多个服务实例都能访问同一份会话数据。共享 Map 也能按会话分开，但还要考虑线程安全、多实例共享和数据持久化。

③、④可以用“排队”理解：如果 AI 回答需要 20 秒，大量请求会长时间占用资源。限流控制进入的数量，连接池控制连接使用，独立线程池让 AI 任务在自己的队列里执行。**这些措施保护容量，不会自动解决串话。**“池化”通常针对 HTTP / 数据库连接，模型客户端是否需要额外池化要看具体实现。

截图还有两个容易误解的地方：

- **ThreadLocal 是按线程保存数据。** 在线程池里要及时清理，切换到异步线程时也不会自动传递上下文，所以显式传参通常更清楚。
- **不同会话分开后，同一会话仍可能并发冲突。** 两条消息同时读取旧历史、生成回答、写回时，可能互相覆盖，因此通常按会话协调整个聊天轮次。LangChain4j 官方也要求避免并发调用同一个 `memoryId`。[官方说明](#)

截图的“必然串话”说得过于绝对。准确表述是：**单例 Bean 可以安全使用；把用户专属的可变状态放进共享成员字段，会产生串话风险。**

Gemini答案

一、核心痛点：为什么把“上下文”存成员变量，AI 应用必然串话？

1. 生活化比喻：会议室白板 vs 个人随身笔记本

- Spring 的单例 Bean (Singleton)：相当于一间所有人共用的会议室，整个公司只有这一间。
- Bean 的成员变量 (Field)：相当于会议室正中央的那块大黑板。
- 方法的局部变量 (Local Variable)：相当于每个人带进会议室、写完就带走的私人小笔记本。

如果员工 A 进来，在**大黑板**上写下：“我是张三，这是我的工资明细”。然后 A 开始打电话（耗时很长的操作）。在 A 打电话的这 5 秒钟里，员工 B 进来了，把黑板擦掉，写上：“我是李四，我要查假条”。当 A 打完电话回过头看黑板时，黑板上已经变成李四的名字了！——**这就是“串话”**（张三拿到了李四的数据，或者李四看到了张三的隐私）。

2. 代码对比：错在哪？怎么改？

❌ 致命错误写法（必然串话）：

```
@Service
public class ChatService {
    // 错误! 这是单例 Bean 的成员变量，所有并发请求共享这几个字段!
    private String currentUserId;
    private List<String> ragDocuments;

    public String askAi(String query, String userId) {
        this.currentUserId = userId; // 线程 A 赋值: "张三"
        this.ragDocuments = searchVectorStore(query); // 线程 A 检索出张三的私密数据

        // 【致命等待区】：调用大模型需要耗时 3~5 秒!
        // 此时线程 B (李四) 进来了，执行了 this.currentUserId = "李四"，并覆盖了 ragDocuments!
        String answer = callLlm(query, this.ragDocuments);

        // 此时打印出来的 currentUserId 已经变成李四了，甚至大模型吐出的回答被发给了李四!
        return answer;
    }
}
```

为什么传统 CRUD 业务没暴露，AI 应用一上线 100% 暴雷？

- **传统 CRUD**：查 MySQL 只要 5 毫秒。哪怕写了成员变量，因为时间极短，两个并发请求精准撞在一起的概率很小，测试环境根本测不出来。
- **AI 应用**：检索向量库 + 联网搜索 + 大模型流式吐字，通常需要 2,000 ~ 10,000 毫秒 (2~10秒)！这个“时间窗口”被放大了上千倍，高并发下并发请求重叠率是 100%，只要有 2 个人同时提问，必定产生数据覆盖与串话！

正确写法（栈封闭 / 局部变量）：

```
@Service
public class ChatService {
    // 不声明任何有状态的成员变量!

    public String askAi(String query, String userId) {
        // 数据存放在当前线程私有的 JVM 方法栈帧中，线程间物理隔离
        List<String> userRagDocs = searchVectorStore(query);

        // 无论等多久，userRagDocs 都只有当前线程自己能访问
        return callLlm(query, userRagDocs);
    }
}
```